

Masterarbeit

**Adaptives, lernendes Assistenzsystem zur
Aufenthaltsgestaltung an Mobilitätsknoten intermodaler
Reiseketten**

von

Niclas Kannengießer

Fachgebiet Mensch-Maschine-Systemtechnik

Univ.-Prof. Dr.-Ing. Ludger Schmidt

Fachbereich Maschinenbau, Universität Kassel

Mensch-Maschine-Systemtechnik
Univ.-Prof. Dr.-Ing. Ludger Schmidt

Universität Kassel
Mönchebergstr. 7
34125 Kassel

L.Schmidt@uni-kassel.de
fon 0561 804 2704
fax 0561 804 93 2704

05.07.2017

Masterarbeit für Herrn Niclas Kannengießer, Matr.-Nr. 31248637

Umfang 18 Credits inkl. Kolloquium

Studiengang Wirtschaftsingenieurwesen, Fachrichtung Maschinenbau

**Adaptives, lernendes Assistenzsystem zur Aufenthaltsgestaltung an
Mobilitätsknoten intermodaler Reiseketten**

Im Rahmen dieser Arbeit soll ein Assistenzsystem konzipiert, prototypisch realisiert und evaluiert werden, das dem Nutzer an Mobilitätsknoten Vorschläge zur Gestaltung des Aufenthalts macht. Diese generierten Vorschläge sollen auf den jeweils aktuellen Nutzungskontext abgestimmt werden und insbesondere auf einem Modell des Nutzers basieren, das mit der Zeit die Fähigkeiten und Interessen des Nutzers lernt und sich entsprechend adaptiert.

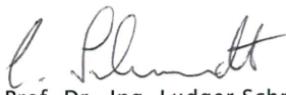
Die Arbeit ist eingebettet in das Forschungsprojekt RadAR+. Die Implementierung erfolgt auf einem Android-Smartphone. Für Visualisierungen und zur Sprachinteraktion wird die Datenbrille Microsoft HoloLens eingesetzt. Die Darstellung von Vorschlägen sowie die Möglichkeit zum Feedback sind entsprechend dieser technischen Rahmenbedingungen zu gestalten. Eine wichtige Anforderung aus dem Projektkontext ist die ausschließlich lokale Vorhaltung und Verarbeitung von Nutzerdaten. Eine Abweichung von dieser Anforderung durch Anonymisierung muss ggf. im Gesamtkonsortium abgestimmt werden.

Ein spezieller Schwerpunkt der Arbeit ist der Umgang mit der Kaltstart-Problematik im Kontext von Nutzerstudien, also die Adaption an den Nutzer, ohne dessen Eigenschaften über einen längeren Zeitraum lernen zu können.

Zur Bearbeitung des Projekts wird folgende Vorgehensweise vorgeschlagen:

1. Recherche zum Stand der Technik bzgl. geeigneter technischer Lösungsansätze sowie zu vergleichbaren Assistenzsystemen und deren Evaluation
2. Ermittlung aller im Projektrahmen nutzbaren Parameter der Kontext- und Nutzermodelle.

3. Erarbeitung eines Konzepts für das Assistenzsystem einschließlich der Adoptions- und Lernfunktionen. Zentrale Assistenzfunktionen sollen sein:
 - a. Hinweis auf relevante POI entlang des Weges
 - b. Hinweis auf Aufenthaltsmöglichkeiten bei absehbaren Wartezeiten
4. Planung der nutzerbasierten Evaluation, insbesondere der zu betrachtenden Szenarien, Aufgaben und Forschungshypothesen und der aufgrund der Kaltstart-Problematik vorzunehmenden Vorarbeiten (z. B. Ermittlung der üblichen Laufgeschwindigkeit)
5. Realisierung eines für die geplante Evaluation geeigneten Prototyps mit dem ein Teil des Konzepts umgesetzt werden soll. Andere Teile können simuliert oder in Absprache mit dem Betreuer vernachlässigt werden.
6. Durchführung der geplanten Evaluation mittels einer bestehenden virtuellen Simulationsumgebung in der CAVE des Fachgebiets. Anschließend statistische Auswertung hinsichtlich der Forschungshypothesen und geeignete Dokumentation der Ergebnisse.



Univ.-Prof. Dr.-Ing. Ludger Schmidt



Dipl.-Inf. Jens Regenberg

Hiermit erkläre ich, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel benutzt habe.

Ort, Datum

Unterschrift

Inhaltsverzeichnis

Abbildungsverzeichnis.....	I
Tabellenverzeichnis	II
Listenverzeichnis	III
1 Einleitung	1
2 Stand der Technik	2
2.1 Item- und User-Repräsentation.....	3
2.2 Initiales Daten Set	5
2.3 Empfehlungen finden	6
2.3.1 Soziales Filtern.....	7
2.3.2 Wissensbasiertes Filtern.....	9
2.3.3 Hybride Ansätze.....	11
2.3.4 Diversität in Empfehlungen	12
2.3.5 Kontext-Sensitivität	12
2.3.6 Architektur	15
2.4 Darstellung und User Interface.....	15
2.4.1 Gängige Ansätze	16
2.4.2 Darstellung in Augmented Reality.....	17
2.5 Feedback.....	17
2.6 Adaptives Lernen.....	18
2.7 Privatsphäre und Empfehlungssysteme	19
2.8 Verwendung bei der Reiseassistenz	20
2.9 Evaluation von Empfehlungssystemen.....	21
3 Anforderungen	24
4 Gesamtkonzept des Assistenzsystems zur Aufenthaltsgestaltung	27
4.1 Überblick über die Komponenten	27
4.2 Aufbau und Funktionsweise des Empfehlungssystems zur Aufenthaltsgestaltung	34
4.2.1 Initiales Daten Set und Benutzer-Initialisierung	34
4.2.2 Repräsentation von Benutzern, Items und Kontext	35
4.2.3 Filterung	36
4.2.4 Präsentation von Empfehlungen	42
4.2.5 Feedback	47
4.2.6 Adaptivität und Lernen	48
5 Evaluation des Systems zur Aufenthaltsgestaltung.....	51
5.1.1 Zielsetzung	51

5.1.2	Genereller Aufbau	52
5.1.3	Gesamtszenario	52
5.1.4	Umsetzung	54
5.1.5	Studiendesign	54
6	Prototypische Realisierung.....	58
6.1	Eingrenzung der Funktionen des Gesamtkonzeptes	58
6.2	Komponenten und Umfang des realisierten Teilsystems	59
6.2.1	Wizard-of-Oz Controller	60
6.2.2	CAVE.....	69
6.2.3	HoloLens	71
7	Durchführung der Evaluation.....	73
8	Ergebnisse und Limitierung	74
9	Diskussion	75
10	Ausblick	76
11	Literaturverzeichnis.....	77
12	Anhang	85
12.1	Benutzer-Modell des Gesamtkonzept	85
12.2	Item-Modell des Gesamtkonzept	111
12.3	Kontext-Modell des Gesamtkonzept	152
12.4	Übersicht über Feedbackmechanismen des Gesamtkonzept	152
12.5	Benutzer-Modell des Prototyp	152
12.6	Item-Modell des Prototyp	152
12.7	Kontext-Modell des Prototyp	152
12.8	Übersicht über Feedbackmechanismen des Prototyp	152
12.9	Netzwerknachrichten im Prototyp	152

Abbildungsverzeichnis

Abbildung 1: Kategorisierung von Informations-Quellen eines Empfehlungssystems (Felfering & Burke, 2008)	5
Abbildung 2: Filter-Techniken und ihr jeweiligen Wissensquellen (Burke, 2007, S. 379)....	7
Abbildung 3: Case-based reasoning cycle (Eremeev & Vagin, 2011, S. 106)	11
Abbildung 4: Pre-Filtering	13
Abbildung 5 Post-Filtering	13
Abbildung 6: Contextual-Modelling	13
Abbildung 7: Schematische Übersicht über Hauptkomponenten des Systems und deren Zusammenwirken.....	27
Abbildung 8: Schematischer Überblick über den Suchbaum bei der Suche mit Critiquing.	32
Abbildung 9: Schematischer Filterprozess auf dem Smartphone des Benutzers.....	37
Abbildung 10: Schematische Darstellung des Effizienz-Modus	43
Abbildung 11: Schematische Darstellung der Top-N-Item Liste	44
Abbildung 12: Schematische Darstellung der maximalen Detail-Ansicht eines Items der Domäne Gastronomie während der Benutzer steht	45
Abbildung 13: Detailansicht während der Fortbewegung des Benutzers	46
Abbildung 14: Überblick der prototypischen Realisierung	60
Abbildung 15: Schematische Darstellung des im Prototypen implementierten Filters	65

Tabellenverzeichnis

Tabelle 1: Gegenüberstellung der Item Eigenschaften	38
Tabelle 2: Cosinus-Ähnlichkeit der Items	39

Listenverzeichnis

Liste 1: Kategorisierung von Benutzer-Modellen nach Rich (1979b, S. 330).....	4
Liste 2: Auflistung exemplarischer Aspekte on der Kontext-Modellierung (Ziegler et. al, 2005)	14
Liste 3 Auflistung von Qualitäts-Aspekten zur Bewertung von Empfehlungssystemen (Gunawardana & Shani, 2015)	22
Liste 4: Empfehlungs-Modi des Assistenzsystems zur Aufenthaltsgestaltung.....	30
Liste 5: Im System genutzte Klassen zur Darstellung des Grades der Vertrautheit eines Benutzers mit seiner Umgebung	31
Liste 6: Umfang dargestellter Informationen in der Detailansicht von Items aufbauend auf Vertrautheits-Klassen (s. Liste 5)	47
Liste 7: Ziele der geplanten Evaluation	52

1 Einleitung

Die zunehmend allgegenwärtige Verfügbarkeit des Internets von verschiedenen Endgeräten und deren zunehmend umfangreicherer Sensorik vergrößerten das Funktionsspektrum von Assistenzsystemen deutlich. Das wird u. a. an der zunehmenden Vielseitigkeit von Apps deutlich, die in den vergangenen Jahren entwickelt wurden und Bereiche umfassen, wie bspw. Gesundheit, Finanzen und Reisen.

Bei aktuellen Reise-Assistenzsystemen...

Diese häufig eingesetzten Assistenzfunktionen sollen im Rahmen des Forschungsprojekts RadAR+ um ...

Augmented Reality (AR)...

Das Projekt umfasst verschiedene, sich gegenseitige bedingende oder beeinflussende Module, wie bspw. Indoor- und Outdoor-Navigation, das Beziehen von Echtzeitinformationen sowie auch ein Sprachsteuerungs-Modul. In dieser Arbeit wird das Modul zur Aufenthaltsgestaltung an Verkehrsknoten betrachtet. Dabei wird u. a. ein Empfehlungssystem System (*Recommender System*, kurz: RS) implementiert, das über klassische Reiseinformationen hinaus auf den Benutzer zugeschnittene Empfehlungen generiert.

Das Generieren von Empfehlungen hängt von vielfältigen Faktoren ab, die mit dem jeweiligen Benutzer in Verbindung stehen. Dazu gehören sowohl demographische Daten, kognitive Verarbeitungs-Prozesse und die jeweilige Intention eines Benutzers.

... der Benutzer-Intention (wie spezifisch sind die gesuchten Informationen)

... der Persönlichkeit des Nutzers (zu welchem Grad sollen die Ergebnisse neu für den Nutzer sein)

... der Benutzer-Kontext (welche Items kommen dem Nutzer bereits bekannt vor)

... dem Vertrauen des Nutzers in das RS

... dem Interface, mittels derer der Nutzer das System bedient

2 Stand der Technik

Assistenzsysteme helfen....

Die Möglichkeit, dass ein Benutzer das Assistenzsystem mit gewünschten Einstellungen umgestalten kann wird als Customization bezeichnet. Diese Einstellungen umfassen bspw. das Ein- und Ausblenden von Funktionen und das Konfigurieren von Warnungen (bspw. bzgl. der Anzeigedauer).

Die ursprüngliche Anwendung von RS röhrt aus dem E-Commerce, wo sie auch heute noch am stärksten eingesetzt werden. Im Allgemeinen werden RS definiert als ein System, „[...] das einem Benutzer in einem gegebenen Kontext aus einer gegebenen Entitätsmenge aktiv eine Teilmenge nützlicher Elemente empfiehlt“ (A. Klahold, 2009). Mit RS ist das sogenannte Tailoring in einigen Bereichen (bspw. geeignete Informationsdarstellung) verknüpft. Tailoring wird verstanden als das Verwenden persönlicher Charakteristika, Präferenzen und Attribute eines Benutzers mit dem Ziel, zur Verfügung gestellte Informationen für ihn zu individualisieren (Noar et al., 2016). Nach Kreuter et al. (1999) ist Tailoring definiert als „Any combination of information or change strategies intended to reach one specific person, based on characteristics that are unique to that person, related to the outcome of interest, and have been derived from an individual assessment“. Dabei wird sich stark auf das Ergebnis oder den Kontext der bereitgestellten Informationen nach den Interessen des Nutzers fokussiert (Kreuter et al., 2000). Informationen hoher Relevanz für den Benutzer werden demnach hervorgehoben bzw. aufbereitet dargestellt, um den Informationsgehalt individuell zu konzentrieren. Anders als beim Tailoring steht bei der Personalisierung von Informationen, die persönliche Ansprache des Benutzers mit seinem Namen oder seinen Charakteristika im Fokus. Ziel der Personalisierung ist es, die Motivation des Benutzers zum Verarbeiten von Informationen zu steigern (Bargh, 1982). Außerdem soll die Aufmerksamkeit des Benutzers gegenüber personalisierten Nachrichten erhöht werden und zum Verarbeiten von Informationen stimulieren (Kirchner et al., 2000). Anders als beim Tailoring wird durch Personalisierung die Erinnerung an Informationen nicht erhöht. Benutzer können durch Personalisierung u. U. von den eigentlichen Informationen abgelenkt werden (Tam et al., 2006, pp. 883-885).

Tailoring von Informationen und der Einsatz von Empfehlungen in Anwendungen und Diensten im Internet wurden aufgrund der messbar besseren User-Experience auch für andere Anwendungsbereiche attraktiver (Hof et al., 1998; Bache, 1999; Cooperstein et al.,

1999; Hagen et al., 1999; Schafer et al., 1999; Peppers & Rogers, 1993; Peppers & Rogers, 1997). Twitter entwickelte den Who-to-Follow-Algorithmus, der auf Basis ähnlicher Vorlieben von Benutzern Empfehlungen für das Abonnieren bestimmter Nachrichten empfiehlt (Gupta et al., 2013). Netflix erregte mit dem Netflix Prize große Aufmerksamkeit, als es darum ging, bestehende Algorithmen zum Generieren von Empfehlungen von Filmen zu optimieren (Amatriain & Basilico, 2015).

In diesem Kapitel wird beschrieben, auf welche Weise RS Relationen zwischen Benutzern und Benutzern und Items feststellen. Dabei wird verstärkt auf Mechanismen eingegangen, die getailorte Empfehlungen generieren. Die einem Benutzer empfohlenen Objekte werden im Folgenden als Item bezeichnet. Ein Item kann bspw. ein Produkt oder Information sein. Items sind gewöhnlich passiv, d. h. sie geben kein aktives Feedback auf Empfehlungen. Die aktive Komponente in einem RS ist der Benutzer bzw. User. Dieser bekommt vorgeschlagene Items in einer geeigneten Form dargestellt und reagiert auf diese auf verschiedene Art und Weise. Darüber hinaus muss zwischen Daten und den daraus generierten Informationen unterschieden werden: „Daten werden aus Zeichen eines Zeichenvorrats nach definierten Syntaxregeln gebildet [...]. Daten werden zu Information, wenn ihnen eine Bedeutung (Semantik) zugeordnet wird. Man assoziiert einen Begriff, eine Vorstellung aus der realen Welt oder theoretischer Art. Man stellt die Daten in einen „Kontext“. Daten sind dann Symbole, d. h. Platzhalter für Betrachtungsgegenstände, so genannte Konzepte.“ (Bodendorf, 2006).

Die Beurteilung der Qualität von Empfehlungen und dem ihnen zugrundeliegenden System wird in *Kapitel 2.9* beschrieben.

2.1 Item- und User-Repräsentation

Bevor ein RS umgesetzte bzw. eingesetzt werden kann, muss die Repräsentation von Benutzern, Items und die dazu notwendigen Informationen festgelegt werden. Dabei muss untersucht werden, welche Informationen aus welchen Daten abgeleitet werden können und ob bzw. wie die benötigten Daten erfasst werden können.

Für die Repräsentation ist zwischen dem Modellbasierten (model-based) und einem Speicher-basierten (memory-based) Ansatz zu unterscheiden. Wohingegen beim Speicher-basierten Ansatz sämtliche Daten, die mit dem Benutzer bzw. einem Item assoziiert werden, in die Empfehlungsgenerierung einbezogen werden, wird beim Modellbasierten nur ein Teil dieser Daten einbezogen. Dadurch ist der Modellbasierte Ansatz meist performanter. Zudem besteht unter Verwendung des Speicher-basierten Ansatzes verstärkt

die Gefahr eines Overfittings aufgrund der fehlenden Generalisierungs-Fähigkeit (Breese et al., 1998).

Modellbasierte RS bilden Benutzer-Modelle unter Verwendung von Data-Mining und Techniken des maschinellen Lernens. Aufgrund der Kompaktheit der Benutzer-Modelle sind diese Systeme meist performanter und besser zu skalieren als Speicher-basierte. Daraus resultiert eine meist kürzere Antwortzeit. Andererseits ist das notwendige Modellieren der Benutzer und Items abhängig vom Abstraktionsgrad und dem Grad der gewünschten Individualisierung meist aufwendig. Eine Unterscheidung von Benutzer-Modellen kann wie in *Liste 1* vorgenommen werden. Dabei trennt Rich (1979b) ähnlich wie Oppermann (1994) u. a. zwischen Modellierung anhand expliziter Benutzereingaben und systemseitiger Modellierung.

1. Sind sie Modelle eines kanonischen Benutzers oder sind sie Modelle individueller Benutzer?
2. Werden die Modelle vom Benutzer explizit erstellt oder werden sie vom System auf Basis des Benutzerverhaltens abstrahiert?
3. Enthalten sie kurzfristige, sehr spezifische Informationen oder langfristige, eher allgemeine Informationen?

Liste 1: Kategorisierung von Benutzer-Modellen nach Rich (1979b, S. 330)

Viele Daten über die Präferenzen des Benutzers können bei getailorten RS unter Einbeziehung des Nutzungsverhaltens eines Users gewonnen werden. Welche Informationen für die jeweiligen Modelle benötigt werden und ob und wie die dafür benötigten Daten bereitgestellt werden müssen im Vorfeld geklärt werden. Felfering und Burke (2008) haben die Bezugs-Quellen für Benutzer- und Item-Informationen soziale, individuelle und Inhalts-basierte unterteilt:

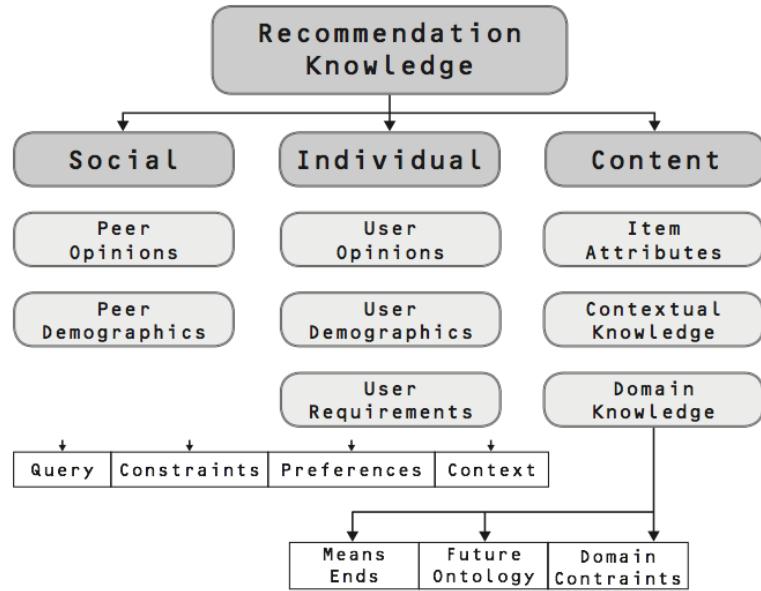


Abbildung 1: Kategorisierung von Informations-Quellen eines Empfehlungssystems (Felfering & Burke, 2008)

Die Beschreibung von Items beschränkt sich meist auf ihre inhaltlichen und meist statischen Eigenschaften (*Item Attributes*), wie z. B. Preis oder inhaltlicher Bezug. Im Gegensatz dazu verändern sich die Bedürfnisse der Benutzer stetig, wodurch die Entwicklung eines ggf. zu erstellende Benutzer-Modells maßgeblich beeinflusst wird. Benutzerbedürfnisse können anhand scharfer Parameter, bspw. demographischen Eigenschaften, wie bspw. Alter und Geschlecht, sowie unscharfen Eigenschaften, bspw. der Meinung des Benutzers oder dessen Vorwissen in einer bestimmten Domäne, abgeleitet werden.

2.2 Initiales Daten Set

Sobald die Repräsentation von User und Items festgelegt und der damit verbundene Bedarf an Daten und Information identifiziert worden ist, muss der Bedarf an Daten zum Start der Anwendung geklärt werden. Dieser optionale Bestand wird als Initial Dataset bezeichnet und dient hauptsächlich dem Entgegenwirken des sog. Kaltstartproblems (Cunningham et al., 2001). Dieses Problem ergibt sich verstärkt bei RS, die auf Basis von sozialen Filter-Methode (s. 2.3) Empfehlungen generieren und dafür auf eine hohe Aktivität von möglichst vielen Nutzern angewiesen sind.

Initial Datasets können sowohl einmalig für das ganze System generiert werden als auch zum Start der Nutzung einer Applikation durch einen neuen User. Im ersten Fall ist ein weit verbreiteter Ansatz das Bilden von Personas. Diesen werden Benutzer (häufig anhand demographischer Daten) Benutzer zugeordnet (Kobsa et al., 2001). Im letzteren Fall wird

häufig eine initiales Benutzer-Modell anhand von wenigen Eckdaten, die für die jeweilige Anwendung besonders relevant sind erzeugt. Um den Nutzer dabei zu unterstützen können ihm zum Start der Anwendung Fragen gestellt werden. Auf Basis seiner Antworten werden bei der anschließenden Nutzung erste Empfehlungen generiert. Diese Methode macht die Empfehlungen des Systems sehr transparent für den Benutzer, birgt allerdings das Problem, dass Benutzer ihre Bedürfnisse häufig nicht konkret genug ausdrücken können. Ein anderer Ansatz wird durch das Erstellen von sog. Training-Sets verfolgt. Dabei wird ein Benutzer aufgefordert verschiedene konkrete Items aus den u. U. verschiedenen Domänen des Systems zu bewerten. Auf dieser Grundlage kann das RS schon bereits zu Beginn zwischen mehr und weniger relevanten Items unterscheiden (Boone, 1998).

2.3 Empfehlungen finden

Um dem Benutzer unter der Vielzahl von Items in einem RS nur diejenigen zu präsentieren, die zum jeweiligen Zeitpunkt am wahrscheinlichsten für ihn relevant sind, wird gefiltert. Die Art des Filterns ist dabei stark abhängig von dem Anwendungsfall und den zugrundeliegenden Daten. Allgemein ist jedoch in allen Filter-Methoden zu beobachten, dass im ersten Schritt eine Vorauswahl von für Empfehlungen in Frage kommenden Kandidaten generiert wird und anschließend daraus die endgültigen Empfehlungen gewählt werden.

Empfehlungen im Rahmen einer Echtzeit-Reiseassistenz zu generieren erfordert das Berücksichtigen von Daten und Informationen verschiedener Domänen, bspw. geographische Daten sowie konkrete Ziele und persönliche Vorlieben des Benutzers. Daher werden im Folgenden aktuelle Methoden vorgestellt, die den Umgang mit diesem Problem ermöglichen. Dabei werden Filter-Methoden zuerst in soziale und Wissensbasierten Filtermethoden unterteilt und anschließend Kontext-Sensitivität einbezogen. *Abbildung 2* illustriert, an diese zusätzliche Klassifizierung angepasst, die Verknüpfung verschiedenen Wissens und der jeweilig angewandten Filter-Methode:

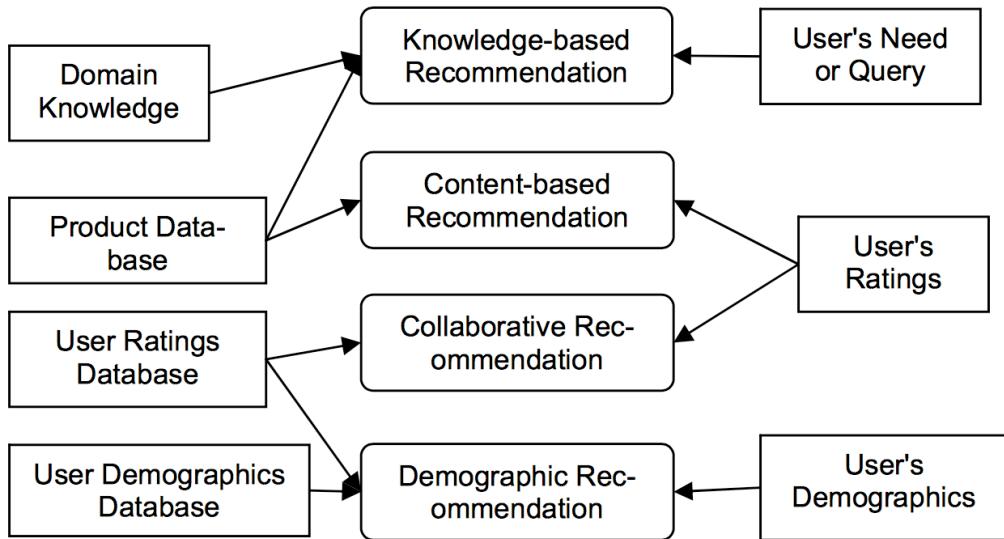


Abbildung 2: Filter-Techniken und ihr jeweiligen Wissensquellen (Burke, 2007, S. 379)

2.3.1 Soziales Filtern

Sollen Empfehlungen auf Basis subjektiver Kriterien (bspw. anhand von Bewertungen von Filmen) generiert werden, eignen sich soziale Filter-Methoden. Nach Konstanz & Ried (2012) kann Benutzern das Finden von passenden Produkten unter Verwendung von Ähnlichkeiten zwischen ihren Profilen sehr vereinfacht werden. Innerhalb sozialer Filter-Methoden wird zwischen Collaborative-Filtering und Content-based Filtering unterschiedene. Nach Simonson (2005) ist jedoch besonders im e-Commerce zu beachten, dass Empfehlungen für Items besser auf Basis von persönlichen Charakteristika der Benutzer gemacht werden, als auf Basis ihrer Produktpräferenzen, da User meist nur eine begrenzte Sicht auf das Angebot haben.

Collaborative-Filtering

Collaborative-Filtering ist ein weit verbreiteter Ansatz im Bereich E-Commerce (Goldberg et al., 1992; Maes et al., 1999; Resnick et al., 1994; Resnick et al., 1997). Dabei werden Daten über die Gewohnheiten und Vorlieben von Benutzern aggregiert. Darunter fallen Daten über die Nutzung der Anwendung (z. B. angeklickte Items, Suchanfragen, etc.) und Bewertungen von Items, wobei diese explizit oder implizit ausgedrückt werden können (Delgado & Davidson, 2002; s. Kapitel 2.5). Basierend auf diesen Daten können Gemeinsamkeiten zwischen Benutzern identifiziert und Empfehlungen abgeleitet werden. Da die Wissensbasis bei Collaborative-Filtering hauptsächlich aus Angaben der Benutzer besteht (typischer Weise Bewertungen), ist es häufig nicht notwendig die Attribute der Items genauer zu analysieren. Collaborative-Filtering kann deswegen in vielen Bereichen

genutzt werden, in denen keine oder nur eine unstrukturierte textuelle Beschreibung der Items vorliegt (Gupta et al., 1999; Miyahara & Pazzani, 2000).

Die Qualität der Empfehlungen eines RS auf Basis von Collaborative-Filtering ist abhängig von der Anzahl der Bewertungen und Aktionen, die mit einem Benutzer assoziiert werden können (Shardanand & Maes, 1995). Weiterhin birgt Collaborative-Filtering die Gefahr, dass häufig von vielen Benutzern gekaufte Items in hohem Maße mit verschiedenen Benutzern und Items Korrelieren. Burke (2000) bezeichnet dieses Problem, das eine item-to-item-Relation nahezu unmöglich macht, als Banana-Problem.

Ansätze für Collaborative-Filtering können in Nachbarschafts- und Model-basierte Methoden unterteilt werden (Desrosiers & Karypis, 2011; Linden et al., 2003; Shardanand & Maes, 1995; Everitt, 1993). Beim Nachbarschafts-basierte Ansatz werden Items gemäß vorhandener User-to-Item-Relationen bewertet. Im Gegensatz dazu werden beim Model-basierten Ansatz diese Bewertungen verwendet, um ein Model für Vorhersagen von Bewertungen neuer Items einzutrainieren. Modelle können u. a. unter Verwendung von Clustering-Algorithmen (bspw. Pearson-Korrelation, Bayes'sche Klassifizierer) erstellt werden (Linden et al., 2003, McDonald & Ackermann, 2000). Wird lediglich einer dieser Algorithmen eingesetzt ergibt sich daraus ein einziges kollaboratives Modell, das als Birds-of-a-Feather-Flock beschrieben wird (McDonald & Ackermann, 2000).

Content-based Filtering

Beim Content-based Filtering oder Feature-based Filtering werden Informationen aus den (un)strukturierten Daten über ein Item gesammelt und ausgewertet. Die Daten beinhalten bspw. Beschreibungen oder Meta-Tags (Delgado & Davidson, 2002). Das jeweilige Model, das die Präferenzen eines Users abbildet, wird individuell unter Berücksichtigung von den Bewertungen von Items und deren Beschreibungen generiert. Die Beschreibung von Items liegt meist in textueller Form vor und kann sehr unstrukturiert sein. Deswegen werden häufig Text-Mining-Algorithmen eingesetzt, um die Beschreibungen zu strukturieren. Diese Systeme versuchen Regelmäßigkeit in den Item-Beschreibungen aufzudecken aufgrund derer Relationen zwischen Items identifiziert und bewertet werden können (Miyahara & Pazzani, 2000). Anschließend werden die bewerteten Items mit den Präferenz-Modellen der User abgeglichen und diese Relation bewertet. Daraus ergibt sich eine Liste von Items, die für den jeweiligen Benutzer als potentiell relevant angesehen werden.

Die aktuell noch begrenzten technischen Möglichkeiten zur inhaltlichen Analyse von Items und Überspezialisierung sehen Shardanand und Maes (1995) als ein Problem bei der Verwendung reinen Content-based Filterings. Nach Jannach et al. (2011) verbesserte die Berücksichtigung von Semantik bei der Analyse von Beschreibungen den traditionellen Ansatz einer reinen Schlagwortsuche beim Content-based Filtering.

2.3.2 Wissensbasiertes Filtern

Wissensbasierte (Knowledge-based) RS orientieren sich an objektiven Fakten über User und Items und umgehen dadurch einige Probleme sozialer Filter-Methoden, wie bspw. das beschriebene Banana-Problem oder die notwendiger Weise große Anzahl aktiver Benutzer. Das Sammeln von Informationen über Benutzergewohnheiten und Bewertungen von Benutzern fließen bei diesen Methoden nicht ein, weswegen wissensbasierte Filter-Ansätze häufig nicht getailort sind („one-fits-all“-Ansatz). Anstelle dessen werden Annahmen über die Relevanz von Items auf Basis objektiver Kriterien getroffen, bspw. einem gewünschten Gewichtig, Ausmaß. Dieser Ansatz erfordert, dass User ihre Bedürfnisse konkret ausdrücken können, weswegen häufig Dialog-Systeme eingesetzt werden (s. Kapitel 2.5).

Wissensbasierte Filtermethoden können in Constraint-Based- und Case-Based-Filtering eingeteilt werden. Können keine Items gefunden werden, die die Anfrage eines Users befriedigen, können bei beiden Ansätzen sog. Repair-Funktionen implementiert werden. Repair-Funktionen „[...] exploit mechanisms supporting the determination of minimal set of changes to the given set of customer requirements such that a solution can be found which is considered as repairs“ (Felfering & Burke, 2008, p. 4).

Constraint-based Filtering

Selten bewertete oder gekaufte Items (z. B. Häuser, Autos) können sehr schlecht unter Verwendung zuvor vorgestellter sozialer Filter-Methoden empfohlen werden. Sofern Items konkrete Parameter zu erfüllen haben, ist constraint-based Filtering eine geeignete Methode zu generieren von Empfehlungen. Die dabei verwendeten Parameter werden als Constraints bezeichnet und bilden in ihrer Gesamtheit ein Constraint-Set bezogen auf eine Anfrage. Der Filter-Prozess kann daraufhin als Constraint-Satisfaction angesehen werden (Tsang, 1993). Constraint können dabei sowohl durch den User als auch durch Items gegeben sein. Ein exemplarischer Anwendungsfall für den Einsatz von Constraint-based Filtering ist der folgende:

„Joe would like to buy web hosting services for his business. He connects to a recommender system for such services and answers a few simple questions such as whether e-commerce services (e.g., shopping cart or advisory services) are required, what is the expected number of users per day, and what is the expected connection performance. Joe answers these questions and receives immediate feedback that due to the expected number of users hosting services should be based on a higher connection performance (an option that has as well been selected by many other users). Joe accepts this proposal and the system recommends the solutions HostingA and HostingC. Joe asks for more information on each of these, and learns that they both have similar pricing, but that although HostingA offers more storage, HostingC has a larger bandwidth. He ultimately decides that he would rather have the better bandwidth and chooses HostingC.“

(Felfering & Burke, 2008, S. 1)

Die Qualität von Empfehlungen durch Constraint-based Filtering ist stark abhängig von der Qualität und der Menge an Informationen über Items und User. Dazu ist es unbedingt notwendig, ein genaues Verständnis über die jeweilige Domäne zu besitzen. Ein Vorteil von Constraint-based RS gegenüber sozialen Filter-Methoden ist, dass ein Kaltstart ohne weiteres möglich ist.

Case-based Filtering

Case-based Filtering hat seinen Ursprung im maschinellen Lernen. Es ist eine Methode, die ein neues Problem löst, indem es mit in der Vergangenheit gelösten Problemen auf Ähnlichkeiten untersucht wird. Existiert ein vergleichbarer Fall (Case), wird dieser wiederverwendet, um das aktuelle Problem zu lösen (Eremeev & Vagin, 2011). Bei diesem Ansatz werden ein Case und ein Item als identisch angesehen. Die Problem-Komponente eines Case wird typischer Weise als ein Set aus Attributen eines Items dargestellt, die durch einen User angegeben wurden. Die Lösung des Cases sind letztendlich diejenigen Items, die die verlangten Attribute in ausreichender Weise erfüllen. Können keine Items einer Lösung zugeordnet werden, wird ein neuer Zyklus gestartet. In Abbildung 3 wird das generelle Vorgehen von Case-based Filtering dargestellt:

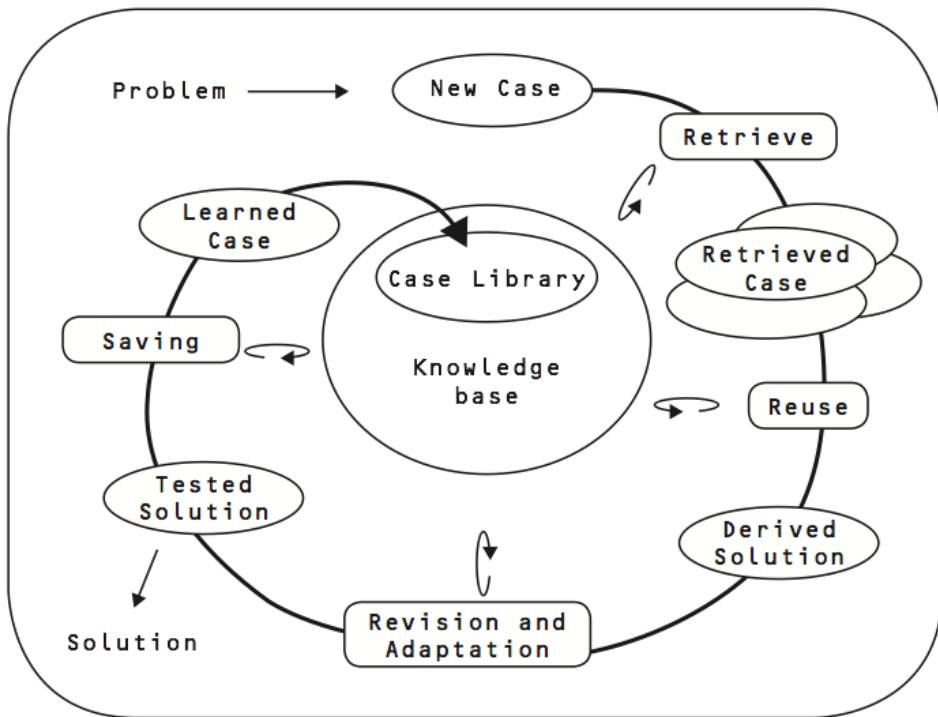


Abbildung 3: Case-based reasoning cycle (Eremeev & Vagin, 2011, S. 106)

2.3.3 Hybride Ansätze

Aufgrund der vorgestellten Vor- und Nachteile der einzelnen Filter-Methoden werden diese häufig zu hybriden Ansätzen kombiniert (Burke, 1999; Good et al., 1999; Felfering & Burke, 2008). Dabei kann auch die selbe Filter-Methode mit unterschiedlich eingestellten Parametern genutzt werden. Hybride Systeme können u. a. eingesetzt werden, um das Kaltstart-Problem zu minimieren (Burke, 2007).

Beim Einsatz mehrerer Filter-Methoden zur Generierung von Empfehlungen ist eine Strategie zum Vereinigen der jeweiligen Ergebnisse notwendig (Burke, 2007; Burke, 2002). Burke (2007) identifizierte sieben verschiedene Herangehensweisen, die zu diesem Zweck eingesetzt werden, aus denen hier drei beschrieben werden. Eine einfache Möglichkeit bietet das Zusammenführen unter Einsatz von Gewichtungen für jeden einzelnen Recommender. Dabei generiert jeder Recommender die Relevanz der Items. Bei der anschließenden Zusammenführung der Ergebnisse können Mengen-Operationen (bspw. die Schnittmenge aller Kandidaten) oder die Berechnung des Kombinierten-Scores anhand von Linearkombinationen angewandt werden. Bei der Zusammenführung mittels Schnittmengenbildung ist es jedoch möglich, dass nur wenige Kandidaten verbleiben. Eine weitere Strategie ist das Zusammenführen der Kandidaten-Listen jeweiliger Recommender in einer kombinierten Liste. Dabei werden die Empfehlungen nebeneinander gelistet. Als

Switching wird die Möglichkeit des Systems bezeichnet, einen einzelnen Recommender unter Berücksichtigung der entsprechenden Situation auszuwählen.

2.3.4 Diversität in Empfehlungen

Sinha und Swearing (2002) fanden heraus, dass Benutzer einem RS mehr vertrauen, wenn bereits bekannte Items in den Empfehlungen auftauchen. Zudem können einige fremde Items eingestreut werden, um dem Benutzer Anreize zu schaffen, neue Items aus u. U. anderen Domänen zu entdecken. Dadurch soll eine ausgewogene Mischung zwischen ähnlichen und verschiedenen Items erzeugt werden, die verhindert, dass der Benutzer nur noch ähnliche Items empfohlen bekommt (McGinty & Smith, 2003; McNee et al., 2006; Pu et al., 2012a). Rachid et al. (2002) bezeichnen das Problem mangelnder Diversität bei Empfehlungen als *Similarity Hole* und veranschaulichen dieses wie folgt: „[...] once a user rated Star Trek movie she would only receive recommendations for more Star Trek movies“ (Rashid et al., 2002, S. 127). Dieses Problem ist außerdem als Filter Bubble bekannt. Nach Pariser (2011) entsteht eine diese, wenn Web-Dienste algorithmisch basierend auf Benutzerprofilen vorauszusagen versuchen, welche Informationen der Benutzer sucht. Dadurch gerate der Benutzer in eine Isolation gegenüber Informationen, die seinem Profil nicht entsprechen.

Eine Möglichkeit dem Aufbauen einer Filter Bubble technisch entgegenzuwirken wird als Cycling bezeichnet (Zhao et al., 2017). Dabei werden Items, die aufgrund ihrer als hoch eingestuften Relevanz in einer Top-n-Item-List immer ganz oben positioniert wurden gegen Items niedrigerer Relevanz getauscht werden, sofern die Top-Items nicht vom User genutzt wurden. Diese Manipulation der Reihenfolge kann sich auf die aktuelle Sitzung des Nutzers beschränken (intra-session) oder folgende Sitzungen beeinflussen (inter-session).

2.3.5 Kontext-Sensitivität

Wie in den *Abbildung 1* bereits dargestellt, gibt es die Möglichkeit den jeweiligen Kontext in dem ein Benutzer ein System nutzt einzubeziehen. Kontext-sensitive RS werden als Context-Aware RS (CARS) oder Context-Driven RS bezeichnet. Abhängig von der Forschungsrichtung variiert die Definition des Kontextbegriffes. In dieser Arbeit wird Kontext wie im Bereich Mensch-Computer-Interaktion verstanden werden als „...any information that can be used to characterize the situation of entities (i.e. whether a person, place or object) that are considered relevant to the interaction between a user and an application, including the user and the application themselves.“ (McCarthy, 1993, S. 5).

Kontext kann in diesem Sinne nach Winograd (2001) weiter differenziert werden in Setting und den aktuellen Kontext. Unter dem Begriff Setting werden alle Umgebungs faktoren, die eine Situation kennzeichnen zusammengefasst. Der eigentliche Kontext beschränkt die Anzahl von Kontextfaktoren eines Settings auf die tätigkeitsrelevanten. Kontextfaktoren können bspw. die Uhr- oder Jahreszeit, die geographische Position oder der emotionale Zustand einer Person sein.

Der jeweilige Kontext zu einem bestimmten Zeitpunkt als Element der Menge aller Kontextzustände gesehen. Bei der Kontext-Modellierung müssen generell alle möglichen Kontext-Zustände abzubilden sein, wobei zu einem Zeitpunkt nur bestimmte Eigenschaften aktiviert sind. Die Realität vollständig abbildende Kontext-Modelle gibt es aufgrund der unendlich großen Zahl potentiell zu berücksichtigender Faktoren jedoch nicht (Brézillon, 2003). Daher ist eine hierarchische Verteilung von Relevanzen auf die verschiedenen Faktoren notwendig.

Kontext-sensitive RS erfordern zusätzliches Filtern (Adomavicius & Tuzhilin, 2015). Generell werden die dazu verwendeten Filter-Methoden in Pre-Filtering (*Abbildung 4*), Post-Filtering (*Abbildung 5*) und Contextual-Modeling (*Abbildung 6*) unterteilt:

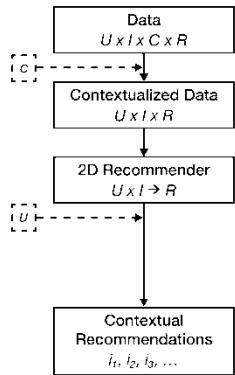


Abbildung 4: Pre-Filtering

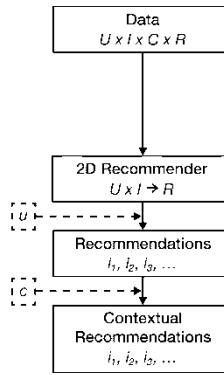


Abbildung 5 Post-Filtering

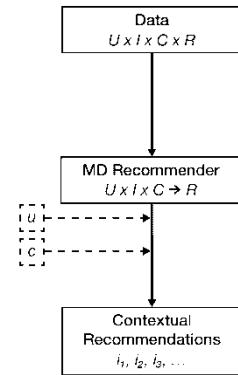


Abbildung 6: Contextual-Modelling

Beim Pre-Filtering werden zuerst ausschließlich Daten aus der Datenbank ausgewählt, die zum aktuellen Kontext passen. Diese Auswahl erfolgt unter Einbezug des Benutzers (*U*), des Items (*I*), des Contextes (*C*) und der entsprechenden Bewertung (*R*). Anschließend werden die zuvor beschriebenen Filter-Methoden auf den generierten Datensatz angewandt. Wird Post-Filtering angewandt, läuft dieser Filter-Vorgang umgekehrt ab. Beide Verfahren sind werden als 2D-Verfahren bezeichnet, da sie beim Generieren der Empfehlungen nur zwei Faktoren einbeziehen. Contextual-Modeling ist hingegen ein 3D-Verfahren, da

Empfehlungen in einem Schritt unter simultanem Einbezug von User-, Item- und Kontextdaten generiert werden (González et al., 2004).

Der Kontext kann sowohl eine Rolle spielen, wenn der Benutzer Anfragen an das System stellt oder selbst das Generieren von Empfehlungen durch festgelegte Trigger auslösen. Solche Trigger können bspw. die Verspätung eines Zuges sein, den der Benutzer für seine Reise ausgewählt hat oder standortbezogene Informationen.

Das Kontext-Modell wird nach Ziegler et al. (2005) untergliedert in die Aspekte Benutzer und dessen Rolle, Aufgabe, Ort, Zeit und Gerät:

- *Benutzer & Rolle:*

In dieser Kategorie werden entweder individuelle Benutzer anhand unterschiedlicher Rollen definiert. Dabei kann eine explizite Auswahl und Zuordnung des Benutzers während der Systemverwendung erfolgen oder eine Eingruppierung auf Basis der Beobachtung des Nutzerverhaltens vorgenommen werden.

- *Aufgabe:*

Zielbezogener Kontext wie Arbeitsaufgaben oder persönliche Zielsetzungen bei der Nutzung, bei der Reiseassistenz mit Priorität 1 das Ankommen am Zielort. Bei langen Wartezeiten Prioritäten für den Aufenthalt anpassen. Priorität 2 ist dabei individuell auf den Benutzer zugeschnitten und ergibt sich aus Stereotypen und individuellen Eigenschaften.

- *Ort:*

Orts-Modelle, in denen der physische Aufenthaltsort des Nutzers eingeordnet werden kann (z. B. Geokoordinaten, im Bahnhof, Flughafen, im Freien)

- *Zeit:*

Unter dieser Kategorie sind Zeitinformationen zusammengefasst, wie z.B. die Zeitzone des Clients, die aktuelle Zeit, eine virtuelle Zeit und auch Reisebezogene Zeiten, wie Wartezeiten, Umsteigezeiten etc.

- *Gerät:*

Geräte-Informationen, wesentlich für die Anpassung von Informations-Präsentationen und Interaktions-Möglichkeiten werden durch diese Kategorie abgedeckt.

Liste 2: Auflistung exemplarischer Aspekte on der Kontext-Modellierung (Ziegler et. al, 2005)

Zusätzlich können weitere potentiell adaptionsrelevante Kontextaspekte einbezogen werden, bspw. Umgebungslicht und -lautstärke (Schilit et al. 1994) oder der soziale Kontext (Gross & Specht 2002).

2.3.6 Architektur

Abhängig von der jeweiligen Anwendung variiert die Architektur des eingesetzten RS. Benutzer-Modelle können zentral auf einem Server gespeichert werden, wodurch der Nutzer auf jedem Endgerät auf dasselbe Modell zugreift. Eine andere Möglichkeit ist es, das Modell lokal auf dem Endgerät zu erstellen, was u. U. ein höheres Maß an Kontrolle über die eigene Privatsphäre bietet. Darüber hinaus können sich Benutzer-Modellen auf die jeweilige Sitzung beziehen und danach verworfen werden (intra-session) oder über längere Zeit gespeichert und fortlaufend Benutzereigenschaften adaptieren (inter-session).

Bei sozialen Filter-Methoden mit inter-session Benutzer-Modellen wächst die Menge gespeicherter Daten über Benutzer stetig. Die wachsende Menge an Daten lässt die Rechenzeit zur Generieren von sowohl Model-basierte als auch Speicher-basierte Ansätze beeinflusst. Um Endgeräte zu entlasten, Häufig werden diese Daten daher zentral gespeichert. Die Forderung nach kurzen Response-Zeiten auf eine Anfrage an ein RS und einer hohen Genauigkeit der Empfehlungen führt demnach zu einem Trade-Off. Um diesem entgegenzuwirken verwenden Dienstleister wie Netflix oder YouTube Batch-orientierte Architekturen. Dabei wird das Aktualisieren von Benutzer-Modellen auf einer sogenannten offline-Ebene durchgeführt. Das aktualisierte Model wird dann auf die sog. online-Ebene. Anhand der generierten Modelle können dann auf der Online-Ebene in kurzer Zeit relevante Items generiert werden. Wie von Amatriain und Basilico (2015) beschrieben, nutzt der Streaming Service Netflix neben der Online-Ebene eine dritte, die als Nearline-Ebene bezeichnet wird. Diese Ebene dient der Verkürzung der Response-Zeiten und beinhaltet die offline generierten Benutzer-Modelle in detaillierterer Form als die online-Ebene. Dadurch können Anfragen die von der Online-Ebene nicht sofort verarbeitet werden können zuerst an diese Ebene weitergegeben werden, bevor sie in die Offline-Ebene verarbeitet werden.

2.4 Darstellung und User Interface

Benutzern diejenigen Informationen in angemessenem Umfang und angemessener Qualität bereitzustellen, die sie zu einem bestimmten Zeitpunkt und in einem bestimmten Kontext benötigen, ist die Hauptaufgabe getailorter RS. Um das zu ermöglichen ist das Verstehen

von Benutzerpräferenzen besonders wichtig. Diese Präferenzen sind jedoch nicht strukturiert und nicht statisch, sondern vielmehr sehr dynamisch (Bettman et al., 1998; Slovic, 1995). Besonders, wenn Benutzer keinen Überblick über die Optionen haben, werden Entscheidungen oft intuitiv getroffen (Yaniv, 2004). Der Entscheidungsprozess wird häufig beeinflusst von bekannten Alternativen (Iyengar & Lepra, 2000; Levin & Gaeth, 1988; Parikh et al. 2001), das Vertrauen in das System (Wang & Benbasat, 2005) und das User Interface (Hong et al., 2004; Lim & Benbasat, 2000; Schiaffino & Amandi, 2004). Daher müssen die durch Filtern generierten Empfehlungen dem Benutzer (unter Beachtung der Beschränkungen verschiedener Endgeräte) in angemessener Form vermittelt werden.

2.4.1 Gängige Ansätze

Häufig werden Empfehlungen als Liste dargestellt, in denen dasjenige Item mit der größten Wahrscheinlichkeit für den Nutzer relevant zu sein ganz oben aufgeführt wird. Weitere Items sind nachfolgende sortiert nach der Wahrscheinlichkeit angeordnet. Diese Darstellungsform nennt sich Top-N-Item-List und wird meistens bei konkreten Suchanfragen eingesetzt (Zhao et al., 2017).

Um gegenüber dem Benutzer transparent zu sein, empfehlen Pu und Chen (2006), dass zu jeweiligen Empfehlungen vermittelt wird, warum entsprechende Items ausgewählt wurden. Eine Möglichkeit ist die Einbindung von Critiquing, indem der Benutzer über mehrere Interaktionen seine Präferenz auswählt bzw. anpasst (Chen & Pu, 2006; Chen & Pu, 2012a; Linden et al., 1997; Zhang & Pu, 2006). Auf diese Art und Weise kann das System sich mit jeder Iteration genauer auf das aktuelle Bedürfnis des Nutzers einlernen. Critiquing wurde bereits in Case-based und Knowledge-based RS eingesetzt und wird in Kombination mit dem Anzeigen von Empfehlungen (*Recommendation-and-Critiquing*) u. a. *Tweaking* genannt (Burke et al., 1997).

Die meisten Dienste zur Reiseassistenz (bspw. DB Navigator oder Navigationssysteme mit Echtzeit Verkehrs-Informationen) sind bisher auf Smartphones oder sogar nur auf einem Computer zu nutzen. Aufgrund der Neuheit von Datenbrillen und der bisher noch geringen Verbreitung gibt es bisher keine Styleguides für die Gestaltung von Feedback und Darstellung in Verbindung mit RS. Verschiedene Empfehlungen aus dem Bereich AR werden in Kapitel 2.4 behandelt.

2.4.2 Darstellung in Augmented Reality

Die Gestaltung der Benutzeroberfläche und der Interaktionsmöglichkeiten eines RS haben starke Auswirkungen auf die Art möglichen Feedbacks auf Empfehlungen (s. Kapitel 2.5). Aufgrund der Neuheit von Datenbrillen zur Realisierung von AR existieren bis dato noch keine allgemeinen Styleguides, wie es bei Smartphone-Anwendungen der Fall ist. Allerdings gibt es Empfehlungen von bspw. Google (Google, 2015), was bei der Gestaltung von Einblendungen in AR zu beachten ist. Datenbrillen haben bisher ein sehr eingeschränktes Sichtfeld (bspw. Microsoft HoloLens mit 30°-40°; EPSON Moverio BT-300 mit ca. 23°). Um dieses nicht nur mit bereichernden Informationen zu überlagern und den Fokus des Nutzers von der Realität abzulenken, müssen Informationen mit möglichst minimalen Platzverbrauch dargestellt werden. Aus diesem Grund erscheint es besonders wichtig, generierte Empfehlungen zusätzlich zu tailorn. Dadurch soll die individuelle Relevanz dargestellter Informationen für den Benutzer schnell ersichtlich, dessen Aufmerksamkeit gesteigert und die Merkfähigkeit gesteigert werden (Skinner et al., 1994; Campbell et al., 1994; Brug et al., 1996; Kreuter, 1997). Darüber hinaus soll sich der Benutzer Informationen besser einprägen können und muss daher seltener Einblendungen in sein Sichtfeld aufrufen. Neben den neuen Herausforderungen, die mit Datenbrillen verbunden sind, ergeben sich auch einige Potentiale. Dazu gehört die mögliche Einbindung von 3D-Einblendungen oder die Bedienung anhand von Sprache und 3D-Gesten. Darüber hinaus ist es bspw. bei dem Datenbrillen-Modell HoloLens von Microsoft möglich Einblendungen nicht nur starr in der Brille zu verankern (Gerät-gebunden), sondern auch fest an Orten im Raum (ortsgebunden) oder relativ zum Benutzer (benutzergebunden).

2.5 Feedback

Feedback ist für RS notwendig, um mehr über die Interessen des Users zu lernen und dadurch auf Veränderungen in seinen Gewohnheiten und Bedürfnissen einzugehen. Darüber hinaus ist Feedback ein essentieller Bestandteil des Lernprozesses adaptiver RS. Feedback wird hier als Rückmeldung auf Empfehlungen aufgefasst und kann durch den User aktiv oder passiv gegeben werden. Unter aktiv werden dabei Aktionen verstanden, die der Benutzer direkt in Bezug auf ein Item ausdrückt, bspw. durch das Auswählen mittels Mausklick oder Bewertungen. Das dadurch erhaltene Feedback ist explizit und eindeutig. Passives Feedback wird durch den Benutzer unbewusst gegeben. Dazu zählen bspw. die Betrachtungsdauer von Posts, Klicks auf Items, um mehr Informationen zu erhalten oder auch die Dauer, über die ein Benutzer einen Film anschaut, bevor er umschaltet. Diese Art

des erhaltenen Feedbacks wird als implizit bezeichnet und muss anschließend interpretiert werden.

In Bezug auf Datenbrillen müssen weitere Arten von Feedback in Betracht gezogen werden. Da der Benutzer kein Endgerät in der Hand trägt, ist eine gewöhnliche, haptische Bedienung ungeeignet. Möglich ist hingegen die Bedienung des Systems mittels Sprache oder anhand von 3D-Gesten im Aufnahme-Korridor der Kamera der Datenbrille.

2.6 Adaptives Lernen

Nach Oppermann (1994) wird der Zugewinn von Angaben über den Benutzer in adaptiv (*adaptive*) und adaptierend (*adaptable*) unterteilt. Als adaptiv werden diejenigen System bezeichnet, die sich automatisch auf Basis ihrer Annahmen an Benutzer anpassen. Im Gegensatz dazu bietet ein System, das als adaptierend bezeichnet wird, dem Benutzer die Möglichkeit, manuell Veränderungen von Systemparametern vorzunehmen, an die es sich anpasst. Diese Ansätze können in Kombination verwendet werden. Nach Rich (1979) bringen Systeme, die Modelle auf Basis des Benutzerverhaltens aufbauen die Herausforderung mit sich, dass sie mit inkonsistentem und konfliktbehaftetem Benutzerverhalten umgehen müssen.

Um adaptierte Informationen für zukünftige Empfehlungen in das Benutzer-Modell zu integrieren ist ein Lernprozess notwendig. Für diesen Aktualisierungs-Vorgang werden häufig Data-Mining Techniken eingesetzt (Amatriain, 2013). Generell können drei sequentielle Schritte beim Data-Mining unterteilt werden: Data Pre-Processing, Model-Learning und Tests und Validierung.

Beim Data Pre-Processing wird darauf abgezielt, Daten aus der Realität für den Machine-Learning Prozess vorzubereiten. Welche Daten dazu gehören, ergibt sich aus dem Benutzer- bzw. Item-Modell.

Der Model-Learning Prozess lässt sich in überwachtes und nicht überbewachtes lernen Unterteilen. Der Hauptunterschied zwischen den beiden Ansätzen besteht darin, dass es sich bei überwachtem Lernen um ein Klassifizierungsproblem handelt, bei dem die Zugehörigkeit von Usern bzw. Items zu im Vorfeld bestimmten Klassen bestimmt wird, wohingegen beim nicht überbewachten lernen diese Klassen durch Clustering selbst bestimmt werden. Clustering kann bei Collaborative Filtering effizienter sein als Klassifizierung bei überwachtem lernen, wobei die Zunahme der Präzision der Empfehlungen sich nicht notwendigerweise verbessert (Amatriain & Pujol, 2015).

2.7 Privatsphäre und Empfehlungssysteme

Das Paradox zwischen dem Verlangen nach Privatsphäre und Personalisierung bzw. Tailoring im Internet kann besonders nach der breiten Verbreitung von Smartphones beobachtet werden (Kavassalis et al., 2003; Lee & Benbasat, 2003; Watson et al., 2002). Die meisten RS sammeln und speichern Informationen über Benutzereigenschaften und -verhalten, für die in 2.2 beschriebene Repräsentation von Nutzern bzw. Items. Besonders Smartphones bieten durch ihre Menge an Sensoren viele Möglichkeiten Benutzerdaten zu erfassen, die sich nicht auf die konkrete Interaktion mit der Anwendung beschränkt sind. Dadurch kann die Qualität von Empfehlungen und die Darstellung von Informationen durch gezieltes Tailoring verbessert werden (Peppers & Rogers, 1997; Stewart & Pavlou, 2002; Xu et al., 2008). Die meisten Benutzer sind dabei gewillt persönliche Informationen preiszugeben, um im Gegenzug besser durch das entsprechende RS unterstützt zu werden (Awad & Krishnan, 2006; Chellappa & Sin, 2005; Culnan & Bies, 2003; Kobsa, A., 2007; Toch et al., 2012). Diese Informationen reichen abhängig von dem entsprechenden RS von weniger sensiblen, bspw. das Alter, bis hin zu sehr sensiblen, wie bspw. Krankheiten. Die u. a. dadurch stetig größer werdende Menge von gesammelten und gespeicherten Benutzer- und Item-Informationen aus verschiedenen Domänen, die für Empfehlungen einbezogen werden, erscheint der Austausch dieser zwischen verschiedenen Anbietern sinnvoll. Durch die sich dadurch ergebende Aufwandsminimierung ergibt sich jedoch ein Problem, das als *Privacy-Personalization Trade-Off* bezeichnet wird (Awad & Krishnan, 2006; Berkovsky et al., 2012; Chellappa & Sin, 2005; Kobsa, A., 2007; Li & Unger, 2012; Zhang et al., 2014). Um die Privatsphäre der Nutzer zu schützen gibt es sowohl rechtliche Rahmenbedingungen, bspw. der European Data Protection Directive (1995) und der deren Regulation (2006), das deutsche Telemediengesetz (2007) oder von der OECD (OECD, 2013), als auch zahlreiche technische Realisierungsmöglichkeiten, die von der Erhöhung der Transparenz und Sicherheit einer Anwendung und der Verwendung von Nutzerdaten (Kobsa, 2001), über den Einsatz verteilter Agenten (Wang et al., 2015) bis zu Konzepten von differentiell-privaten RS (Sherry & Mironov, 2009) reichen.

Nach Friedmann et al. (2015) können Risiken für die Privatsphäre aus dem direkten Zugang zu Daten, durch andere Systembenutzer und durch externe Entitäten entstehen. Unter dem direkten Zugang zu Daten wird u. a. das Sammeln von Informationen über den Benutzer verstanden, ohne dass der Benutzer darüber explizit informiert wird und das damit verbundene, für ihn unerwartete Eingreifen in dessen Privatsphäre. Darunter fällt bspw. das untersuchen der im Smartphone gespeicherten Kontakte. Weiter werden Benutzerdaten

häufig aus verschiedenen Gründen an Dritte verkauft. Außerdem besteht ein Risiko der Privatsphäre durch Datenmissbrauch durch Mitarbeiter der entsprechenden Unternehmen, die mit der Handhabung der Daten betraut werden.

Ein Konzept, bei dem die Adaptierung und der Lernprozess zum Schutz der Privatsphäre auf dem mobilen Endgerät durchgeführt wird, wurde von Sutanto et al. (2013) vorgestellt. Dabei wird das Benutzer-Modell auf dem Endgerät gespeichert von wo aus Anfragen an einen Server gestellt werden. Dabei wird die Personalisierung und das Tailoring von Werbung durch Filtern auf dem Endgerät erreicht. Allerdings ist dieses Verfahren auf Pull-basierte Kommunikation begrenzt. Bei der Entwicklung eines RS für Reiseassistenz sind Push-basierte Benachrichtigung (bspw. Zugverspätungen) allerdings notwendig. Weitere Ansätze zum Schutz der Privatsphäre im Bereich Trust-Systeme sind Homomorphe Verschlüsselung und der Skalar-Produkt-Ansatz (Zhan et. al, 2010).

2.8 Verwendung bei der Reiseassistenz

Aktuell werden RS in Verbindung mit Reisen meist bei der Planung eingesetzt. Bspw. bietet TripAdvisor (www.tripadvisor.com) das Planen eines Aufenthalts in einer Stadt anhand weniger Parameter unter Einbezug von Bewertungen von Benutzern mit ähnlichen Eigenschaften an.

In der Reiseassistenz der Deutschen Bahn in der App DB Navigator werden Ergebnisse in der Autovervollständigung zur Suche nach Zielen aus der Historie von bereits gesuchten Zielen und gebuchter Tickets beeinflusst.

Auf Basis von Geo-Tags entwickelten Majid et al. (2013) ein kontextsensitives RS zum Generieren getailorter Empfehlungen von Orten. Dafür verwendeten sie die öffentlich zugängliche FlickrAPI mittels derer die Flickr Fotodatenbank nach Bildern durchsucht werden kann, die Geo-Tags enthalten. Durch Auswertung dieser social Tags und zusätzlicher Informationen zu entsprechenden Bildern entwickelten Ahern et al. (2007) bereits zuvor ein RS namens WorldExplorer. Dieses wurde um Kontext- und Kontext-basierte Analysen erweitert (Ahern et al., 2007).

Barbeau et al. (2010) haben eine kontextsensitive Reiseassistenz entwickelt, die mit Fokus auf geistlich eingeschränkte Personen, Benutzern zu bestimmten Abschnitten einer Reise Handlungsempfehlungen gibt. Diese fokussieren sich auf v. a. auf Abläufe bei bevorstehenden Umstiegen. Die Aufmerksamkeit des Benutzers wurde multimodal sowohl auf visuelle als auch akustische und taktile Weise auf das Endgerät gelenkt.

2.9 Evaluation von Empfehlungssystemen

Die Leistungsfähigkeit eines RS lässt sich nach verschiedenen Aspekten bewerten. Gängige Eigenschaften, die nach Gunawardana und Shani (2015) und Ge et al. (2010) auf die Qualität Einfluss nehmen, werden in Liste 3 aufgeführt und beschrieben:

- *Benutzer-Präferenzen*
Bewertung verschiedener Algorithmen nach ihren Empfehlungen durch Benutzers
- *Genauigkeit der Vorhersagen*
Die Genauigkeit der Empfehlungen in Bezug auf einen Benutzer kann in kategorisiert werden in die Genauigkeit der Vorhersagen von Bewertungen, der Nutzung von Items und des Rankings von Items.
- *Coverage*
Viele RS, die auf Basis von Collaborative Filtering arbeiten, geben sehr gute Empfehlungen für Items, zu denen viele Daten vorliegen. Für Items, über die wenige Daten vorliegen (Sparsity-Problem), werden die Empfehlungen hingegen oft deutlich schlechter. Dieses Problem wird als Heavy Tail oder Long Tail Problem bezeichnet und kann sowohl bei Items, die selten bewertet wurden, als auch bei Usern, bspw. in Form einer nicht erreichten Mindest-Anzahl von Bewertungen in Collaborative Filtering, auftreten. Ein dazu verwandtes Problem ist das zuvor beschrieben Kalt-Start-Problem.
- *Confidence*
Confidence beschreibt das Vertrauen des Systems in seine eigenen Empfehlungen bzw. Vorhersagen und den damit verbundenen Bewertungen.
- Vertrauen des Benutzers in das System
- *Neuheit* von Empfehlungen
- *Serendipity*, das Maß dessen, wie überraschend erfolgreiche Empfehlungen waren
- *Unterschiedlichkeit*, ausgehend von einem Item abstrahieren und andere Items empfehlen
Beispiel: Hotelsuche an einem Ort zum Urlaub machen und das RS empfiehlt Hotels in Gegenden, die ähnlich zur ursprünglich gesuchten sind
- *Gebrauchstauglichkeit*
Die meisten eCommerce Webseiten wollen vorrangig ihren Umsatz erhöhen und richten ihr RS danach aus.

- *Risiko*
Es ist zu klären, wie riskant die Empfehlungen für den Anwender sein können. Ein Beispiel dafür sind Empfehlungen zum Kauf von Aktien.
- *Robustheit und Sicherheit* gegenüber Angriffen und Manipulationen
- *Privatsphäre*
- *Anpassungsfähigkeit*
- *Skalierbarkeit*

Liste 3 Auflistung von Qualitäts-Aspekten zur Bewertung von Empfehlungssystemen (Gunawardana & Shani, 2015)

Nachdem die zu bewertenden Kriterien festgelegt sind, muss ein Versuchsaufbau festgelegt werden. Die nach Gunawardana und Shani (2015) dafür möglichen drei Varianten Offline-, Benutzer- und Online-Studie werden im Folgenden beschrieben.

Bei einer offline Evaluation findet keine Interaktion des Benutzers mit dem RS statt, weswegen dieser Versuch besonders einfach, günstig und mit relativ wenig Aufwand durchgeführt werden kann. Allerdings stehen dem die Begrenztheit auf zuvor zusammengestellte Daten-Sets entgegen. Zudem ist nur eine begrenzte Menge an Informationen zu erfassen, da der Einfluss auf den Benutzer durch das System offenbleibt. Benutzer neigen dazu, eher diejenigen Items zu bewerten, über die sie bereits eine starke Meinung entwickelt haben. Daraus kann das zuvor beschriebene Heavy Tail Problem resultieren, was bei Tests des RS berücksichtigt werden muss. Dieses Phänomen schlägt sich auch auf vorliegende Test-Datensätze nieder und muss vor der Durchführung einer Offline Evaluation durch eine Korrektur (bspw. mittels *Resampling* und *Reweighting*) beseitigt werden.

Eine weitere Möglichkeit der Evaluation von RS sind Experimente mit kleinen Gruppen in einer kontrollierten Umgebung. Dabei können sowohl qualitative Daten (durch Befragung der Benutzer vor, während und nach dem Versuch) erhoben werden sowie quantitative (bspw. Umfang und Genauigkeit zu dem/der die Aufgabe erfüllt wurde, Zeitaufwand). Weiter muss das Benutzerverhalten anders als in der Offline-Evaluation nicht simuliert werden. Ein typischer Test ist das Bewerten des Einflusses des RS auf das Browsing-Verhalten des Nutzers. Dabei wird eine Aufgabe ohne und einer weiterer mit Empfehlungen durchgeführt und überprüft, inwiefern das Browsing-Verhalten durch Empfehlungen beeinflusst wurde. Verglichen mit den anderen beiden Verfahren können Daten bei diesem Versuchsaufbau am genauesten erfasst werden. Allerdings sind Versuche dieser Art sehr zeitintensiv bezüglich der Vorbereitung und der Durchführung. Hinzu

kommt, dass lange Versuchsdauern eingeplant werden müssen, um alle Parameter erheben zu können. Daher wird meist nur kleine Anzahl von Probanden einbezogen, die nur wenige Aufgaben zu erfüllen haben. Diese Aufgaben müssen durch verschiedene Nutzer wiederholt werden, um verlässliche Ergebnisse zu erhalten. Zur Planung und Durchführung dieser Art der Evaluation kann das Framework von Pu et al. (2011) zur Hilfe genommen werden.

Durch den Einsatz des Systems bei einer Menge wirklicher Benutzer können die aussagekräftigsten Ergebnisse erzielt werden. Der Aufbau ist geeignet, um den Einfluss verschiedener Algorithmen bzw. Implementierungen eines RS anhand des Browsing-Verhaltens der Nutzer miteinander zu vergleichen. Häufig werden im eCommerce zur Durchführung solcher Evaluationen Anfragen von Usern zufällig auf ein Test-System weitergeleitet. Bevor ein solcher Test im laufenden Betrieb durchgeführt wird, ist allerdings zu empfehlen, die Funktionsfähigkeit des RS durch bspw. einen Offline-Evaluation zu überprüfen. Die Menge zu erfassender Parameter ist allerdings bei diesem Versuchsaufbau deutlich begrenzt.

3 Anforderungen

Ziel der Entwicklung ist ein portables Assistenzsystem, mittels dessen Benutzer während eines Aufenthaltes an Verkehrsknoten durch verbale und visuelle Hinweise dabei unterstützt werden, diesen Aufenthalt zu gestalten. Die Anwendung muss mobil nutzbar sein und soll mindestens von Android Smartphones unterstützt werden. Die See-Through Datenbrille Microsoft HoloLens (Developer Edition) muss als Ein- und Ausgabegerät des Systems über eine Schnittstelle am Smartphone eingebunden werden können.

Die von der Anwendung zu generierenden Hinweise umfassen benutzerbezogene Empfehlungen zur Aufenthaltsgestaltung (bspw. der Besuch eines Restaurants), Handlungsempfehlungen (bspw. Aufforderung zum auf den Weg zum nächsten Gleis machen) und Warnungen (bspw. Verspätung von Verkehrsmitteln). Für alle drei Arten von Hinweisen muss das System dem Benutzer die Möglichkeit bieten Einstellungen vorzunehmen. Diese Einstellungen umfassen u. a. das De-/Aktivieren von einzelnen Hinweisen und das Modifizieren von Zeitpunkten bzgl. Hinweisen.

Eine der Hauptkomponenten der Aufenthaltsgestaltung stellt das Empfehlungssystem dar. Dabei müssen Empfehlungen Benutzer-bezogen und Kontext-sensitiv generiert werden, um einem Nutzer seinen Aufenthalt am entsprechenden Verkehrsknoten so angenehm wie möglich zu machen. Empfehlungen zur Aufenthaltsgestaltung umfassen Points of Interest (POI) aus verschiedenen Domänen, wie bspw. Gastronomie, Shopping, Reisen und Finanzen. Empfehlungen von POI sollen sich geographisch auf den aktuellen Verkehrsknoten konzentrieren und vom Benutzer unter Berücksichtigung von Charakteristika (bspw. seine individuellen Gehgeschwindigkeit) fußläufig erreichbar sein. POI außerhalb des aktuellen Verkehrsknotens, zu deren Erreichbarkeit ggf. weitere Tickets notwendig sind, müssen nicht berücksichtigt werden. Um benötigte Daten über POI zu erhalten, können Web-Services eingebunden werden.

Das System soll den Nutzer bei Umstiegen darüber informieren, ob er noch Zeit für kurze Zwischenstopps (z.B. Zeitschrift kaufen) oder längere Aufenthalte (z. B. essen gehen) hat. Existieren geringe Zeitpuffer zwischen Umstiegen, soll es den Nutzer nur über diejenige Ausstattung (z.B. Sanitäre Anlagen, Kiosk) des aktuellen Verkehrsknotens informieren, die auf seinem direkten Weg zum nächsten Ziel liegt. Existiert ein zusätzliches, freies Zeitkontingent, sollen beim Generieren von Empfehlungen POI des gesamten Verkehrsknotens einbezogen werden. Dabei müssen deren Erreichbarkeit vom aktuellen Standort des Nutzers, der zeitliche Aufwand, jeweilige Benutzereigenschaften sowie die

vom Benutzer individuell festgelegte, minimale Aufenthaltsdauer zur Nutzung eines POI berücksichtigt werden. Das Reisen in Gruppen bzw. in Begleitung ist vernachlässigbar. Empfehlungen werden lediglich für einen einzelnen Nutzer generiert.

Beim Generieren benutzerbezogener Empfehlungen, muss das System neben demographischen Daten auch Vorlieben und Verhaltensweisen von Benutzern adaptieren. Auf Basis des damit verbundenen, kontinuierlichen Lernprozesses können Empfehlungen zunehmend individueller an den Benutzer angepasst werden. Die Adaption kann sowohl anhand expliziter Eingaben des Benutzers als auch anhand automatisch erfasster Daten und daraus abgeleiteter Implikationen durchgeführt werden. Explizite Angaben muss der Benutzer zudem in Form von Bedingungen bzw. Constraints bzgl. der Empfehlungen machen können. Das System soll demnach bspw. vom Benutzer gekennzeichnete Domänen beim Generieren von Empfehlungen nicht einbezieht.

Zusätzlich zu den Eigenschaften des Nutzers muss das System das jeweilige Setting beim Erstellen von Empfehlungen einbeziehen. Das Setting umfasst u. a. den Standort des Nutzers, die Uhr- und Tageszeit, Umstieg- und Wartezeiten zwischen Verkehrsmitteln sowie etwaige Verspätungen und Änderungen während der Reise. Um Veränderungen bzgl. der Umgebung des Nutzers und seiner Weiterfahrt erfassen zu können, müssen Echtzeit-Informationen bezogen und verarbeitet werden. Diese können von internen Komponenten der verwendeten Geräte und externen Diensten bezogen werden. Haben die erfassten Veränderungen Einfluss auf die Aufenthaltsgestaltung des Benutzers bzw. auf die Generierung von Hinweisen, muss der Benutzer darüber in Kenntnis gesetzt werden. Kommt es zu unvorhergesehenen bzw. spontanen (v. a. zeitliche) Veränderungen (z. B. durch Störungen), sollte der Benutzer bei seiner Reise über diese informiert werden. Im Falle einer Verspätung soll das System dem Nutzer bspw. den bekannten Umfang der Verspätung (z.B. 10 min) anzeigen. Sofern verfügbar, soll darüber hinaus eine kurze Begründung für die entstandene Veränderung eingeblendet werden. Durch diese Begründung soll dem Benutzer die Verlässlichkeit der aktualisierten, zeitgebundenen Informationen verdeutlicht werden.

Zu empfohlenen POI sollen Details abrufbar sein. Deren Detailgrad und Inhalt kann sich am notwendigen Informationsbedarf des Benutzers im entsprechenden Setting, seinem Kenntnisstand und seinen Intentionen anpassen. In der Detailansicht ist es wünschenswert, dass der Nutzer Bewertungen zu entsprechenden Aufenthaltsvorschlägen anonymisiert angezeigt bekommt (z. B. Restaurantbewertungen). Eine Möglichkeit dafür ist die Darstellung als Fünf-Sterne-Rating oder als Summe binärer Bewertung (*like/dislike*). Die

eigenen Bewertungen des Benutzers sollen Einfluss auf das Generieren seiner Empfehlungen nehmen und gehen in sein Benutzerprofil ein. Benutzer dürfen anhand ihrer Bewertungen außerhalb des genutzten Endgerätes nicht identifizierbar sein. Dennoch muss gewährleistet werden, dass jeder Benutzer nur einmal Bewertungen abgeben kann.

Zum Zeitpunkt der Inbetriebnahme der Anwendung durch den jeweiligen Benutzer müssen bereits personenbezogene Empfehlungen für die Aufenthaltsgestaltung generiert werden können. Um dies zu gewährleisten muss das Kaltstart-Problem gelöst sein. Dieses Problem ist sowohl auf der Seite der Bereitstellung von Items als auch bei der initialen Klassifikation von Benutzern anzugehen.

Obwohl Empfehlungen zur Aufenthaltsgestaltung benutzerbezogen sind, muss die Privatsphäre des Nutzers geschützt bleiben. Darunter fällt die Wahrung von Anonymität bei der Einbindung externer Dienste und Datenintegrität. Daher müssen alle privaten, Benutzer-bezogenen Daten auf dem Endgerät des Nutzers gespeichert werden. Der Benutzer muss eine Möglichkeit haben, sich über die Nutzung seiner Daten informieren und Speicherung und Nutzung seiner Daten modifizieren zu können. Die Funktionsweise des Systems soll dem Benutzer u. a. dadurch transparent sein.

Losgelöst vom Empfehlungssystem muss es dem Benutzer möglich sein, auf konkrete Suchanfragen nach Items an das System zu stellen. Eine Schlagwortsuche nach Domänen oder Eigenschaften von POI ist dabei wünschenswert.

Die Bedienbarkeit des Systems sollte möglichst barrierefrei sein, muss aber mindestens mittels Sprache gewährleistet sein. Die Bedienung mittels Gesten könnte zusätzlich eingebunden werden. Das System soll mit möglichst wenig aktiver Interaktion Empfehlungen generieren und größten Teils automatisch arbeiten. Um das Sichtfeld des Nutzers nicht durch unnötige Einblendungen einzuschränken, soll das System den Grad der Vertrautheit des Nutzers mit seiner Umgebung berücksichtigen. Zudem müssen alle Einbildungen durch einen Befehl sofort auszublenden sein.

Warnhinweise sollen mit einer passenden Handlungsempfehlung kombiniert werden und beschränken sich in diesem Modul von RadAR+ auf Aufforderungen, sich zur Weiterreise bereit zu machen.

Der Nutzer muss die zur Verfügung stehende, freie Aufenthaltszeit vom System abrufen können.

4 Gesamtkonzept des Assistenzsystems zur Aufenthaltsgestaltung

Aufgrund der Notwendigkeit von Echtzeit-Verkehrsinformationen ist eine Internet-Verbindung von grundlegender Bedeutung für die Funktionsfähigkeit des Systems und wird im Folgenden vorausgesetzt.

Die benötigten Hardware- und Software-Komponenten, die im Gestaltungsbereich dieses Moduls liegen, werden im folgenden *Kapitel 4.1* vorgestellt. Auf die Funktionsweise eingebundener, externer Dienste sowie extern entwickelter Module für das Gesamtsystem RadAR+ wird dabei nicht näher eingegangen.

4.1 Überblick über die Komponenten

Das System setzt sich aus drei Geräten zusammen: Einem zentralen Server, einem Smartphone und einer Datenbrille (Microsoft HoloLens Developer Edition). *Abbildung 7* gibt eine Übersicht des Zusammenwirkens der Komponenten, die im Folgenden im Detail vorgestellt werden:

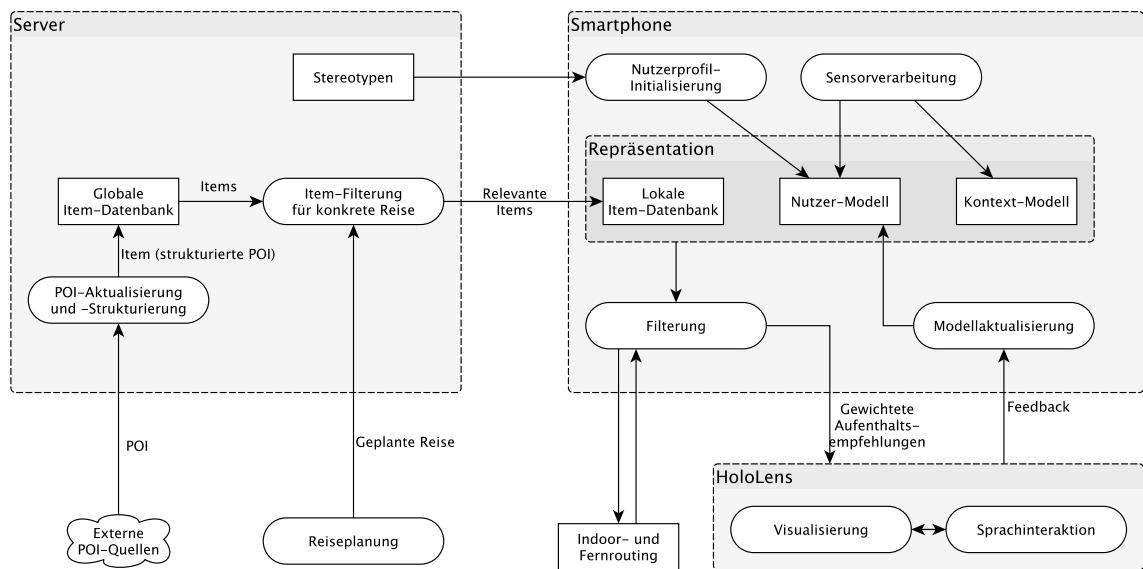


Abbildung 7: Schematische Übersicht über Hauptkomponenten des Systems und deren Zusammenwirken

Server

Die zur Generierung von Empfehlungen benötigten Daten (bspw. POI und aktuelle Verkehrsinformationen) werden vom Server bezogen und Strukturiert. Dazu werden externe Dienste mittels ihrer jeweils angebotenen Programmierschnittstelle (*Application Programming Interface*, kurz: API) eingebunden. Zu den genutzten externen Diensten gehören Open-Street-Maps, Google-Maps und OpenPOI. Darüber hinaus werden die von

den Verkehrsknoten-Betreibern übermittelten Daten über POI genutzt. Der auf diese Weise bereitgestellte Datenbestand wird entsprechend des Item-Modells (s. *Anhang 12.2*) aufbereitet und strukturiert. Die standardisierte Strukturierung wird vorgenommen, um Items vergleichbarer zu machen und somit Empfehlungen anhand entsprechender Attribute einfacher berechnen zu können. Beim Strukturierungsvorgang werden empfangene Daten zu einem POI nach Eigenschaften durchsucht, die auch im entsprechenden Modell hinterlegt sind. Diese Eigenschaften können auf verschiedenen Ebenen des Modells liegen und müssen ggf. unter Verwendung weiterer Parameter genauer spezifiziert werden. Dabei können POI auch mehreren Domänen auf verschiedenen Detail-Ebenen angehören. Folgendes Beispiel veranschaulicht den Strukturierungsvorgang:

Das Attribut Kaffee wird in den empfangenen POI-Daten gefunden. Die damit assoziierte Elterndomäne könnte demnach ein Café, ein Restaurant, eine Imbiss halle o. a. sein, in allen Fällen jedoch eine Gastronomie. Nach der Untersuchung weiterer Attribute und der berechneten Pearson-Korrelation mit den Modellen der Domänen konnten die Elterndomänen auf Café und Restaurant eingegrenzt werden.

In diesem Sinne strukturierte POI werden im Folgenden als Items bezeichnet. Die Gesamtheit dieser Items wird auf dem Server für die spätere Nutzung auf dem Smartphone bereitgestellt. Aktualisiert werden die Daten auf dem Server in regelmäßigen Zeitintervallen durch Abgleich mit den Daten der externen Dienste. Die von den Verkehrsknotenbetreibern übermittelten Angaben über POI werden bei Bedarf angepasst. Darüber hinaus werden auf dem Server Stereotypen vorgehalten, die zur initialen Repräsentation von Benutzern abrufbar sind.

Beginnt ein Benutzer seine Reise, wird seine geplante Route an den Server geschickt und dort temporär gespeichert. Anhand der gesendeten Route werden auf dem Server für die Reise relevante Items gefiltert. Items gelten dann als relevant, sofern sie in Relation zu Verkehrsknoten stehen, die mit der Route verbunden sind. Die nach dem Filtern als relevant geltenden Items werden an das Smartphone des Benutzers gesendet und dort lokal abgelegt. Das Speichern der Route ist notwendig, um Echtzeit-Informationen bzgl. jener (bspw. Fahrplanänderungen) an davon betroffene Benutzer zu senden. Diese Informationen werden vom Indoor- und Fernrooting (IFR) von RMS und der Fa. HaCon bereitgestellt. Nach Abschluss der Reise wird die Route vom Server gelöscht.

Smartphone

Unter Berücksichtigung des Settings generiert das System auf dem Smartphone wichtige Hinweise, Handlungsempfehlungen und Empfehlungen zur Aufenthaltsgestaltung für den einzelnen Benutzer. Handlungsempfehlungen sind direkt mit Verkehrsmitteln und deren Erreichung verbunden. Sie umfassen u. a. Aufforderungen zum Bereitmachen für die Weiterreise. Handlungsempfehlungen sind vom Benutzer anhand folgender Parameter konfigurierbar:

- Aktivieren und Deaktivieren der Hinweise
- Zeitpunkt der Aufforderung

Es ist eine feste Zeitspanne vor Abfahrt des folgenden Verkehrsmittels einstellbar (bspw. 5 min vor Abfahrt), bei der ein entsprechender Hinweis eingeblendet wird. Zusätzlich soll das System Kontext-sensitiv Hinweise zum Bereitmachen geben, bei der aktuelle Wegzeiten bis zum Ort der Weiterreise berücksichtigt werden. Beide Varianten können getrennt voneinander aktiviert und deaktiviert werden.

Um dem Benutzer den Aufenthalt an einem Verkehrsknoten so angenehm wie möglich zu machen, werden POI aus verschiedenen Domänen (bspw. Gastronomie, Shopping) abhängig von den Vorlieben des Nutzers, seinen demographischen Eigenschaften und des Settings empfohlen. Befindet sich der Benutzer in einer Stresssituation, wird das Generieren von Empfehlungen angepasst, um den Benutzer nicht zusätzlich zu beanspruchen. Zu diesem Zweck gibt es zwei verschiedene Empfehlungs-Modi zwischen denen das System automatisch wechselt. Die Empfehlungs-Modi unterscheiden sich wie folgt:

- *Empfehlungs-Modus I: Effizienz-Modus*

Dieser Modus wird aktiviert, sofern der Benutzer nur Zeit für einen Umstieg am Verkehrsknoten hat und das System keine Items, deren Besuch freie Zeit erfordern würde, empfehlen kann. In diesen Modus wird auch dann gewechselt, wenn der Benutzer darauf hingewiesen wird, dass er sich auf den Weg zum nächsten Verkehrsmittel machen muss. In diesem Modus werden lediglich Items auf direktem Wege zum nächsten geplanten Verkehrsmittel eingeblendet, deren maximale Verwendungszeit durch den Benutzer dessen zeitliches Kontingent bis zur Weiterfahrt nicht überschreitet. Darunter fallen bspw. Sanitäre Anlagen, Geldautomaten oder Kiosks. Diese Items werden im Item-

Modell als Produktivität-Items klassifiziert. Die maximale Verwendungszeit wird anhand von geschätzten Standard-Werten im System voreingestellt.

- *Empfehlungs-Modus II: Aufenthalts-Modus*

Das System hat erkannt, dass genug freie Zeit zum Wahrnehmen von Empfehlungen zur Verfügung steht. Es werden daher Empfehlungen zur Aufenthaltsgestaltung im Rahmen des aktuellen Zeitkontingents generiert.

Liste 4: Empfehlungs-Modi des Assistenzsystems zur Aufenthaltsgestaltung

Das Aktivieren eines der Modi wird an einem Schwellwert festgemacht. Dieser wird anhand der zur Verfügung stehenden Aufenthaltsdauer am Verkehrsknoten, benötigter Wegzeiten und der minimal geforderten Dauer zur Nutzung eines Items errechnet. Die minimale Nutzungsdauer an einem Item ist je Untergruppe einer Domäne mit Standardwerten voreingestellt und kann vom Benutzer explizit bearbeitet werden (bspw. Café ≥ 30 min oder Restaurant ≥ 50 min). Zusätzlich wird ein vom Benutzer optional eingegebener Puffer zwischen Umstiegen bei der Schwellwertberechnung einbezogen.

Um Annahmen über den Grad der Vertrautheit des Nutzers mit der Umgebung treffen zu können, wird für jeden Nutzer ein individuelles, temporäres Bewegungsprofil generiert. Das Erfassen der dazu notwendigen Geokoordinaten des Nutzers wird in festen Zeitintervallen vorgenommen. Das jeweilige Bewegungsprofil enthält alle vom Nutzer besuchten Verkehrsknoten und wird während der System-Nutzung kontinuierlich ergänzt. Anhand des Bewegungsprofils ist nachvollziehbar, in welchen Bereichen des Verkehrsknotens sich der Benutzer aufgehalten hat, wie lange er an einzelnen Orten verweilte und wie häufig er bestimmte Wege bereits gegangen ist.

Da die Auswertung des Bewegungsprofils in Echtzeit sehr rechenintensiv ist, wird dieses erst nach Reiseende optimiert. Dabei wird das Bewegungsprofil mit den Geopositionen der heruntergeladenen Items abgeglichen. Dabei wird untersucht, ob sich der Benutzer in der Nähe von Items aufgehalten hat und wie viel Zeit er an diesem Ort verbracht hat. Anhand dieser Daten werden Annahmen darüber getroffen, ob ein Benutzer entsprechende Items wahrgenommen hat oder nicht. Diese Ergebnisse fließen in die Berechnung der Stärke der Relation zwischen dem jeweiligen Item und dem Benutzer maßgeblich ein. Die Nutzung eines Items stärkt die Relation, während das Nicht-Nutzen die Relation schwächt. Zu Items, an denen sich der Benutzer gemäß seinem Bewegungsprofil nicht aufgehalten hat wird keine Relation hergestellt. Diese Items werden nach Abschluss der Route vom Smartphone

gelöscht, um Speicher zu sparen. Auch das Bewegungsprofil ist nach der Optimierung obsolet und kann nach Abschluss der Reise zurückgesetzt werden. Die mit der Optimierung verbundenen Auswirkungen auf das Generieren weiterer Empfehlungen werden erst zur nächsten Reise gültig, sofern der Benutzer keine Echtzeit-Aktualisierung explizit anfordert. Basierend auf dem jeweiligen Bewegungsprofil bzw. der Relation zu Items wird der Grad der Vertrautheit des Benutzers mit dem jeweiligen Verkehrsknoten anhand von vier Klassen beschrieben:

- **Klasse I:** Unbekannte Umgebung

Der Benutzer befindet sich zum ersten Mal am Verkehrsknoten. Die Vertrautheit mit der Umgebung wird somit als minimal eingestuft.

- **Klasse II:** Bereits besuchter Verkehrsknoten, jedoch wenig Kenntnis über die Umgebung

In dieser Klasse wird angenommen, dass sich der Benutzer in größeren Zeitabständen bereits häufiger an einem Verkehrsknoten aufgehalten hat. Seine Aufenthalte waren jedoch sehr kurz oder das Bewegungsprofil für den entsprechenden Ort besagt, dass die Umgebung von ihm noch kaum erkundet wurde.

- **Klasse III:** In größeren Zeitabständen bereits mehrfach besuchter Verkehrsknoten und Kenntnis über die Umgebung

In dieser Klasse wird angenommen, dass sich der Benutzer in größeren Zeitabständen bereits häufiger an einem Verkehrsknoten aufgehalten hat. Das entsprechende Bewegungsprofil lässt darauf schließen, dass die Umgebung bereits erkundet wurde. Wahrgenommen wurden jedoch noch kaum Items.

- **Klasse IV:** Häufig oder regelmäßig besuchter Verkehrsknoten und gute Kenntnis der Umgebung

Dieser Klasse werden diejenigen Orte zugeordnet, die der Benutzer in regelmäßigen Zeitabständen besucht. Darunter fallen auch Orte, die der Benutzer in größeren Zeitabständen besucht hat und anhand des Bewegungsprofils angenommen werden kann, dass er über gute Kenntnis seiner Umgebung verfügt.

Liste 5: Im System genutzte Klassen zur Darstellung des Grades der Vertrautheit eines Benutzers mit seiner Umgebung

Zusätzlich zum automatisierten Generieren von Empfehlungen wird das explizite Suchen nach Items anhand von Attributen ermöglicht. Neben einer Schlagwortsuche wird

zusätzlich eine Suchfunktion angeboten, die sich an Critiquing (Linden et al., 1977) orientiert. Dem Benutzer wird dabei die Möglichkeit geboten nach Empfehlungen innerhalb spezifischer Domänen zu suchen. Bei Aufruf dieser Suchfunktion wird dem Benutzer eine Übersicht aller Domänen auf oberster Ebene angezeigt. Er kann er sich aus dieser Auswahl von Domänen (bspw. Gastronomie, Unterhaltung, Hygiene, Shop o. a.) für eine entscheiden. Aufbauend auf dieser Entscheidung werden erste Items vorgeschlagen. Falls diese Items dem Bedürfnis des Benutzers nicht entsprechend, kann er die Suchergebnisse weiter spezifizieren, indem eine der ausgewählten Domäne zugehörige Unterdomänen ausgewählt werden kann. Dieser Vorgang kann auf weiteren Detailebenen wiederholt werden. Der Aufbau dieser Suchfunktion wird schematisch in Abbildung 8 dargestellt. Der vollständige Suchbaum entspricht dem Item-Modell (s. Anhang 12.2).

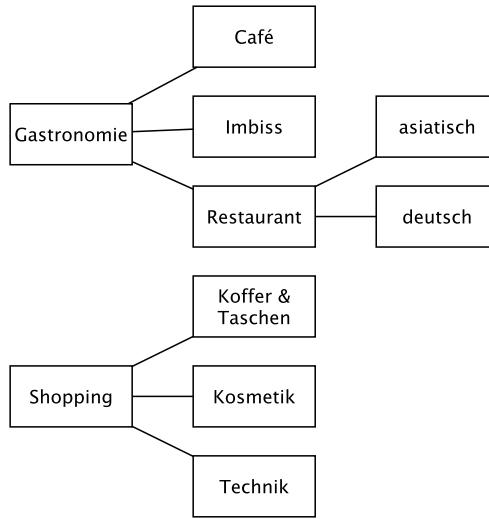


Abbildung 8: Schematischer Überblick über den Suchbaum bei der Suche mit Critiquing

Auf einer Rückfallebene bietet das System die Möglichkeit, Aufenthalte an einem Verkehrsknoten auf Wunsch des Benutzers zu verlängern. Die damit verbundene Neuplanung der Reise wird durch das Modul zur Routenplanung (Indoor- und Fernrouting, kurz: IFR) ermöglicht. Der Benutzer wird auf daraus resultierende Zielkonflikte aufmerksam gemacht und Empfehlungen werden angepasst.

Um den Anforderungen an Transparenz und Privatsphäre aus Kapitel 3 gerecht zu werden, gibt es ein Menü, in dem sich der Benutzer über die Nutzung und die Speicherung seiner persönlichen Daten informieren und entsprechende Einstellungen vornehmen kann. Dabei ist es möglich das Speichern einzelner und einer Gruppe von Daten zu erlauben bzw. zu verbieten. Eine Gruppierung wird anhand funktionaler Gesichtspunkte (bspw. Daten, die

dem Generieren von Empfehlungen dienen) oder nach Art ihrer Erfassung (bspw. Verfolgen des Nutzungsverhaltens) vorgenommen. Beim Konfigurieren dieser Einstellungen wird der Benutzer darüber informiert, welche Einschränkungen aus dem Deaktivieren des Speicherns von Daten für das Generieren von Hinweisen folgen. Bspw. wird u.a. der Zugriff auf verschiedene Sensoren des Smartphones benötigt (bspw. GPS-Sensor), um automatisch Daten über das Setting des Benutzers zu beziehen. Darüber hinaus wird dem Benutzer über einen weiteren Menüpunkt eine Übersicht über die Nutzung seiner Daten bereitgestellt, um die Transparenz des Systems weiter zu verbessern.

Datenbrille

Für den Benutzer sichtbar werden die Resultate zuvor beschriebener Prozesse auf der Datenbrille. Diese dient als Ausgabe- und Eingabegerät, mittels derer sowohl verbale als auch gestische Steuerbefehle erfasst werden. Diese Befehle nehmen entweder direkt Einfluss auf die aktuellen Einblendungen (bspw. ein- und ausblenden) oder werden an das Smartphone gesendet und dort entsprechend verarbeitet (bspw. Suchanfragen).

Da das System zum Einsatz auf Reisen konzipiert ist, wird besonders auf eine Bedienung geachtet, die wenig Interaktion erfordert und weitgehend freihändig möglich ist. Daher bietet die Datenbrille eine Schnittstelle zu einem Spracherkennungs-Modul (SM), das von der Fa. VoiceInterConnect bereitgestellt wird. Dieses Modul liefert auf Sprachbefehle eine JSON formatierte Zeichenkette zurück, die von der Brille als Befehl interpretiert und anschließen entweder sofort auf der Datenbrille verarbeitet oder an das Smartphone weitergeleitet wird.

Um dem Benutzer die Qualität und Zuverlässigkeit der zeitgebundenen Informationen zu suggerieren, wird ihm bei längeren Aufenthalten an einem Verkehrsknoten der Grund der freien Aufenthaltszeit mitgeteilt (bspw. geplanter Aufenthalt oder Verspätung bzw. Ausfall eines Verkehrsmittels mit Dauer der Verspätung). Grund-Annahme dafür ist, dass geplante Aufenthalte aufgrund von Umstiegen mindestens so lang dauern, wie sie geplant sind. Bei ungeplanten Aufenthalten sind die Angaben zur Verspätung meist weniger sicher.

Die Einblendungen der Assistenzfunktionen des Systems können jeder Zeit ausgeblendet und deaktiviert werden. Dies ist sowohl mittels Sprache als auch mittels Gesten möglich und dient v. a. der Sicherheit.

4.2 Aufbau und Funktionsweise des Empfehlungssystems zur Aufenthaltsgestaltung

Das Empfehlungssystem generiert kontinuierlich Vorschläge. Wird vom Benutzer ein Item ausgewählt, startet die Navigation aus dem IFR, um ihn zum entsprechenden Ort zu führen. Auf diesem Weg und während der Nutzung des Items werden die Anzeigen des Empfehlungssystems ausgeblendet. Erst sobald auf Basis von Positionsänderungen des Benutzers angenommen werden kann, dass er das Item nicht mehr nutzt, werden Empfehlungen entsprechend des aktiven Modus (s. *Liste 4*) wieder eingeblendet.

Im Folgenden werden der Aufbau und die Mechanismen des Empfehlungssystems beschrieben, das den Hauptteil der Assistenzfunktion zur Aufenthaltsgestaltung darstellt. Die dabei beschriebenen Prozesse beziehen v. a. das Smartphone und die Datenbrille ein.

4.2.1 Initiales Daten Set und Benutzer-Initialisierung

Gute Empfehlungen auf Basis der strukturierten Items zu generieren ist besonders zu Beginn der Inbetriebnahme des Systems eine erhebliche Herausforderung (s. Kalt-Start-Problem). Dieses Problem wird durch die Verwendung von im Vorfeld angelegten Stereotypen angegangen (s. [Anhang X](#)). Stereotypen wurden bereits häufiger erfolgreich zum Generieren initialer Empfehlungen eingesetzt, um schon in einem frühen Nutzungsstadium treffende Empfehlungen hervorzubringen (bspw. Ge et al., 2010). Die genutzten Stereotypen basieren auf einer Analyse des Item- und Nutzermodells. Dabei wurden diese Modelle nach Attributen untersucht, die besonders großen Einfluss auf die Auswahl von Items zu scheinen haben (bspw. Alter) und als wie sicher die darauf basierenden Prognosen des Benutzerverhaltens angenommen werden können.

Zur weiteren Verfeinerung der Stereotypen kann zu einem späteren Zeitpunkt eine groß angelegte Umfrage mittels Amazon Mechanical Turk (AMT) gestartet werden. Dabei müssen Teilnehmer einen Großteil der im Benutzer-Modell eingetragenen Attribute angeben und anschließend ein Training zum Feststellen der jeweiligen Präferenzen durchlaufen. Die so erhobenen Daten können anschließend zuerst nach Präferenzen geclustert werden. Die den jeweiligen Klassen angehörigen Benutzer werden anschließend nach gemeinsamen Attributen untersucht. Auf diese Weise können Benutzereigenschaften identifiziert werden, die die Art von Empfehlungen stark beeinflussen. Das Erstellen von Stereotypen kann darauf aufbauend erfolgen (vgl. Brandtzæg 2010). Nach Pruitt & Adlin (2010, S. 2) sind diese Verfahren zu gegenüber dem „händischen“ Entwickeln von Stereotypen zu bevorzugen, da sie valide und intersubjektiv nachvollziehbare Erkenntnisse

liefern. Zusätzliche Verfeinerungen dieser Stereotypen können darauf aufbauend mittels Affinity Diagramming vorgenommen werden (Pruitt & Adlin 2010, S. 40). Die Stärke der Relationen zwischen den jeweiligen Stereotypen und Items werden in Batches zum System-Start berechnet. Aktualisiert werden diese Werte nach der Aktualisierung von Item-Daten. Die initiale Zuordnung des Nutzers zu einem der auf dem Server gespeicherten Stereotypen erfolgt zu Beginn der Nutzung der Anwendung bei der Benutzerinitialisierung. Die dazu benötigten Daten werden als Pflichtangaben bei der Registrierung im System erhoben und umfassen hauptsächlich demographische Daten, wie Alter, Geschlecht und körperliche Einschränkungen. Darüber hinaus wird der Benutzer anhand eines Trainings-Sets in das System eintrainiert. Die Erstellung des Trainings-Sets orientiert sich an Critiquing (Pu & Chen, 2006, S. 3f; Linden et al., 1997) und dem Trainings-Mechanismus von Netflix. Es werden dafür verschiedene Domänen gegenübergestellt (z. B. Gastronomie vs. Shopping) und darauf aufbauend weitere Bewertungen innerhalb dieser vorgenommen (z. B. wurde Gastronomie gewählt, dann Café vs. Biergarten; Kategorien s. Anhang 12.2). Der Benutzer entscheidet sich für seine Präferenz und gelangt zur nächsten Iteration. Weitere Angaben, wie sie in [Anhang X](#) zu sehen sind, können anschließend in den Einstellungen vorgenommen werden. In Verbindung mit dem Nutzerverhalten und durch die Angabe persönlicher Daten in den Einstellungen, individualisieren sich sowohl die Benutzerprofile als auch die darauf aufbauenden Empfehlungen zunehmend.

4.2.2 Repräsentation von Benutzern, Items und Kontext

Für dieses kontextsensitive System werden Modelle für User, Items und Kontext genutzt (s. [Anhang 12.1, 12.2, 12.3](#)). Anhand von explizit angegebenen und automatisch erfassten Daten werden diese Modelle konkrete Benutzerprofile bzw. Items in einem Setting.

Das Benutzer-Modell wurde durch Recherche zu häufig genutzten Benutzer Charakteristika im Zusammenhang mit Reiseassistenz und durch darüberhinausgehende Überlegungen erzeugt. Zudem wurden Ergebnisse von im Vorfeld erfolgten Fokusgruppen-Treffen genutzt. Zur Erstellung des Item Modells wurden bisher genutzte Klassifikationen von POIs von Open Street Maps und dem Deutschen Hotel und Gaststättenverband (DEHOGA) genutzt. Anschließend wurden POIs an verschiedenen Verkehrsknoten gesucht und in das Item-Modell eingeordnet. Dabei identifizierte, zusätzliche Eigenschaften dieser POI wurden im Modell ergänzt. Für die Erstellung des Kontext-Models wurden zuerst Faktoren identifiziert, die Einfluss auf das Nutzen von Empfehlungen haben. Auch dazu wurden die Ergebnisse aus den Fokusgruppen genutzt. Anschließend wurden diese entsprechend ihrer

angenommenen Relevanz für das Generieren von Vorschlägen bewertet. Die nach dieser Bewertung als wichtig befundenen Attribute (bspw. Aufenthaltszeit, Entfernung zwischen Benutzer und Item) gingen in das Modell ein.

Der Benutzende kann Bedingungen für Empfehlungen in Form von Constraints in einem Menü festlegen (bspw. „niemals Treppen steigen“). Das System bewegt sich dadurch in seinen adaptiven und adaptierenden Fähigkeiten in dem vom Nutzer festgelegten Rahmen (vgl. *Kapitel 2.6*). Constraints werden vom System nicht verändert.

Um Aktualität der Item-Daten zu gewährleisten werden vor Reiseantritt alle relevanten Item-Daten vom Server geladen. Bei bereits vorhandenen Items wird anschließend der entsprechende Zeitstempel der letzten Aktualisierung verglichen. Kommt es zu einer Aktualisierung lokaler Item-Daten ist darauf zu achten, dass die daraus folgenden Veränderungen im Item keinen Einfluss auf das Benutzerprofil haben. Wurde bspw. bereits eine Relation zwischen einem zu aktualisierenden Item und dem Nutzer hergestellt, so würde eine Änderung des Item-Modells u. U. die Präferenzen des Nutzers verfälscht darstellen. Daher werden verschiedene Versionen desselben Items gespeichert, damit Informationen über das Nutzerverhalten nicht verloren gehen.

Der Schutz der Privatsphäre der Nutzer ist eine wichtige Anforderung an das System. Daher wird das auf dem Benutzer-Modell aufbauende Profil jedes Benutzers (wie im Projektantrag beschrieben) lediglich auf dem entsprechenden Endgerät gespeichert und wird nicht von außerhalb zugänglich sein. Daten über den Benutzer werden nur an externe Dienste weitergegeben, sofern deren Nutzung dies zwingend erforderlich. Zu diesen Daten gehören die Geo-Position des Benutzers und der davon ausgehende, erreichbare räumliche Radius und die Information, ob Wege barrierefrei sein müssen. Informationen, über die der Benutzer identifiziert werden kann (bspw. Name) werden nicht an Dritte gesendet.

4.2.3 Filterung

Der integrale Bestandteil dieser Anwendung besteht darin, die Stärke von Beziehungen zwischen Items untereinander und zum Benutzer zu identifizieren und darauf aufbauend Empfehlungen herauszufiltern. Da Benutzer-Modelle lediglich auf dem Endgerät zur Verfügung stehen, können beim Filtern die Modelle anderer Benutzer nicht einbezogen werden. Daher sind kollaborative Filter-Verfahren in diesem System nicht anwendbar. Bestimmung der Relevanz von Items für einen Benutzer bietet sich aus diesen Gründen Content-based Filtering an, wobei Item-Item-Beziehungen und Benutzer-Item

berücksichtigt werden. Zusätzlich werden festgelegte Constraints des Benutzers einbezogen. Aus Performance-Gründen wird der Filterprozess auf dem Smartphone in drei Schritte unterteilt: Constraint-based Filtering, Content-based Filtering und kontextbezogenes Post-Filtering. Diese drei Filterschritte sind seriell miteinander verknüpft (s. Abbildung 9) und werden im Folgenden beschrieben.

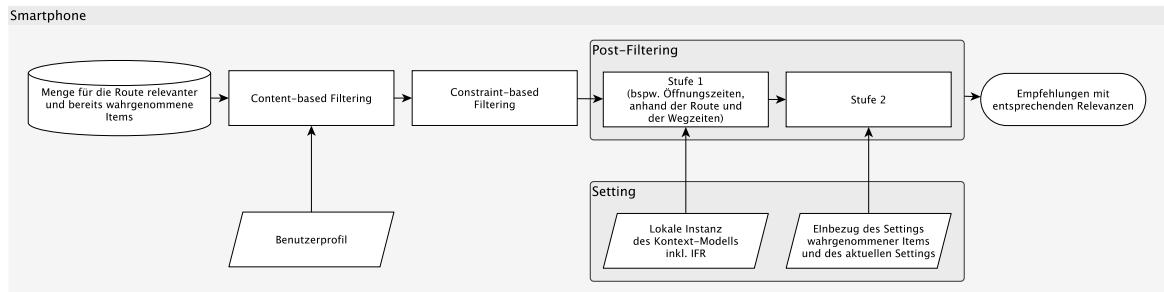


Abbildung 9: Schematischer Filterprozess auf dem Smartphone des Benutzers

Ist der Benutzer an einem Verkehrsknoten angekommen, wird der abgebildete Filterprozess einmal vollständig durchlaufen. Items, die nach dem Constraint-based Filtering für die Nutzung in Frage kommen, werden zwischengespeichert. Dadurch wird ermöglicht, dass bei jeder weiteren Filterung während des Aufenthaltes an diesem Verkehrsknoten das Filtern erst beim Post-Filtering ansetzen muss, sofern sich die Constraints des Benutzers nicht verändert haben.

Bereitstellung von Items auf dem Smartphone

Das Bereitstellen von Items zu entsprechenden Verkehrsknoten auf dem Endgerät ist in zwei Modi möglich: On-Demand und Available. Im On-Demand-Modus bezieht das Gerät vor Ort Items vom Server zum aktuellen Verkehrsknoten. Diese Items werden mit dem aktuellen Zeitstempel auf dem Smartphone abgelegt. Der Available-Modus ist dem On-Demand-Modus nachgelagert, denn damit das System im Available-Modus arbeiten kann, müssen Items bereits lokal bereitgestellt sein. Dazu ist es dem Benutzer möglich, bereits vor Reiseantritt Items von Verkehrsknoten auf dem Endgerät zu speichern oder zu aktualisieren, die auf seiner Route liegen. Die Aktualisierung aller auf dem Endgerät vorliegender Item-Daten wird vorgenommen, sofern dieses an Strom angeschlossen ist und über eine WiFi-Verbindung verfügt oder sobald der Benutzer explizit eine Aktualisierung anfordert. Eine explizit angeforderte Aktualisierung ist entweder für jene Items des aktuellen Verkehrsknotens, der aktuellen Route oder für alle gespeicherten Items wählbar.

Item-Item und Item-User Relationen und deren jeweilige Stärke werden bzgl. des Content-based Filtering bereits vor Reiseantritt berechnet. Durch die batch-orientierte Verarbeitung werden Response-Zeit und Performance des Systems verbessert und der durch große Berechnungen verursachte Energie-Verbrauch bleibt vertretbar.

Content-based Filtering

Die Stärke der Relation zwischen Items und Benutzer und zwischen Items untereinander wird unter Verwendung eines erweiterten Vector-Space-Models (eVSM) berechnet. Dabei wird sich an dem von Musto et al. (2013) beschriebenen Ansatz orientiert. Bei der Verwendung von VSM werden sowohl Items als auch Nutzers als Vektor ihrer Eigenschaften verstanden, die wiederum selbst Vektoren sind. Ein Item mit n Attributen wird somit in einem n -Dimensionalen Raum dargestellt. Ausgehend davon werden paarweise die Winkel zwischen Items bestimmt, die als Indikator der Ähnlichkeit dienen. Je geringer der Abstand zwischen zwei Punkten im Raum bzw. je geringer kleiner der Winkel zwischen den beiden Vektoren ist, als desto ähnlicher werden zwei Items interpretiert. Der Zusammenhang zwischen Benutzern und Items wird ähnliche Weise bestimmt.

Bei der Bestimmung des Winkels werden zuerst gemeinsame Attribute zwischen den jeweiligen Items identifiziert. Anschließend werden die dabei gebildeten Vektoren normalisiert und der Cosinus zwischen ihnen berechnet. Das nachfolgende Beispiel veranschaulicht den Vorgang zur Berechnung vereinfacht. Es werden dabei Empfehlungen für einen Benutzer berechnet, dessen Profil sich hier lediglich aus Bewertungen zusammensetzt. Alle Attribute sind gleichgewichtet.

Item	Kaffee	Tee	Kuchen	Torte	Schnitzel	Forelle	Bio	Anz. Attribute
Item 1	1	0	1	1	0	1	0	4
Item 2	1	1	1	1	0	1	1	6
Item 3	0	1	0	1	1	1	1	5
Item 4	1	1	1	0	0	1	0	4
Item 5	1	0	1	0	0	0	1	3

Tabelle 1: Gegenüberstellung der Item Eigenschaften

Im folgenden Schritt werden die Vektoren der Items normalisiert. Aufgrund der Struktur des Item-Modells, kann die Normalisierung auf Basis binärer Daten durchgeführt werden:

$$\text{Normalisierter Wert} = \frac{1}{\sqrt{\text{Anzahl Attribute}}}$$

Formel 1: Normalisierung des binären Items als Vektor

Aufbauend auf den normalisierten Vektoren kann die Ähnlichkeit zwischen Items durch deren Summenprodukt bestimmt werden. Die Ähnlichkeit zweier Items wird durch die Bestimmung des Cosinus zwischen ihren Vektoren anhand folgender Formel bestimmt:

$$\cos \theta = \frac{v * w}{\|v\| \|w\|} = v * w, \quad \text{für normalisierte } v \text{ und } w$$

Formel 2: Bestimmung des Cosinus zwischen zwei Item-Vektoren

Daraus ergibt sich die folgende Ähnlichkeit der Attribute in diesem Beispiel:

	Item 1	Item 2	Item 3	Item 4	Item 5
Item 1	1	0,82	0,45	0,75	0,58
Item 2		1	0,73	0,82	0,71
Item 3			1	0,45	0,26
Item 4				1	0,58
Item 5					1

Tabelle 2: Cosinus-Ähnlichkeit der Items

Im nächsten Schritt wird das Benutzerprofil einbezogen. Das darauf basierende berechnete Präferenzen Profil des Benutzers besteht aus dem entsprechenden Produkt der normalisierten Vektoren und seinen Bewertungen. Die in **Fehler! Verweisquelle konnte nicht gefunden werden.** abgebildeten Bewertungen des Benutzers für ein Item sind wie folgt zu verstehen: 1 *like*, -1 *dislike*, 0 *nicht bewertet*. Negative Bewertungen einzubeziehen steigert nach Musto (2010) die Genauigkeit von Empfehlungen. Anschließend werden diejenigen Items gezählt, die das gesuchte Attribut beinhalten (*Document Frequency*, kurz: DF) und das Inverse davon (IDF; s. *Formel 3*) gebildet, um Ungleichverteilungen im zahlenmäßigen Vorkommen von Attributen auszugleichen.

$$IDF_t = \log_{10} \left(\frac{|D|}{1 + |\{d \in D : t \in d\}|} \right)$$

Formel 3: Berechnung des IDF; D entspricht der Menge aller Items, t dem gesuchten Attribut

Die daraus sich daraus entstehende Gewichtung w ergibt sich nach *Formel 4*:

$$w(t, d) = tf_{t,d} * IDF_t$$

Formel 4: Berechnung der Gewichtung w aus der Häufigkeit des Vorkommens des Attributs t im Item d (Term Frequency, $tf_{t,d}$) und dem IDF

Im Anschluss werden die Stärken der Relationen (Scores) zwischen jeweiligen Items und dem Benutzer berechnet, die sich aus dem Summenprodukt des normalisierten Item-Vektors, dem normalisierten Vektor der Benutzerpräferenzen und der entsprechenden Gewichtung w ergeben (*Formel 5*).

$$score(u, d) = \sum_t (w(t, d) * u_t * d_t)$$

Formel 5: Berechnung des Relevanz-Scores eines Items bezogen auf einen Benutzer

Da dazu das Nutzerprofil benötigt wird, kann die Berechnung ab diesem Punkt nicht mehr vom Server vorbereitet werden. Dieser Schritt wird alleine auf dem Smartphone ausgeführt. Das in **Fehler! Verweisquelle konnte nicht gefunden werden.** beschriebene, beispielhafte Benutzerprofil entspricht in dem zu entwickelnden Gesamtsystem den Präferenzen eines Benutzers.

Um nicht immer dieselben Items zu empfehlen und die sog. Filter Bubble nicht zu eng zu fassen, wird zudem Cycling eingesetzt (s. *Kapitel 2.3.4*). Dazu werden systematisch Items, die in der Top-n-Liste nicht ganz oben positioniert sind, als Empfehlungen eingestreut. Dabei werden v. a. Items berücksichtigt, die mit einem Score $s \in [0,3; 1]$ bewertet sind.

Zur Nutzung von Collaborative Filterung (s. *Kapitel 2.3.1*) müssten die Nutzermodelle auch außerhalb des Endgerätes verfügbar gemacht werden. Eine Lösung dafür wäre, diese auf einem Server zentral, aber dennoch anonymisiert zu speichern. Dafür sollen Kontaktdaten (Name, Adresse etc.) weiter alleine auf dem Client-Endgerät gespeichert werden. Der Client sendet bei Anfragen an den Server ein Token mit, dass seine persönliche, einzigartige ID beinhaltet. Mittels dieser ID kann die Anfrage dem Modell des Benutzers zugeordnet und entsprechend verarbeitet werden. Anfragen an zuvor beschriebene externe Dienste könnten ebenfalls von diesem Server aus getätigt werden. Empfehlungen könnten dann On-Demand auf dem Server generiert und anschließend an den Client zurückgegeben werden.

Constraint-based Filtering

Zur weiteren Auswahl von Items, die den festgelegten Bedingungen des Benutzers entsprechen, wird Constraint-based Filtering eingesetzt. Ziel ist es, die Anzahl der im Anschluss zu filternden Items zu reduzieren und den Rechenaufwand somit zu reduzieren. Daher werden Items, die den Constraints nicht entsprechen aus der Menge relevanter Items entfernt, jedoch nicht vom Endgerät gelöscht. Auf diese Weise muss keine neue Anfrage an den Server gesendet werden, wenn der Benutzer Constraints während seiner Reise ändert. Kommt es zu einer solchen Änderung, müssen alle Items der Menge wieder hinzugefügt und der in *Abbildung 9* gezeigte Filterprozess erneut vollständig durchlaufen werden.

Post-Filtering

Kontext-Sensitivität ist in diesem System ein wichtiger Bestandteil zur Selektion von für den Benutzer nutzbaren Items. Beim kontextsensitiven Filtern auf dem Smartphone werden v. a. die im Kontext-Modell verankerten Parameter berücksichtigt. Anders als Items und das entsprechende Benutzerprofil, wird die jeweilige Instanz des Kontext-Modells (Settings) in diesem Zusammenhang nicht gespeichert, sondern stellt lediglich Parameter bereit, die dem Filtern dienen. Das Kontext-Modell wird u. a. vom Modul zur Sensordaten-Verarbeitung in Echtzeit gefüllt. Zusätzlich greift es auf externe Dienste zurück, wie z. B. Wetterdienste und das Indoor- und Fernrouting-Modul (IFR).

Das kontextbezogene Filtern ist in zwei sequentiell verbundene Schritte unterteilt. Im ersten Schritt wird die Nutzbarkeit eines Items geprüft. Im ersten Filter-Schritt werden Öffnungszeiten von Items mit der aktuellen Uhrzeit abgeglichen. Dabei wird die vom Benutzer als minimal angegebene Verweildauer an einem Item, der vom Benutzer eingestellte Puffer und die benötigten Zeiten für den Hinweg und den Weg zum nächsten Gleis berücksichtigt. Um Wegzeiten zu berechnen und die Zugänglichkeit des Items zu überprüfen, wird der aktuelle Standort des Benutzers, die Geokoordinate des jeweiligen Items und Anforderungen an die entsprechende Strecke (bspw. Barrierefreiheit) an das IFR gesendet. Die davon berechneten Wegzeiten orientieren sich am Bewegungsprofil bzw. dessen optimierten Darstellung und den darin abgebildeten Gehgeschwindigkeiten. Ist ein Item nach dieser Berechnung nicht nutzbar, wird es aus der Menge der für diesen Filter-Durchlauf relevanten Items entfernt. Wird das System durch das IFR über Veränderungen im Fahrtablauf benachrichtigt, wird der Filter-Prozess von Neuem an diesem Punkt begonnen.

Ist ein Item nutzbar, wird im nächsten Schritt geprüft, ob dieses oder ähnliche Items bereits in einem bestimmten Setting genutzt wurden. Diese Daten werden u. a. aus dem Bewegungsprofil des Nutzers sowie den in *Kapitel 4.2.5* beschriebenen Feedback-Mechanismen erhoben. Unter Berücksichtigung der Nutzungsdauer werden Annahmen darüber getroffen, mit welcher kontextbasierten Gewichtung dieses oder ähnliche Items nochmals in die Empfehlungen eingehen. Dabei steigert die Anzahl von anzunehmenden Besuchen auch die Relevanz eines Items. Dabei wird die Domänenangehörigkeit beachtet, da bspw. lange oder häufige Aufenthalte an Reiseinformationsschaltern in diesem Zusammenhang nicht beachtet werden sollen.

Auf der Online Ebene wird darüber hinaus beachtet, welche Items auf der aktuellen Reise bereits genutzt worden sind und ob eine Domäne ggf. temporär aus der Menge zu Filternder Items herausgenommen wird. Hat bspw. ein Benutzer längere Zeit ein Café besucht, erscheint es sinnvoll, nicht im nächsten Filterdurchlauf wieder ein Café zu empfehlen. Die entsprechende kontext-basierte Gewichtung wird auf die Relationsstärke zwischen Benutzer und Items bezogen und nicht auf einzelne Attribute des Items (vgl. *Abbildung 4*).

4.2.4 Präsentation von Empfehlungen

Für die im vorherigen Kapitel beschriebenen zwei Empfehlungs-Modi (*Liste 4*) werden unterschiedliche Darstellungen eingesetzt. Im Effizienz-Modus werden Informationen auf ein Minimum reduziert, da davon ausgegangen wird, dass sich der Benutzer in einer Stress-Situation befindet. Daher werden ausschließlich Items, die als Produktivität-Item gekennzeichnet sind eingeblendet. Produktivität-Items bilden eine Gruppe von Items, die unter Zeitdruck noch wahrgenommen werden können und hilfreich sind. Dazu gehören bspw. Geldautomaten und Sanitäre Einrichtungen. Auch Produktivität-Items werden an den Benutzer angepasst. So würden bspw. Geldautomaten, bei denen der User gebührenfrei Geld abheben kann gegenüber anderen hervorgehoben werden oder für das jeweilige Geschlecht die entsprechende sanitäre Einrichtung. Produktivität-Items werden in diesem Modus lediglich durch POI-Symbole an entsprechenden Orten markiert, wobei zum besseren Verständnis jedem dieser Symbole ein entsprechendes Icon hinzugefügt wird. Ist ein Benutzer mit seiner Umgebung bereits vertraut, reduziert sich die Menge markierter Items entsprechend der Vertrautheits-Klasse (*Liste 5*). *Abbildung 10* zeigt schematisch den Aufbau der Präsentation im Effizienz-Modus:



Abbildung 10: Schematische Darstellung des Effizienz-Modus

Im Gegensatz zu dem zuvor beschriebenen Effizienz-Modus gestaltet sich die Darstellung im Aufenthalts-Modus deutlich detaillierter und bietet dem Nutzer u. a. Funktionen zur Suche und Auswahl von Items. Zudem wird die Möglichkeit eine Detailansicht zu Items aufzurufen bereitgestellt. Dem Benutzer wird bei einem Wechsel zwischen den Modi mittels eines Piktogramms signalisiert, welcher Modus aktiv ist.

Wie in *Kapitel 2.4.2* beschrieben, bringt der Einsatz von Datenbrillen einige neue Herausforderungen und neue Potentiale mit sich. Bei Optical See-Through (OST) Brillen, wie die HoloLens, ist die Textdarstellung und Lesbarkeit von Text stark von der jeweiligen Hintergrundfarbe bzw. von Helligkeit und Kontrast abhängig (Azuma et al. 1999, S. 252; Gleue & Dähne 2001, S. 161). Zudem ist der Einfluss des Kontrastes zwischen der Textfarbe einer Einblendung und deren Hintergrund auf die Lesbarkeit hoch (Jankowski et al. 2010, S. 1321; van Krevelen & Poelman 2010, S. 4). Bei OST-Geräten können, abhängig vom Gerät, schwarze Objekte und Schrift nicht angezeigt werden bzw. erscheinen (semi-) transparent, was als Schwäche der Technik erwähnt wird (Debernardis et al. 2014, S. 127).

Die Darstellung einer umfangreichen Top-N-Item Liste erscheint aufgrund des Platzbedarfs der Liste in diesem Anwendungsfall nicht praktikabel. Die Liste wird daher auf die als am wahrscheinlich passendsten drei Items reduziert. In getrennten visuellen Containern eingefasst, werden der Name des Items und seine kategoriale Zuordnung unter Berücksichtigung der Benutzerpräferenzen (bspw. Café aus Gastronomie) angezeigt. Darüber hinaus wird dem Benutzer die berechnete Strecke für den Hinweg eingeblendet (*Abbildung 11*).

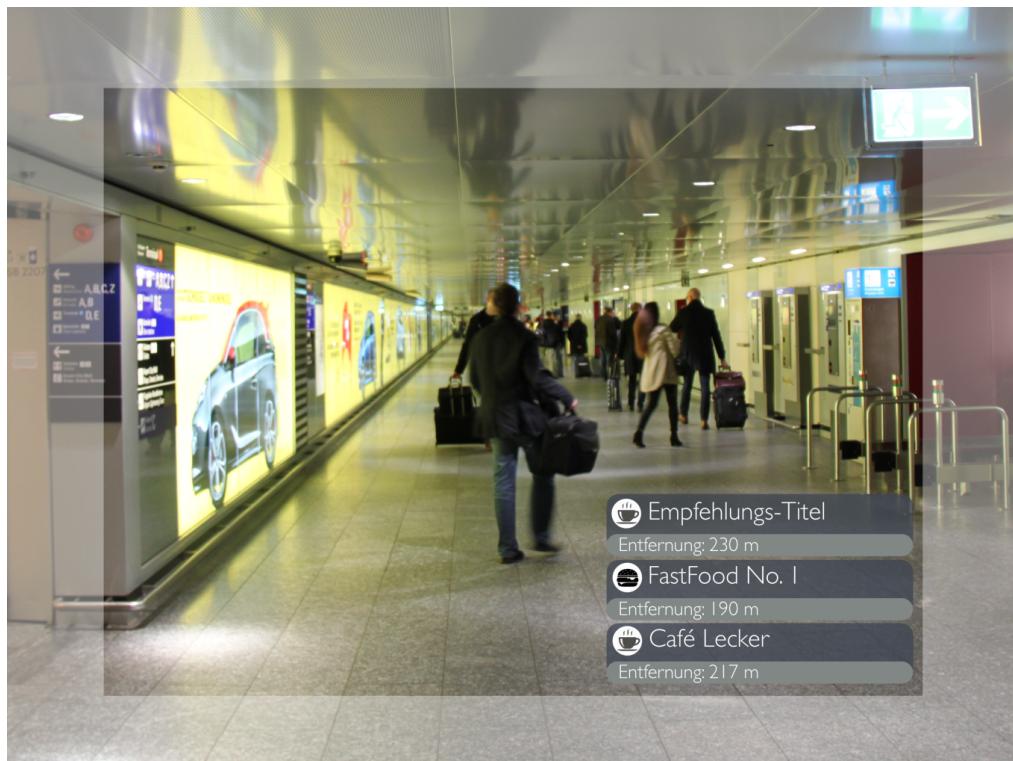


Abbildung 11: Schematische Darstellung der Top-N-Item Liste

Die Container werden im rechten unteren Eck des Displays der Datenbrille im Billboard-Style eingeblendet. Der Billboard-Style gilt als besonders gut lesbar, v. a. bei der Verwendung von weißen Hintergrund und blauer Schrift ohne Serifen (Debernardis et al. 2014, S. 134-136). Diese Farbkombination ist an Verkehrsknoten allerdings bei Anzeigen und Beschilderungen sehr verbreitet, weswegen hier anthraziter Hintergrund mit weißer Schrift eingesetzte wird.

Der Benutzer kann mittels Sprachbefehlen Items aus der Empfehlungsliste selektieren („nächstes“, „vorheriges“, „Item eins“, „Item zwei“, ...) und Details zu einem selektierten Item anfordern. Eine Schnellauswahl ist zusätzlich über die Nennung des eingeblendeten Namens des empfohlenen Items möglich.

In der Detailansicht (Abbildung 12) wird dem Benutzer zusätzlich ein Bild des Items nebst einer kurzen Beschreibung, die auf die Interessen des Benutzers zugeschnitten ist, angezeigt. Das Tailoring der Beschreibung bezieht Parameter zum Kenntnisstand des Benutzers und seiner Intention sowie das Setting ein. Bspw. wird einem Benutzer, der sehr gerne Kaffee trinkt mitgeteilt, dass das entsprechende Item über eine große Auswahl verschiedener Kaffeesorten verfügt. Die Beschreibung umfasst sowohl das Angebot des Items als auch eine kurze Beschreibung, eine binäre, akkumulierte Bewertung und eine Begründung, warum das Item empfohlen wurde. Das Angebot wird so (soweit möglich) in Form von Icons dargestellt, da das Lesen eingeblender Texte in AR meist schwierig ist. Nach Horton (1994) soll durch den Einsatz von Icons die Wahrnehmung von entsprechenden Eigenschaften verbessert werden. Darüber hinaus spart der Einsatz von Icons anstelle von textlichen Beschreibungen häufig Platz. Die Bewertung des Items durch andere Benutzer wird mittels Icons visualisiert, die um die entsprechende Anzahl *likes* bzw. *dislikes* ergänzt wird.

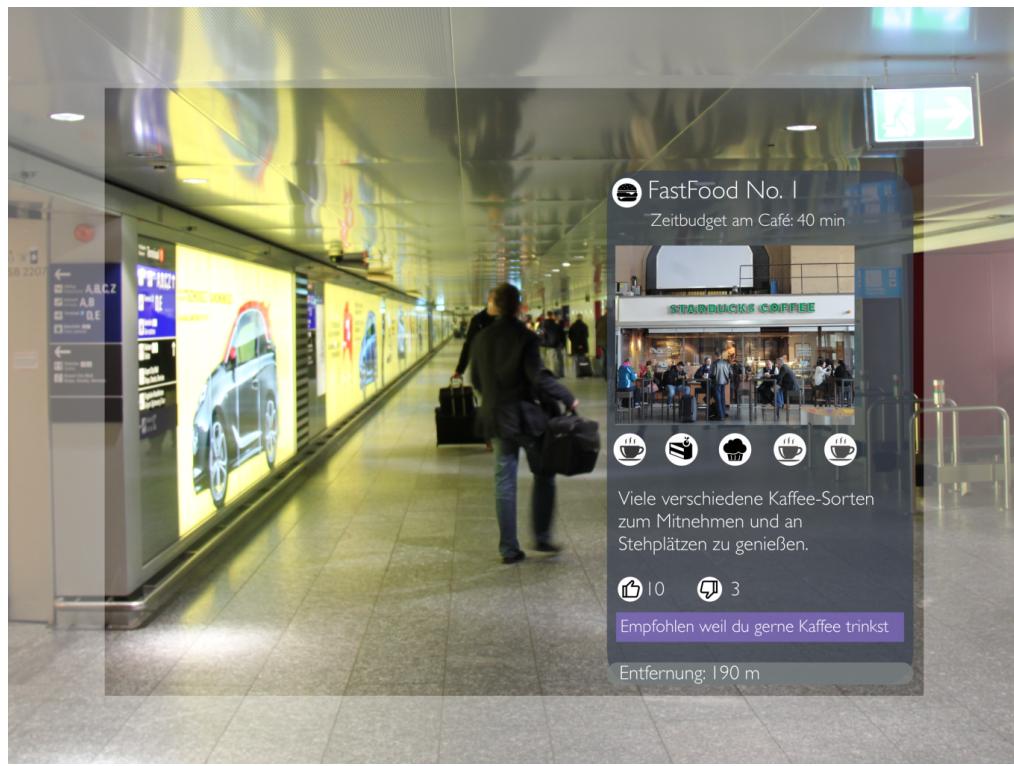


Abbildung 12: Schematische Darstellung der maximalen Detail-Ansicht eines Items der Domäne Gastronomie während der Benutzer steht

Da die Detailansicht (*Abbildung 12*) das Sichtfeld stark einschränkt, wird dieser Sicherheitsgründen minimiert, sobald sich der Benutzer fortbewegt. Die reduzierte Detailansicht bei Fortbewegung ist in *Abbildung 13* dargestellt:

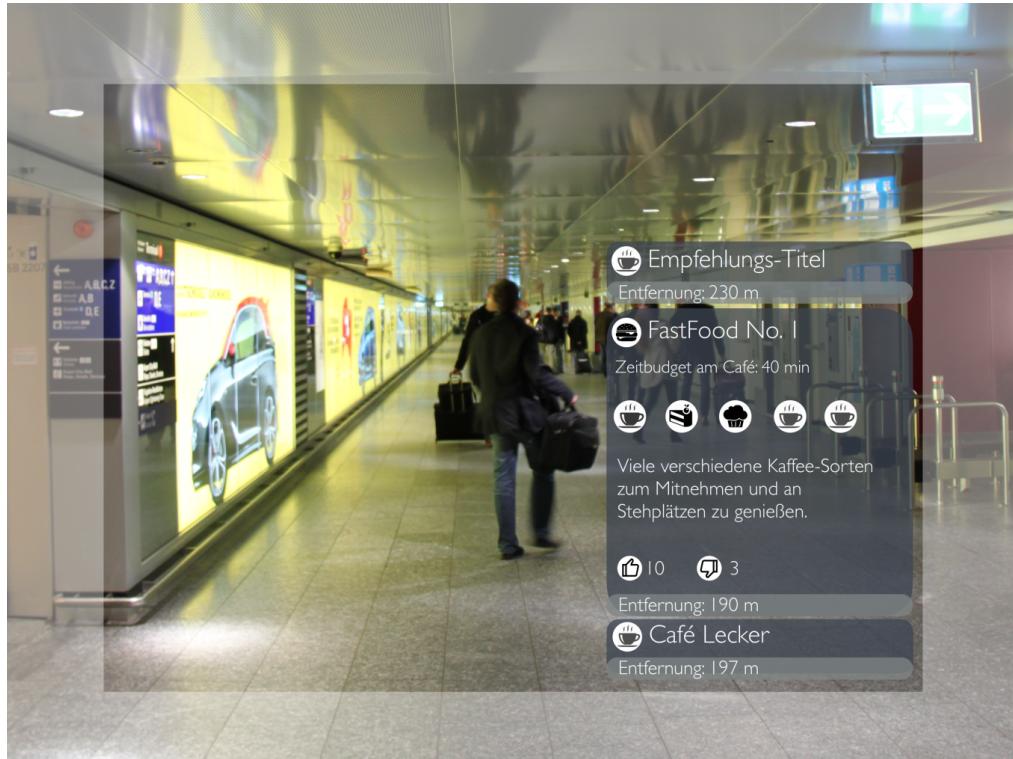


Abbildung 13: Detailansicht während der Fortbewegung des Benutzers

Hat ein Constraint des Benutzers starken Einfluss auf die Auswahl der Empfehlungen bzw. die Wegzeiten zu POI, wird der Benutzer darüber mittels des für den entsprechenden Constraint repräsentative Icon informiert. Hat ein Benutzer bspw. die Domäne Gastronomie aus Empfehlungen per se ausgeschlossen, soll er daran erinnert werden, dass die Auswahl von Items dadurch explizit eingeschränkt worden ist. Darüber hinaus soll eine getailorte Begründungen für die Empfehlung eingeblendet werden, um das Verständnis des Benutzers über die Funktionsweise des Systems zu verbessern. Diese Begründung kann der Benutzer in seinen persönlichen Einstellungen de-/aktivieren.

Wurden Verkehrsknoten, die auf der Route des Nutzers liegen, bereits besucht, wird dies bei der Darstellung der Empfehlungen unter Verwendung der beschriebenen Vertrautheits-Klassen berücksichtigt. Entsprechend werden in der zuvor beschriebenen Ansicht im maximalen Detail-Grad Informationen teilweise ausgeblendet. Die Anpassung des Empfehlungssystems im Aufenthalts-Modus an den Grad der Vertrautheit verhält sich wie folgt:

- *Klasse I:* Unbekannte Umgebung

Die Detail-Darstellung zu Empfehlungen ist besonders ausführlich und entspricht dem maximalen Detail-Grad. Sie umfasst alle zuvor beschriebenen Angaben zu einem Item.

- *Klasse II:* Bereits besuchter Verkehrsknoten, jedoch wenig Kenntnis über die Umgebung

Die Detaildarstellung entspricht der aus Klasse I

- *Klasse III:* In größeren Zeitabständen bereits mehrfach besuchter Verkehrsknoten und Kenntnis über die Umgebung

Die Detaildarstellung (minimaler Detail-Grad) umfasst in dieser Klasse ein Bild des Items und die benötigten, aktuellen Wegzeiten. Es wird zusätzlich die Möglichkeit angeboten, mittels Sprache den maximalen Detail-Grad anzufordern. Ein entsprechendes Symbol, welches das Bereitstehen dieser Funktion suggeriert, wird in der Detailansicht des Items eingeblendet.

- *Klasse IV:* Häufig oder regelmäßig besuchter Verkehrsknoten und gute Kenntnis der Umgebung

Zu Gunsten eines freien Blickfeldes werden dem Benutzer vorerst keine Empfehlungen vorgeschlagen. Gibt es jedoch neue oder Veränderungen an bestehenden Items am entsprechenden Verkehrsknoten, wird der Benutzer darauf hingewiesen. Er hat die Möglichkeit sowohl Informationen zu neuen Items im maximalen Detail-Grad als auch Informationen über die Veränderungen des Items aufzurufen.

Liste 6: Umfang dargestellter Informationen in der Detailansicht von Items aufbauend auf Vertrautheits-Klassen (s. Liste 5)

In der Detailansicht werden zudem Navigations-Funktionen bereitgestellt, die es ermöglichen anhand von Sprachbefehlen (bspw. „nächstes“ bzw. „vorheriges“) durch Empfehlungen zu springen. Die Auswahl und Reihenfolge der auf diese Weise präsentierten Items entspricht derer der Liste der Empfehlungen. Darüber hinaus kann die Navigation zu einem Item aus der Detailansicht durch einen Sprachbefehl gestartet werden.

4.2.5 Feedback

Da in diesem System keine klassischen Steuerungsmethoden anhand einer Maus oder Berührung eingesetzt werden, sind einige weit verbreitete, Feedback-Mechanismen nicht

einsetzbar (bspw. die Verweildauer eines Cursors auf Items). Dennoch werden sowohl explizite als auch implizite Feedback-Mechanismen implementiert. Explizites Feedback kann der Benutzer anhand von binären Bewertungen (*like/dislike*) geben. Die entsprechende Bewertung wird lokal auf dem Endgerät des Benutzers mit dem aktuellen Zeitstempel gespeichert und anonymisiert an den Server weitergeleitet, damit andere Benutzer aufsummierte Bewertungen sehen können. Jeder Benutzer kann jedes Item nur einmal bewerten. Mit *dislike* bewertete Items werden weiterhin bei der Generierung von Vorschlägen einbezogen, werden allerdings in ihrer Relevanz für den Benutzer heruntergesetzt. Ein Benutzer kann seine Bewertung zu einem beliebigen Zeitpunkt wieder ändern. Sollen Items nicht mehr empfohlen werden, kann der Nutzer diese in der Detailansicht zu jener Menge von Items hinzufügen.

Darüber hinaus werden explizite Such-Anfragen an das System getrackt. Diese sind Teil der Nutzungshistorie und gehen somit in das Benutzerprofil ein. Einen weiteren Teil der Nutzungshistorie stellt das Aufrufen der im vorherigen Kapitel beschriebenen Detailansicht von Empfehlungen dar. Es wird angenommen, dass Items, deren Detailprofil aufgerufen wurde für den Benutzer im jeweiligen Setting von besonderem Interesse war. Ebenso wird das Starten der Navigation zu einem Item mit dem damit verbundenen Setting in die Benutzerhistorie aufgenommen.

Ebenso wird das in *Kapitel 4.1* beschriebene Bewegungsprofil herangezogen, um Feedback auf die tatsächliche Nutzung von Items zu erhalten. Damit verbunden wird die tatsächliche Nutzungsdauer von einzelnen Items gemessen.

Die gesammelten Feedback-Daten werden auf dem Endgerät des Nutzers gespeichert und beeinflussen zukünftige Empfehlungen als Teil des Benutzerprofils. Zusätzlich zum eigentlichen Feedback werden Sensor-Daten des Smartphones gespeichert, die das Setting rekonstruierbar machen sollen, in dem eine Feedback gegeben wurde. Der Zeitstempel, der zu jedem Feedback gespeichert wird, ist essentiell, um den Kontext und die Relevanz des Feedbacks für das Generieren späterer Empfehlungen zu beurteilen.

Eine Übersicht der eingesetzten Feedback-Mechanismen ist in *Anhang 12.3* zu finden.

4.2.6 Adaptivität und Lernen

Das System arbeitet sowohl adaptierend durch Berücksichtigung konkreter Einstellungen des Benutzers als auch adaptiv durch Berücksichtigung des Nutzerverhaltens. Der adaptierende Teil des Empfehlungssystems bezieht sich v. a. auf die vom Benutzer festgelegten Constraints zum Generieren von Vorschlägen. Der adaptive Teil bezieht sich

auf das Tracken des Benutzerverhaltens während der Nutzung des Systems wird das auf verschiedenen Ebenen (s. Kapitel 4.2.5). Dadurch erhält das Benutzerprofil immer aktuelle Daten über den Benutzer und kann diese adaptieren. Wichtiger Bestandteil des Trackings sind u. a. die Reaktionen auf Empfehlungen, die durch zuvor beschriebene implizite und explizite Feedback-Mechanismen erfasst werden. Da das Aktualisieren der Stärke der Relationen zwischen User und Items bzw. Items und Items zunehmend rechenintensiv wird, wird in Offline- und Online-Aktualisierung unterteilt. Online bzw. in Echtzeit werden Empfehlungen anhand kurzfristiger Verhaltensweisen des Benutzers angepasst. Ein Beispiel veranschaulicht den Unterschied:

Benutzer A geht auf seinen Reisen sehr regelmäßig in Cafés, verbringt dort eine längere Zeit.

Das System empfiehlt A demnach ein Café in der Nähe seiner aktuellen Position. Aus dem darauffolgenden, längeren Aufenthalt am Item, schließt das System, dass A gerade Kaffee trinken war. Beim Generieren der nächsten Empfehlungen werden Cafés in ihrer Relevant heruntergesetzt, weil A bereits einen Kaffee trinken war. Hält sich A jedoch nur sehr kurz am empfohlenen, bisher noch nicht genutzten Item auf, wird daraus geschlossen, dass A das Café womöglich nicht möchte. Das Item wird daraufhin nicht mehr in den Empfehlungen berücksichtigt. Andere Cafés könnten noch relevant sein und werden nicht beeinflusst.

Bei der Offline-Aktualisierung wird das gesamte Benutzerprofil und alle gespeicherten Items mit dem ggf. entsprechenden Nutzungs-Setting einbezogen. Um trotz dem ständigen Hinzufügen von Daten zum Benutzer-Modell die Aktualität des Modells zu bewahren, Overfitting zu vermeiden und es kompakt zu halten, wird das Modell nicht alle Daten gleichberechtigt in das Generieren von Empfehlungen einbeziehen. Vorrangig werden aktuelle Daten berücksichtigt. Die Nutzungshistorie im Ganzen wird dazu eingesetzt, häufige Handlungsmuster des Benutzers zu identifizieren.

Da angenommen werden kann, dass die zahlenmäßige Präsenz von Items verschiedener Domänen an Verkehrsknoten ein starkes Ungleichgewicht hat (bspw. Geldautomaten verglichen mit Cafés), ist anzunehmen, dass die Relation zwischen Benutzer und eben dieser Art von Items besonders stark ausgeprägt sein wird. Dieses Problem wird vom System durch die Anpassung von Gewichtungen im Filter-Prozess an die örtlichen Gegebenheiten angegangen. Die nicht homogene Verteilung der Items provoziert zudem das Entstehen einer Filter-Bubble. Durch gezielten Einsatz von Cycling an Verkehrsknoten, die besonders von diesem Problem betroffen sind, soll diesem Problem entgegengewirkt werden. Bspw. sollen sich auf diese Weise bei dem ersten Besuch des Nutzers an einem

Flughafen Duty-Frees ebenso unter den Empfehlungen befinden, wie auch die für gewöhnlich an einem Bahnhof zu findenden Items.

5 Evaluation des Systems zur Aufenthaltsgestaltung

Generelles Ziel dieser Evaluation ist es, frühe Erkenntnisse darüber zu erlangen inwiefern das zuvor vorgestellte Gesamtkonzept nutzbar ist und von Benutzern angenommen wird. Die dabei untersuchten Aspekte sowie die damit verbundene Herangehensweise wird im Folgenden beschrieben.

5.1.1 Zielsetzung

Bezogen auf die in *Kapitel 2.9* vorgestellten möglichen Evaluations-Kriterien werden u. a. die Aspekte Genauigkeit und Gebrauchstauglichkeit des Systems in dieser Evaluation auf qualitativer Ebene untersucht. Besonders werden die Zufriedenheit der Nutzer bei dem Umgang mit dem System und dessen Bedienbarkeit als Teilaspekte der Gebrauchstauglichkeit betrachtet. Eine vollständige Übersicht über alle zu untersuchenden Kriterien ist *Liste 7* zu entnehmen:

- *Genauigkeit*

In dieser Evaluation wird Genauigkeit als diejenige Abweichung der System-Empfehlungen von den tatsächlichen Präferenzen des Nutzers verstanden. Dabei wird v. a. die Lösung des Kaltstart-Problems betrachtet.

- *Zufriedenheit* des Benutzers bei der Nutzung des Systems

Ziel ist herauszufinden, ob die Probanden das System als hilfreich empfinden und inwieweit sie mit der Funktionsweise des Systems zufrieden sind. Weiter sollen Erkenntnisse darüber erlangt werden, ob die Probanden das System in ihrer Freizeit benutzen würden.

- *Steuerbarkeit* des Systems

Herauszufinden ist, ob sich das System Erwartungskonform verhält. Darüber hinaus soll identifizieren werden, ob die Menüführung für die Probanden sinnvoll erscheint und ob die eingeblendeten Informationen zu Empfehlungen in der der *Vertrautheits-Klasse I* entsprechenden Detail-Ansicht angemessen erscheinen (*Abbildung 12*).

- *Qualität der Stereotypen und der Benutzer Initialisierung*

Die bei der Initialisierung der Nutzer angelegten Stereotypen sind sehr allgemein gehalten, unterscheiden sich dennoch in einigen Merkmalen stark. In dieser Studie wird

untersucht, inwiefern der zugewiesene Stereotyp der Selbsteinschätzung des Benutzers entspricht.

Liste 7: Ziele der geplanten Evaluation

5.1.2 Genereller Aufbau

Der Versuch orientiert sich an der realen Benutzung des Systems und umfasst den Standard-prozess zur Benutzer-Initialisierung. Es wird bei der Auswahl der Probanden bereits darauf geachtet, dass möglichst jeder der angelegten Stereotypen im Laufe der Studie mehrfach verwendet wird. Jeder der Probanden bekommt dieselben Aufgaben, die es unter Verwendung des entwickelten Assistenzsystems zur Aufenthaltsgestaltung in einer virtuellen Realität (*Cave Automatic Virtual Environment*, kurz: CAVE) zu lösen gilt.

Während des Versuchs, wird der Proband in die Situation versetzt an einem fremden Bahnhof umsteigen zu müssen. Seine Aufgabe besteht darin, sich seinen Aufenthalt an diesem unter Verwendung des Assistenzsystems zu gestalten, wobei er seinen Anschlusszug nicht verpassen darf. Der Versuch wird in drei Varianten durchgeführt, wobei *Szenario I* den planmäßigen Aufenthalt simuliert, *Szenario II* den Aufenthalt aufgrund einer Verspätung und *Szenario III* einen klassischen Umstieg mit einem notwendigen Gleiswechsel simuliert. Dadurch werden beide in *Liste 4* beschriebenen Empfehlungs-Modi in den Szenarien *I* und *II* eingebunden.

Der virtuelle Nachbau des Frankfurter Hauptbahnhof ist mit fiktiven POI ausgestattet, damit vorausgesetzt werden kann, dass Benutzer immer der *Vertrautheits-Klasse I* angehören. Die Menge der POI an diesem Verkehrsknoten umfasst 20 Items, die nach dem Zufallsprinzip aus einer Menge von 50 ausgewählt und positioniert werden. Damit jedoch Vielfalt zwischen den Items gewährleistet ist, gehören die ausgewählten Items immer in folgender Verteilung entsprechenden Domänen an: Gastronomie (X Items), Shopping (X Items), Finanzen (X Items), Reise (2 Items). Die Steuerung des Systems erfolgt mittels Sprachbefehlen, die der Nutzer frei wählen darf, und wird in einem Wizard-of-Oz Versuchsaufbau simuliert.

5.1.3 Gesamtszenario

Zu Beginn aller drei Szenarien ist der Proband gerade an einem Gleis am virtuellen Frankfurter Hauptbahnhof angekommen. Das Gleis und die Ankunftszeit sind während des Versuchs immer dieselben. Die vom Probanden zu durchlaufenden Szenarien sind wie folgt aufgebaut:

- *Szenario I:* Planmäßiger Aufenthalt ohne Verspätung

Die freie Aufenthaltszeit am Verkehrsknoten beträgt 60 min. Der Proband hat somit freie Zeit, um Empfehlungen am Verkehrsknoten wahrzunehmen. Das System signalisiert dem Probanden, dass es im Aufenthalts-Modus arbeitet und zeigt erste Empfehlungen zur Aufenthaltsgestaltung.

- *Szenario II:* Aufenthalt aufgrund von Verspätung

Die reguläre Aufenthaltszeit am Verkehrsknoten ist mit 15 min laut Fahrplan eingeplant. Der Benutzer soll sich zunächst zum nächsten Gleis bewegen. Der Effizienz-Modus ist aktiviert. Nach fünf minütigem Aufenthalt am Bahnhof erreicht das System die Information, dass der Aufenthalt aufgrund einer Verspätung des Anschlusszuges um ca. 45 min verlängert wird. Der Proband hat somit freie Zeit, um Empfehlungen am Verkehrsknoten wahrzunehmen. Das System signalisiert dem Probanden, dass es im Aufenthalts-Modus gewechselt hat. Erste Empfehlungen zur Aufenthaltsgestaltung werden eingeblendet.

- *Szenario III:* Einfacher Umstieg mit Gleiswechsel

Der Proband hat einen planmäßigen Umstieg vor sich und muss von Gleis 1 zu Gleis 10. Das Assistenzsystem signalisiert ihm, dass der Effizienz-Modus aktiviert ist und blendet POI-Icons am Wegesrand an. Der Proband kann diese Items bei Bedarf wahrnehmen. In diesem Szenario wird der Aufenthalts-Modus nicht aktiviert. Die Aufgabe ist erfolgreich abgeschlossen, sobald der Proband am Ziel angekommen ist.

Ist der Aufenthalts-Modus in *Szenario I* bzw. *Szenario II* aktiviert, verläuft die Aufenthaltsgestaltung in beiden Szenarien ähnlich. Der Proband muss sich zunächst für eine Empfehlung entscheiden. Dazu kann er mittels Sprache die Detailansicht entsprechender Items aufrufen, andere Empfehlungen anfordern und ein Item auswählen. Hat der Proband eine Empfehlung ausgewählt und betätigt, wird er zum entsprechenden Item navigiert. Die Zeit, die er dort verbringt, wird mittels der minimalen Aufenthaltszeit am entsprechenden POI simuliert und von der gesamten Aufenthaltszeit am Bahnhof abgezogen. Die genutzte minimale Aufenthaltszeit entspricht der voreingestellten Standard-Zeit des Systems und wird im Versuch übersprungen. Nachdem der Proband am Item angekommen ist, wird das erneute Generieren von Empfehlungen vom Versuchsleiter veranlasst und der Benutzer kann sich für das nächste Item entscheiden. Es können bis zu drei Empfehlungen wahrgenommen werden (abhängig von dem benötigten Zeitaufwand),

bis der Hinweis auf der Datenbrille erscheint, dass er sich auf den Weg zum Gleis machen muss. Ist der Hinweis erschienen, wechselt die Brille in den Effizienz-Modus und die Navigation zum Gleis wird gestartet.

Auf dem Weg zum Gleis kann der Benutzer Produktivitäts-Items nutzen. Deren maximale Nutzungszeit wird wiederum vom übrigen Zeitkontingent des Probanden abgezogen. Der Versuch endet mit dem Erreichen des richtigen Gleises.

5.1.4 Umsetzung

Der Versuch wird in der CAVE an einem virtuellen Verkehrsknoten (Frankfurt am Main Hauptbahnhof) durchgeführt. Dafür werden die entsprechenden Orte (Hauptbahnhof inklusive POI) modelliert. Empfehlungen werden in der HoloLens dargestellt. Markierungen für POI und Navigationspfeile werden aus technischen Gründen in der CAVE eingebettet.

Da alle Probanden der Vertrautheits-Klasse I zugeordnet werden, wird kein Bewegungsprofil angelegt, das beim Generieren von Empfehlungen einbezogen werden könnte. Die Berechnung der Relationen zwischen Items und Benutzer bzw. Items und Items wird einmalig im Vorfeld durchgeführt. Die Online-Aufbereitung der Empfehlungen wird vereinfacht implementiert. Eine detaillierte Beschreibung des entwickelten Prototyps ist im folgenden *Kapitel 6* zu finden.

5.1.5 Studiendesign

Die Studie wird als Within-Subject-Design aufgebaut. Jeder Proband durchläuft alle drei Szenarien und die Ergebnisse werden jeweils verglichen. Lerneffekte auf Seiten des Benutzers müssen nicht berücksichtigt werden, daher werden die beschriebenen Szenarien immer in derselben Reihenfolge durchlaufen.

Abhängige Variablen:

- Trainingsdaten und damit Verbundene Darstellung im Benutzerprofil
 - Genauigkeit der Empfehlungen
 - Objektive Genauigkeit: Reihenfolge bzw. zugeordnete Relevanz der empfohlenen Items und daraus abzuleitende Wahrscheinlichkeiten (Untersuchung der Wahrscheinlichkeit ausgewählter Items)
 - Wahrgenommene Genauigkeit:

- Objektiver Aufwand: Benötigte Zeit bis ein den Benutzer zufriedenstellendes Items gefunden wurde
 - Wahrgenommener Aufwand: Schwierigkeiten, die ein Benutzer während der Auswahl eines Items hat
- Zufriedenheit des Benutzers mit dem System
- Steuerbarkeit des Systems
 - Bewertung des Aufwands der Steuerung (optimal – zu groß)
 - Likert-Skalen
 - Erwartungskonformität
 - Likert-Skalen
- Qualität des Stereotypen und damit verbunden Lösung des Kaltstartproblems:
 - Wie zutreffend war der Stereotyp auf den Probanden (gefühlt)?
 - Qualitativ
 - Wie genau waren die Empfehlungen mit dem Stereotyp?
 - Vergleich mit Stereotyp ohne Training, Stereotyp mit Training, nur Training => Ziel: Beste Herangehensweise für Lösung des Kaltstartproblems
 - s. Genauigkeit von Empfehlungen

Unabhängige Variablen:

- Algorithmus
- Minimale Nutzungsdauer des Items
- Trainingsablauf

Qualitative Daten:

- Anmerkungen der Probanden während des Versuchs
- Gespräch zur Bewertung des Stereotypen nach Beenden des Versuchs (Wie gut hat der Stereotyp der Selbsteinschätzung entsprochen? Wäre ein anderer passender gewesen?)

Durchführung des Versuchs:

• **Vorbereitung:**

- Einführung des Probanden in das Szenario
- Fragebogen zur Technik-Affinität

- Vorstellung des Systems und der Aufgabe
- Jeder Proband durchläuft beide Szenarien
- Zu Beginn des Versuches wird der Proband im System initialisiert.
- Eingabe demographischer Eck-Daten
- Anlegen eines Trainings-Sets zur initialen Priorisierung von Domänen
- Starten der Berechnung der Relationen zwischen Items und Items und Benutzer
- Einweisung in die Bedienung der Cave und der HoloLens

• **erster Durchlauf wird gestartet**

• Fragerunde I:

- Nach dem ersten Durchlauf wird ein Fragebogen ausgefüllt, der die Zufriedenheit mit dem Assistenzsystem erfragt.
- Sortieren von Items aus dem vorherigen Szenario, die für den Benutzer in Frage kamen, nach persönlicher Vorliebe. Ziel ist es durch Abgleich mit den vom System errechneten Wahrscheinlichkeiten für Items herauszufinden, in wieweit die Empfehlungen von den tatsächlichen Vorlieben des Benutzers in diesem Setting abweichen.

• **zweiten Durchlauf starten**

• Fragerunde II:

- Nach dem ersten Durchlauf wird ein Fragebogen ausgefüllt, der die Zufriedenheit mit dem Assistenzsystem erfragt.
- Sortieren von Items aus dem vorherigen Szenario, die für den Benutzer in Frage kamen, nach persönlicher Vorliebe. Ziel ist es durch Abgleich mit den vom System errechneten Wahrscheinlichkeiten für Items herauszufinden, in wieweit die Empfehlungen von den tatsächlichen Vorlieben des Benutzers in diesem Setting abweichen.

• **dritten Durchlauf starten**

• Fragerunde III:

- Nach dem ersten Durchlauf wird ein Fragebogen ausgefüllt, der die Zufriedenheit mit dem Assistenzsystem erfragt.
- Sortieren von Items aus dem vorherigen Szenario, die für den Benutzer in Frage kamen, nach persönlicher Vorliebe. Ziel ist es durch Abgleich mit den vom System errechneten Wahrscheinlichkeiten für Items herauszufinden, in wieweit die Empfehlungen von den tatsächlichen Vorlieben des Benutzers in diesem Setting abweichen.
- Abschließendes Gespräch und Kommentare zur Nutzung des Systems

Messung der Genauigkeit

Die Genauigkeit von Empfehlungen wird bereits parallel zur Entwicklung offline überprüft und wird darauf aufbauend in diesem Versuch in Form einer Benutzerstudie evaluiert. Dazu werden die Wahrscheinlichkeiten aller Items, die bei dem entsprechenden Filter-Vorgang einbezogen wurden, herangezogen und mit einem Vergleichs-Datensatz abgeglichen. Dazu werden, sofern ein Item ausgewählt wurde, alle Gewichtungen der Item-Menge in dem entsprechenden Setting abgespeichert. Umso geringer die Abweichung zwischen der Wahrscheinlichkeit, dass ein bestimmtes Item wahrgenommen wird, und der des Vergleichs-Datensatzes ist, als desto genauer arbeitend wird das Empfehlungssystem bewertet.

Messung Zufriedenheit und Bedienbarkeit:

Zur Erfassung der Daten wird der ErgoNorm Fragebogen vor und nach dem Versuch eingesetzt.

SUS

6 Prototypische Realisierung

Der hier entwickelte Prototyp umfasst nicht alle der in *Kapitel 4* vorgestellten Funktionen und Komponenten. Der Umfang des im Folgenden beschriebenen Prototyps begrenzt sich auf die zur Evaluation notwenige Funktionalität (s. *Kapitel 5*).

6.1 Eingrenzung der Funktionen des Gesamtkonzeptes

Der Versuch bezieht sich ausschließlich auf die Nutzung des Systems direkt nach der Initialisierung des Probanden. Daher werden Funktionen, die die Verwendung von Daten aus einem längeren Nutzungsverhalten erfordern nicht implementiert.

- Aufgrund der kurzen Dauer der Evaluation wurden die Mechanismen zur Adaptivität des Systems (s. *Kapitel 4*) nicht vollumfänglich umgesetzt. Folgende Daten werden nicht erhoben und damit verbundene Funktionen nicht implementiert:
 - Die Erstellung des beschriebenen Bewegungsprofils ist nicht in vollem Umfang möglich. Es werden keine markanten Geokoordinaten gespeichert, sondern lediglich besuchte Items und ihre entsprechenden Positionen hinzugefügt
 - Bewertungen, die der Benutzer explizit während der Nutzung getätigt hat, existieren aufgrund der kurzen Nutzungsdauer im Versuch nicht.
 - Während des Versuchs werden Öffnungszeiten ignoriert und alle Items als nutzbar angenommen (sonst wahrscheinlich zu wenige Items)
 - Die Nutzungshistorie kann aufgrund der Kürze des Versuchs nur sehr eingeschränkt berücksichtigt werden. Dazu gehört bspw. das jeweilige Setting, in dem Items genutzt wurden. Das aktuelle Setting, in dem der Versuch durchgeführt wird, wird jedoch auf Basis eines reduzierten Kontext-Modells einbezogen. Diese Kontext-Modell enthält folgende Parameter:
 - Aktuelle Uhrzeit und die voraussichtliche Abfahrtszeit und den Ort der Abfahrt. Darauf aufbauend kann die frei verfügbare Aufenthaltsdauer im Versuch berechnet werden.
 - Standort des Benutzers sowie die Standorte der Items und die damit verbundenen Wegzeiten

- Während des Versuchs genutzte Items und deren spezifische Eigenschaften. Aufgrund der kurzen Nutzungsdauer kann jedoch kein repräsentatives Profil über das Setting, in dem Items wahrgenommen wurden erstellt werden. Dadurch wird die Nutzungshistorie auf das bloße Wahrnehmen von Items begrenzt. Kontext-basiertes Filtern in der zweiten Stufe (*Abbildung 9*) wird demnach nicht implementiert.
- Vorausgesetzt wird, dass die Probanden während des Versuch konsumieren wollen. Ruheorte o. ä. können während des Versuchs nicht aufgesucht werden und werden nicht empfohlen.
- Da der Benutzer im Szenario immer der Vertrautheits-Klasse I angehören soll, existiert noch kein Bewegungsprofil am entsprechenden Ort auf das zurückgegriffen werden kann. Des Weiteren wird kein Bewegungsprofil des Benutzers erstellt. Das mit dem Bewegungsprofil verbundene Post-Filtering wird vereinfacht als Online-Filtrern implementiert, wie es in *Kapitel 6.2* beschrieben ist.
- Die Bewertungs-Funktion wird nicht implementiert, da Bewertungen erst zum Ende der Reise bei der Aktualisierung Modell-Instanzen Einfluss nehmen.
- Da bei der Evaluation automatisierte Empfehlungen und deren Genauigkeit im Fokus stehen, wird bei der Implementierung auf die Schlagwortsuche verzichtet.
- Die Sprach-Steuerung wird im Prototypen nicht implementiert, sondern unter Verwendung eines entwickelten Controllers in einem Wizard-of-Oz-Aufbau simuliert. Da die Sprach-Steuerung neben den in Kapitel 5.1.1 beschriebenen Punkten von Projektpartnern evaluiert wird, ist eine gestische Steuerung nicht notwendig.

6.2 Komponenten und Umfang des realisierten Teilsystems

Da der Versuch in einer CAVE durchgeführt wird, muss die Anforderung an Mobilität nicht erfüllt sein. Daher werden die Funktionen des Smartphones mit denen des Servers verbunden. Ein Smartphone wird somit in diesem Prototyp nicht eingebunden. Zusätzlich zu den Komponenten des Assistenzsystems werden zur Steuerung der CAVE und zur Durchführung des Wizard-of-Oz Versuchsaufbaus weitere Schnittstellen benötigt. Anhand dieser wird die Darstellung auf der Datenbrille aktualisiert und die Sprachsteuerung simuliert. Darüber hinaus können jeder Zeit fingierte Echtzeit-Reise-Informationen in das

System geleitet werden. Die schematische Übersicht über die für den Versuch umgesetzten Komponenten ist in Abbildung 14 dargestellt. Der Umfang der einzelnen Komponenten wird im Folgenden beschrieben.

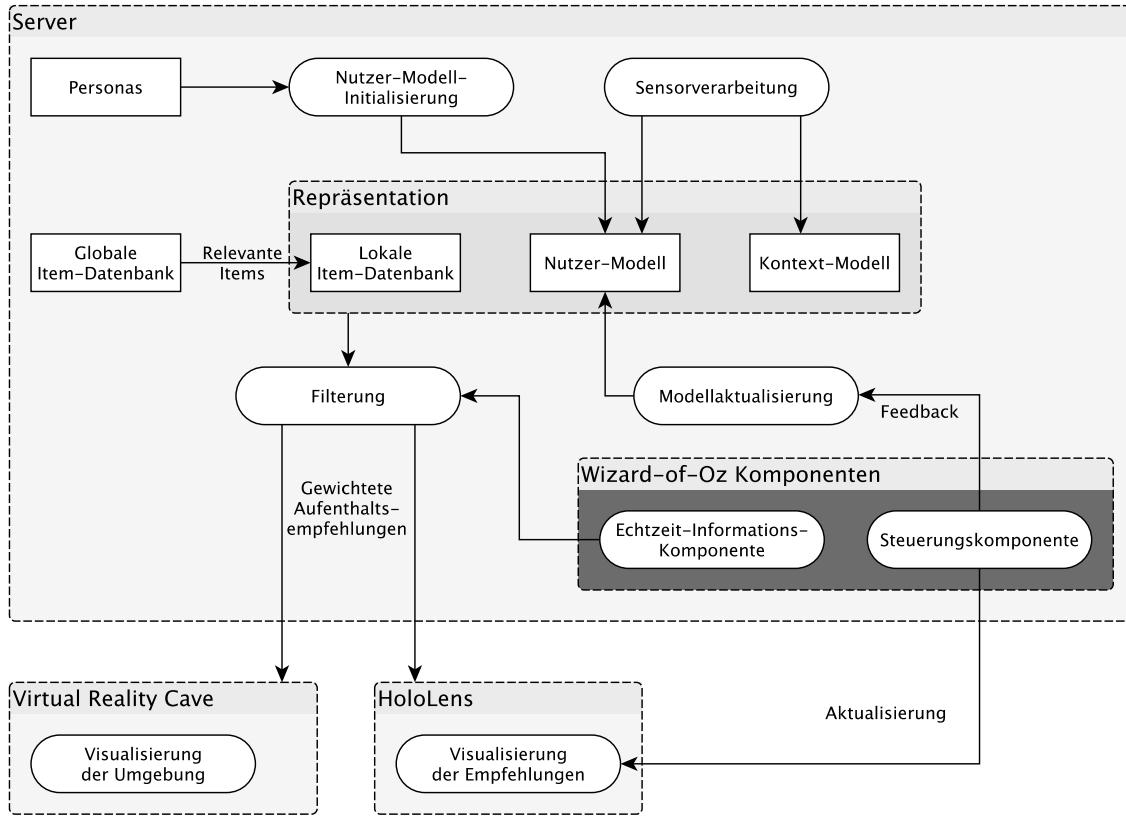


Abbildung 14: Überblick der prototypischen Realisierung

6.2.1 Wizard-of-Oz Controller

Der WoZ-Controller umfasst den Hauptteil der Funktionen des Prototyps. Für die Betriebssprache des Controllers sind Deutsch und Englisch hinterlegt, wobei sich die ausgewählte Sprache an die des Betriebssystems anpasst. Der Controller ermöglicht die Initialisierung der verschiedenen Benutzer und stellt Funktionen zum Einrichten der Versuchsumgebung und zur Durchführung des Versuchs bereit. Dazu wurden drei Hauptansichten entwickelt, die im Folgenden vorgestellt werden: Registrierungsansicht, Trainingsansicht und WoZ-Ansicht.

Der Controller kommuniziert auf Basis von MQTT mit der Datenbrille und der CAVE über das Netzwerk. Die dabei gesendeten Nachrichten sind JSON-formatiert und haben immer einen String-Wert mit dem Namen *action* über den der Empfänger eine bestimmte Funktion ausführen kann. Eine Übersicht über alle möglichen Belegungen von *action* sind im Controller unter *RecTool->About RecTool->Netzwerk* zu finden.

In einer *.sql-Datei wurden 70 Items inklusive ihrer Attribute und deren hierarchischen Ordnung hinterlegt. Darin enthalten sind sieben Trainings-, acht Produktivitäts- und fünfundfünfzig reguläre Items. Diese werden zum Programmstart in die MySQL-Datenbank geladen.

Initialisierung des Benutzers

Die Initialisierung des Benutzers erfolgt in zwei Teilen. Im ersten, dem Registrierungsprozess, werden u. a. demographische Daten über den Benutzer erhoben. Dazu wurde die Registrierungsansicht entwickelt, die auch gleichzeitig die Startansicht des Controllers ist. Beim Registrieren werden die eingegebenen Benutzerdaten in die Datenbank eingetragen. Dabei wird dem Benutzer eine einzigartige Identifikation-Nummer (ID) zugewiesen und wird als aktueller Nutzer im Programm ausgewählt. Sobald der aktuell im System ausgewählte Nutzer eine ID hat, kann der Wizard in die Trainings- und WoZ-Ansicht wechseln.

Im zweiten Schritt trainiert der Benutzer das System durch Auswahl des jeweils präferierten Items in einem randomisierten, paarweisen Vergleich. Die Ergebnisse der jeweiligen Vergleiche werden in einer Matrix festgehalten. Dabei wird für das präferierte *Item A* gegenüber *Item B* eine 1 eingetragen und für den Vergleich von *Item B* gegenüber *A* in diesem Zuge eine 0. Dadurch muss jedes Item-Paar während des Trainings nur einmal verglichen werden. Am Ende des Trainings liegt demnach eine symmetrische, binäre Matrix vor, in der die Vergleiche und die Entscheidung des Benutzers nachvollzogen werden können. Darauf basierend wird pro Item die Summe der Bewertungen gegenüber anderen Items gebildet. Der so entstandene Vektor wird danach normalisiert. Die normalisierten Werte stellen die initiale Bewertung für das jeweilige Item dar. Diese Bewertungen werden mit einer Referenz auf das jeweilige Item im Benutzer-Modell abgelegt. Darauf basierend werden Empfehlungen während des Versuchs generiert werden. Die Benutzerdaten zur Registrierung sowie die Trainingsdaten werdenpersistiert und können zu einem späteren Zeitpunkt über das Menü (*Ablage* → *Öffnen* oder *Strg+O*) erneut geladen werden.

Nachdem ein Benutzer registriert bzw. geladen wurde, kann die Ansicht des WoZ-Controller geöffnet werden.

Anlegen der Versuchsumgebung und Durchführung des Versuchs

Aus den zum Systemstart geladenen Items wird randomisierte Auswahl beim Öffnen des WoZ-Controllers für den Versuch getroffen. Dabei werden die Koordinaten der ausgewählten Items randomisiert vertauscht, wobei Duplikate ausgeschlossen werden.

Zu Beginn des Versuchs ist der WoZ-Controller, wie in *Abbildung X* dargestellt, leer. Damit Empfehlungen für den ausgewählten Nutzer generiert werden, muss auf den grünen Button mit der Aufschrift „*Neue Empfehlungen generieren*“ gedrückt werden. Der Versuch wird nach dem generieren der Empfehlungen automatisch gestartet. Die verbleibende Versuchszeit wird oben rechts in Form eines Countdowns angezeigt. Dieser Countdown läuft von der voreingestellten Versuchsdauer nach Start des herunter. Der Versuch wird automatisch beendet, sobald der Countdown abgelaufen ist.

Nach dem Start der Evaluation füllt sich die linke Liste mit dem Präferenzen-Vektor des Nutzers. Diese Liste bleibt während des Versuchs statisch, da die Aktualisierung des selbigen erst zu Beginn eines evtl. Folgeversuchs durchgeführt wird. Die rechte Liste zeigt eine Übersicht über die Bewertungen aller für den Versuch vom System ausgewählten Items, bezogen auf die Relevanz für den aktuellen Benutzer. Wie diese Relevanzen berechnet werden wird in der Folgenden Sektion *Filter* beschrieben.

Die Buttons unterhalb der beiden Listen werden mit Item-Namen beschriften. Diese drei Item-Namen entsprechen denjenigen Items, die dem Benutzer auf der Datenbrille aktuell gezeigt werden. Dem Benutzer werden immer nur drei Items gleichzeitig präsentiert. Ein Item kann entweder durch Klicken auf einen der Buttons oder den entsprechenden Eintrag Liste selektiert bzw. abselektiert werden. Die entsprechende Detailansicht eines Items in der Brille wird durch einen Klick auf einen der Buttons im linken Menü angezeigt bzw. wieder ausgeblendet. Die jeweilige Aktion wird durch das Färben bzw. Nicht-Färben des entsprechenden Buttons visualisiert.

Die Belegung der Buttons mit einem Tripel kann durch Auswählen eines Items aus der Liste verändert werden. Ist das ausgewählte Item nicht Teil des aktuell angezeigten Tripels, wird die Selektion aufgehoben. Der Controller berechnet das mit dem ausgewählten Item verbundene Tripel und aktualisiert die Buttons entsprechend. Das ausgewählte Item wird an die Datenbrille gesendet, wodurch auch dort das aktuelle Tripel angezeigt wird.

Weitere Funktionen, die den Ablauf der Evaluation beeinflussen, bietet die Button-Leiste rechts in *Abbildung X*. Zu einem ausgewählten Item kann die Navigation in der CAVE gestartet werden. Dabei wird eine Anfrage zur Berechnung der Route mit dem entsprechenden Item an die CAVE gesendet, wo die kürzeste Route zum Item berechnet wird. Während der Berechnung erscheint im Controller die Anzeige, dass die Route

berechnet wird. Nachdem eine Route gefunden wurde bzw. keine Route gefunden wurde, sendet die CAVE eine entsprechende Nachricht zurück an den Controller, woraufhin die Status-Anzeige aktualisiert wird. Während der Navigation wird auf Basis der aktuellen Benutzerposition dessen Abstand vom Ziel berechnet (Luftlinie in [m]) und in der Status-Leiste angezeigt. Nachdem das Item erreicht wurde, kann dieses als genutzt deklariert werden. Dadurch wird das selektierte Item mit dem aktuellen Zeitstempel zu der Liste genutzter Items im Setting hinzugefügt und der im Folgende beschriebene, kontext-basierte Filterprozess wird erneut gestartet. Die aktualisierten Empfehlungen werden anschließend an die Brille gesendet.

Durch einen Klick auf den Button *Alle Verstecken* werden auf der Datenbrille alle Empfehlungen ausgeblendet, bis ein Item selektiert wird oder erneut Empfehlungen an die Brille gesendet werden. System-Nachrichten sind von dieser Funktion ausgenommen und werden weiterhin angezeigt.

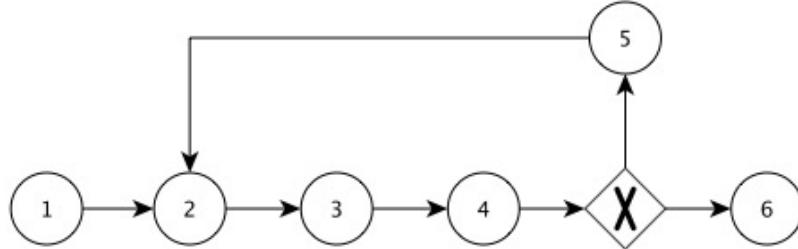
Durch Klicken auf den Button in der rechte Leiste mit der Aufschrift *Meldung senden* erscheint ein Dialogfenster, in dem vorgegebene Systemmeldungen aus einem DropDownList-Menü ausgewählt oder eigene formuliert werden können. Das selbe Fenster lässt sich während der Evaluation auch im Menü unter *Evaluation->System Prompt* senden öffnen. Im folgenden Absatz wird der volle Funktionsumfang näher beschrieben. Während der Evaluation kann jeder Zeit die Navigation zur voreingestellten Ziel-Koordinate zum Ende des Versuchs gestartet werden (*Evaluation->Zur nächsten Abfahrt navigieren*). Der Wechsel in den Effizienz-Modus wird davon nicht beeinflusst.

Nach Ablauf der Versuchszeit erscheint ein Dialogfenster, das dem Wizard mitteilt, dass der Versuch nun beendet ist. Der Wizard hat die Wahl, das während des Versuchs befüllte Setting zu verwerfen oder es beizubehalten. Wird das Setting beibehalten, wird es in folgenden Durchläufen weiter berücksichtigt, bspw. beim Generieren von Empfehlungen durch die bereits genutzten Items und deren Nutzungs-Zeitpunkte. Wird ein Benutzerprofil gespeichert (*RecTool->Speichern*), werden die genutzten Items in die Ratings des Benutzers aufgenommen und in der Datenbank abgelegt. Dabei wird der Score der genutzten Items um 0,1 erhöht, bis der maximale Score erreicht ist.

Versand von Benachrichtigungen

Um die Interaktion zwischen dem Wizard, dem Benutzer und dem System während des Versuchs zu erleichtern, werden zu bestimmten Ereignissen automatisch Nachrichten an die Datenbrille gesendet und dort präsentiert. Dabei wird der Benutzer stets geduzt, wodurch

das System als persönlicher Assistent dem Benutzer vertrauter erscheinen soll. Der Ablauf der automatisch versendeten System-Nachrichten während des Aufenthalts-Modus ist in *Abbildung 15* illustriert.



Ereignis	Meldung
1 Ankunft am Gleis	
2 Route zu einem Item wurde berechnet	Die Navigation zu %itemname% wurde gestartet.
3 Ankunft des Nutzers am Item	Du hast das Ziel %itemname% erreicht!
4 Simulation der Nutzung des Items	Versuchsleiter: Du verbringst hier nun X min.
5 Zeitgesteuerte Frage	Du hast noch X min Zeit. Was möchtest du gerne unternehmen?
6 Wechsel in den Effizienz-Modus	Du musst nun zum Gleis.

Abbildung 15: Aufbau der Interaktion mit System-Prompts

Darüber hinaus können jeder Zeit Nachrichten manuell vom Controller auf die Datenbrille gesendet werden. Dazu stehen verschiedene Vorlagen bereit, die aus einem Dropdown-Menü ausgewählt werden können. Zudem können eigene Nachrichten geschrieben werden. Der Typ jeder Nachricht kann entweder als Fehler- oder Informationsnachricht deklariert werden. Der ausgewählte Typ bestimmt den Stil, in dem jene in der Datenbrille eingeblendet wird (s. **Abbildung XY**). Sollen aktuelle Informationen, wie bspw. die noch verbleibende Aufenthaltsdauer, in der Nachricht eingeblendet werden, so kann ein Platzhalter anstelle der entsprechenden Information eingesetzt werden. Der jeweilige Platzhalter wird nach Absenden der Nachricht mit der entsprechenden Information ersetzt. Folgende Platzhalter werden unterstützt:

%duration%	Voraussichtliche Nutzungsdauer des selektierten Items
------------	---

%itemname%	Name des aktuell selektierten Items.
%min%	Die noch verbleibende, simulierte Zeit bis zur Anfahrt

Tabelle 3: In Systemnachrichten nutzbare Platzhalter

Filter

Aufgrund der in *Kapitel 6.1* beschriebenen Einschränkungen bzgl. der zu erhebenden Benutzerdaten, wird der Filterprozess um die zweite Kontext-basierte Filterstufe reduziert und lediglich in folgendem Umfang implementiert:

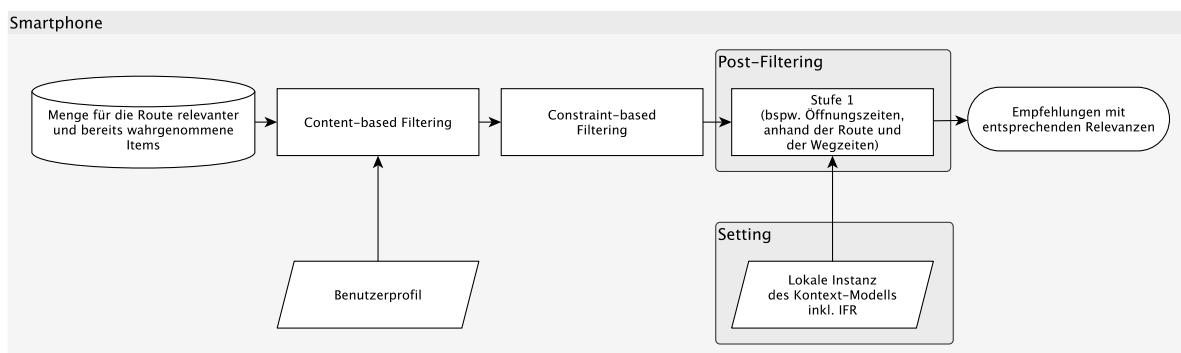


Abbildung 16: Schematische Darstellung des im Prototypen implementierten Filters

Zur Realisierung des Content-based-Filtering wurde das in *Kapitel 4.2.3* beschriebene, erweiterte VSM genutzt. Dabei werden alle Attribute, die in allen Items vorkommen in einen eindimensionalen Vektor überführt. Dieser Vektor wird für jedes Item in einer Matrix abgebildet und mit den entsprechenden Werten gefüllt. Für m Items mit insgesamt n Attributen ergibt sich somit eine $m \times n$ Matrix. Der Präferenz-Vektor (s. *Kapitel 4.2.3*) des Benutzers besteht demnach auch aus n Dimensionen. Nachdem der Präferenz-Vektor des Benutzers erstellt wurde, werden die Ähnlichkeiten des Items zueinander berechnet. Auf diese Ähnlichkeiten wird beim kontext-basierten Filtern zurückgegriffen.

Rolle des Baumes? Hierarchie?!

Im darauffolgenden Constraint-based-Filtering werden die ausgewählten Items zuerst auf ein evtl. Mindestalter geprüft. Falls Der Benutzer bspw. zu jung ist, um ein Item zu Nutzen ist, wird dieses Item aus der Menge von Empfehlungen herausgenommen. Ist das Item noch nutzbar, wird es auf Attribute untersucht, die der Benutzer ausschließt und ggf. aus der Menge empfohlener Items entfernt. Dabei werden Items nur dann entfernt, wenn das Item keine Eigenschaften innehaltet, die nicht mittels der Constraints ausgeschlossen wurden. Der zweite Teil dieses Filters wurde im Prototypen implementiert, wird jedoch während des Versuchs nicht genutzt.

Nach Abschluss des Constraint-based Filtering wird während des Versuchs lediglich auf Basis des Settings online gefiltert. Diese Filterung wird automatisch jede 30 s nach Versuchsstart durchgeführt oder nachdem ein Item als genutzt markiert wurde. Dabei wird der aktuelle Standort des Benutzers, die geschätzten Wegzeiten bis zu den jeweiligen Items, die damit verbundene, angenommene Nutzungsdauer sowie die Wegzeiten von dem Item zur gewünschten Endposition berücksichtigt. Items, die nach diesem zeitlichen Kriterium nicht nutzbar sind, werden aus der Menge zu empfehlender Items entfernt. Diese Items werden während der aktuellen Evaluation im WoZ-Controller in der Liste nutzbarer Items nicht mehr aufgeführt.

Im nächsten Schritt werden Relevanzen während des Versuchs genutzter Items manipuliert, um diese temporär herabzustufen und somit die Nutzung anderer Items zu empfehlen. Darüber hinaus werden Relevanzen von Items, die den bereits genutzte ähnlich sind, ebenfalls temporär herabgestuft. Das damit verfolgte Ziel ist es, dem Benutzer eine Vielfalt von Domänen zu zeigen. Wurde bspw. ein Café besucht ist anzunehmen, dass der Benutzer nicht sofort wieder ein Café besuchen möchte, sondern eher Items aus anderen Domänen, die damit hergehend eine geringe Ähnlichkeit mit diesem Café haben. Um dieses Verhalten unter Berücksichtigung der Zeit und der ursprünglichen Relevanz mathematisch darzustellen, wurden Annahmen bzgl. der Entwicklung von Bedürfnissen von Nutzern getroffen. Es wird angenommen, dass Items, die aktuell wahrgenommen wurden, vom Benutzer nicht gleich wieder wahrgenommen werden. Falls dies doch der Fall sein sollte, muss dieses Item nicht noch einmal empfohlen werden, da der Benutzer jenes bereits kennt und somit die Aufgabe des Assistenzsystems erfüllt ist. Weiter wird angenommen, dass Benutzer, die ein Item genutzt haben, ein Bedürfnis befriedigt haben und daher im Folgenden kein allzu ähnliches Item suchen. Daher nimmt die Nutzung eines Items Einfluss auf die temporäre Relevanz ähnlicher Items. Weiter wird die Frage nach der eigentlichen Absicht zur Nutzung des Items ausgeklammert und das Item somit als Ganzes betrachtet. Die Relevanz einzelner Attribute, die die Nutzung des Items potentiell ausgelöst haben, wird somit im Rahmen dieser Arbeit nicht betrachtet. Die Wiederkehr von Bedürfnissen von Nutzern wird ähnlich dem Verlauf des negierten Cosinus im Bereich von $0 \leq x \leq \pi$ angenommen. Die Entwicklung der Relevanzen genutzter Items verschiedener Domänen über die Zeit wird als gleich angenommen. Damit folgt bspw. das Bedürfnis danach einen Kaffee zu trinken, nachdem bereits ein Kaffee getrunken wurde, derselben Entwicklung über die Zeit, wie das Bedürfnis danach einen Buchladen zu besuchen, nachdem bereits ein solcher besucht wurde. Diese Annahmen vereinfachen die enorme Komplexität dieses

Problems sehr stark und müssen zur Umsetzung des Gesamtkonzeptes und zur Langzeitnutzung weiter ausgearbeitet werden.

Implementiert wurden daher zwei Filter. Der erste (s. *Formel 6*) bezieht sich auf tatsächlich genutzte Items und stuft deren temporäre Relevanz s_{tmp} zum Zeitpunkt der Nutzung t_u maximal ab ($s_{tmp} = -1$). Während der weiteren Nutzung des Systems wird s_{tmp} monoton aufgewertet, bis es den ursprünglichen Wert s erreicht hat. Damit die zeitabhängige Entwicklung verlangsamt wird, wurde der statische Faktor x eingebunden, der für alle Items gleich ist.

$$s_{tmp}(it) = \begin{cases} s - \frac{\cos \frac{t - t_{u,it}}{x} + 1}{2} * (s + 1), & 0 \leq \frac{t - t_{u,it}}{x} < \pi \\ s, & \text{sonst} \end{cases}$$

Formel 6: Abstufung der temporären Relevanz eines genutzten Items

Der zweite Filter (s. *Formel 7*) stuft die Relevanz von Items ab, die ähnlich zu bereits genutzten sind. Diesen Schritt durchlaufen auch Items, die bereits den vorherigen Prozess durchlaufen haben. Nach Abschluss der folgenden Berechnung wird der kleinere der beiden Scores übernommen. Die Ähnlichkeit zwischen zwei Items ($sim(it1, it2) \in [0;1]$) wird unter Verwendung der Kosinus-Ähnlichkeit auf Basis ihrer Eigenschaftsvektoren bestimmt. Überschreitet $sim(it1, it2)$ von einem nicht genutzten Item $it1$ und einemgenutzten Item $it2$ einen Schwellwert von $thrshld_{sim} = 0,4$, so wird $s_{tmp}(it1)$ gemäß ermittelt.

$$s_{tmp}(it1) = \begin{cases} s_{it1} - \frac{\cos \frac{t - t_{u,it2}}{x} + 1}{2} * (s_{it1} + 1) * sim(it1, it2), & 0 \leq \frac{t - t_{u,it2}}{x} < \pi \\ s_{it1}, & \text{sonst} \end{cases}$$

Formel 7:Abstufung der temporären Relevanz eines genutzten Items

Die temporären Änderungen der Item-Relevanzen durch das kontextuelle Filtern und die Liste genannter Items werden vom Controller nach Versuchsabschluss, anders als im Gesamtkonzept für das reale System beschrieben, verworfen, sofern sie nicht explizit gespeichert werden.

Der Controller administriert zudem den Wechsel zwischen Aufenthalts- und Effizienz-Modus. Dazu wird die Wegzeit von der aktuellen Position des Benutzers bis zur angegebenen Endposition einbezogen. Unterschreitet die verbleibende Evaluationszeit diese Wegzeit mit einem zusätzlichen Puffer von 10 % (jedoch minimal 1 min und maximal

5 min), sendet der Controller eine entsprechende Nachricht an die registrierten Komponenten, die die Aktion *switchedRecommendationMode* und als Wert den entsprechenden Namen des neuen Modus enthält.

Administration des Netzwerkverkehrs

Weitere Komponenten des Systems werden durch die WoZ-Komponente gesteuert. Die dazu notwendigen Befehle werden über das Netzwerk an die entsprechenden Geräte gesendet. Dafür wird das häufig zur Kommunikation zwischen Maschinen genutzte MQTT-Protokoll genutzt. Der dazu notwendige Broker ist auf demselben Gerät installiert, wie auch die WoZ-Komponente. Die über das Netzwerk gesendeten, JSON formatierten Nachrichten bestehen jeweils aus einem Tag *action*, mittels dessen die vom Empfänger auszuführende Funktion ausgedrückt wird. Sofern notwendig, können den Nachrichten weitere Daten angefügt werden. *Anhang 12.9* gibt einen Überblick über die genutzten Netzwerkbefehle und deren Empfänger. Die Verarbeitung der entsprechenden Befehle in den jeweiligen Komponenten wird im Folgenden beschrieben.

Einstellungen

Der entwickelte Controller bietet über die bereits beschriebenen Funktionen hinaus die Möglichkeit Einstellungen bzgl. des Versuchs vorzunehmen. Einstellungen können sowohl für die MQTT-Nutzung als auch für die Evaluation selbst vorgenommen werden. Die Netzwerknutzung kann aktiviert und deaktiviert werden. Außerdem kann die Adresse des genutzten Brokers ausgewählt werden. Beim Speichern der Einstellungen wird die Verbindung zu diesem überprüft und ggf. eine Fehlermeldung ausgegeben.

Nach dem Start des Programms können sich CAVE und Datenbrille bei dem Controller registrieren. Dabei senden sie eine Nachricht mit dem Befehl *subscribe* und ihr eigenes Topic. Der Controller *subscribed* sich zu dem gesendeten Topic und ändert das entsprechende Icon zur Visualisierung der Verbindung (s. *Abbildung X*).

In den Einstellungen zur Evaluation selbst kann die Anzahl von Items, die in der Umgebung genutzt werden sollen eingestellt werden. Die damit verbundene Positionierung kann in Geokoordinaten oder in einem eigenen Koordinatensystem erfolgen. Falls Geokoordinaten verwendet werden, muss die entsprechende Checkbox selektiert werden, da sonst die Abstandsmessung während der Navigation nicht korrekt arbeitet. In 10 min Schritten kann zusätzlich die Versuchszeit angegeben werden. Zuletzt kann eine Position im verwendeten Koordinatensystem angegeben werden, an der sich der Proband zum

Ablauf der Versuchszeit befinden soll. Zu dieser Koordinate wird der Benutzer automatisch navigiert, sobald der Effizienz-Modus aktiviert wurde. Die dazu benötigte Wegzeit wird beim Prüfen des aktuellen Modus berücksichtigt.

Darüber hinaus ist das Laden bereits registrierter Benutzer und deren Trainingsdaten möglich (s. *Abbildung X*).

6.2.2 CAVE

Zum Programmstart registriert sich die CAVE mittels einer Netzwerknachricht am WoZ-Controller.

Anlegen der Versuchsumgebung

Die von der WoZ-Komponente für den jeweiligen Versuch gesendeten Items, werden von der CAVE über einen MQTT-Client empfangen. Die Zuordnung von Objekten in der virtuellen Realität zu dem jeweiligen Item wird auf Basis der Koordinaten durchgeführt. Dabei werden die Koordinaten der Items mit denen der in der CAVE hinterlegten, zu texturierenden Knoten verglichen. Konten werden in diesem Zusammenhang als 3D-Objekte verstanden. Derjenige Knoten, dessen Position den minimalen Abstand zum jeweiligen Item hat, wird entsprechend texturiert. In dem genutzten 3D-Modell gibt es drei Arten von Knoten, die zu texturieren sind. Diese unterscheiden sich v.a. in ihrer zu texturierenden Flächengröße. Während sich zwei davon auf die reine Beschilderung eines Items beziehen, stellt die dritte jeweils eine große, virtuelle Schaufensterfläche bereit. Da die Zuweisung der Items zu einer Koordinate zufällig erfolgt, werden für jedes Item drei verschiedene Texturen hinterlegt. Somit kann jeder Knoten optimal texturiert werden.

Im Effizienz-Modus werden Produktivitäts-Items durch Einblenden von POI-Symbolen hervorgehoben. Zur Positionierung des Symbols wird die Koordinate des jeweiligen Items genutzt.

Um die Versuchsumgebung möglichst real wirken zu lassen, werden zur Initialisierung 60 Personen und 11 Züge randomisiert in das Modell generiert.

Personen:

Basis bitmap

Randomisiertes, freies Startfeld

Dann 10 Durchläufe mit randomisierter Streckenlänge zw. 10 und 30 m

Randomisierte Richtung, dann laufen bis Hindernis oder Strecke vollständig gelaufen.

Randomisierte Richtung

Züge:

Jede Minute zufällig 1 wegschicken und 1 ordern

Fahrendes Fahrzeug gesperrt bis Endposition erreicht, es sei denn force

Force bei wechsel in Effizienzmodus, damit Anschlussverkehrsmittel ankommt

Fahrzeug wird anhand des minimalen x-Abstand zum gleis berechnet

Aktualisierung des Settings

Die aktuelle Position des Benutzers wird von der CAVE an den Controller zur Aktualisierung des Settings gesendet. Dies geschieht, sobald eine Positionsänderung von min. 2 m erkannt wurde. Dabei wird die aktuelle Position des Benutzers wird bei jeder Positionsänderung mit der vorherigen abgeglichen.

Navigation zu Items

Zum Start der Simulation in der CAVE wird ein monochromer Grundschnitt des 3D-Modells eingelesen und in eine Bitmap übertragen, um begehbar von nicht begehbar Flächen zu unterscheiden. Dabei wird vorausgesetzt, dass begehbar Flächen weiß gefärbt sind. Sukzessive werden zur Erstellung der Bitmap quadratische Ausschnitte des Grundrisses untersucht und jeweils ein Histogramm für die enthaltenen Farben angelegt. Entspricht die häufigste Farbe in diesem Quadranten ungefähr weiß (min. RGB (250,250,250)), wird in der Bitmap an der entsprechenden Stelle eine 0 eingetragen. Andernfalls wird das Hindernis mit einer 1 markiert. Überschreitet ein Quadrat den Bildrand, wird die entsprechende Fläche als ein Hindernis interpretiert. Die Größe der quadratischen Bildausschnitte entspricht min. einem realen Quadratmeter. Um den dafür benötigten Maßstab zu berechnen, muss zum Programmstart die reale Breite des Grundrisses in Metern angegeben werden. Die Genauigkeit der Repräsentation des Grundrisses durch die Bitmap kann darüber hinaus durch die Abtastung je Streckenmeter angepasst werden. Ein entsprechender Parameter f wird im Programm dazu genutzt, wobei standardmäßig $f = 1$ gilt (ein Quadrat pro Quadratmeter). Wird der Faktor bspw. auf $f = 2$ geändert, so werden vier Quadrate pro Quadratmeter erzeugt ($Anzahl\ Quadrate = f^2$). Bei der Wahl der Auflösung der Bitmap ist zu beachten, dass die Quadrate Grundlage für die Routenberechnung sind. Eine hohe Genauigkeit der Bitmap führt zu einer verlängerten Laufzeit bei der Routenberechnung.

Nach dem Erstellen der Bitmap kann diese unter Verwendung des berechneten Maßstabs auf das 3D-Model bezogen werden. Zusätzlich sind Konfigurationen für Offsets möglich, anhand derer die Bitmap positioniert werden kann.

Die Routenberechnung erfolgt unter Verwendung des A*-Algorithmus, der auf die zuvor beschriebene Matrix zurückgreift. Wird ein Ziel in Form eines Items an die CAVE gesendet, so werden dessen Koordinaten auf die Matrix bezogen. Als Start-Position wird die ebenfalls auf die Matrix bezogene Position des Benutzers gewählt. Nachdem die Routenberechnung abgeschlossen ist, wird an den Controller eine Nachricht gesendet. Wurde eine Route gefunden, wird das empfangene Item zurückgesendet, andernfalls nicht. Zudem wird der berechnete Pfad mit grünen, dreidimensionalen Pfeilen am Boden der virtuellen Realität visualisiert. Die Ausrichtung der einzelnen Pfeile orientiert sich an deren jeweiligen Nachfolgern, wobei die Ausrichtung der Pfeile in 45°-Schritten variiert wird. Zur Hervorhebung des Ziels wird an dessen Koordinate ein dreidimensionales, vertikal rotierendes POI-Symbol platziert.

Bei Positionsänderungen des Benutzers wird, sofern die Navigation aktiviert ist, bei einer Änderung von min. 2 m überprüft, welche Pfeile einen größeren Abstand zum Ziel haben als der Benutzer. Diese Pfeile werden als nicht mehr notwendig interpretiert und entfernt. Sobald der Benutzer das Ziel im Umkreis von 2 m erreicht hat, werden die Navigationshilfen ausgeblendet und eine Bestätigung an den Controller gesendet.

Erhält die CAVE eine Nachricht mit der Aktion *switchedRecommendationMode* und dem Wert *efficiencyMode*, so wird die Route zur gesendete Endposition des Benutzers berechnet. Diese Route wird im Anschluss an den Controller gesendet. Weiter werden POI-Symbole über Produktivitäts-Items eingeblendet, die sich an der Route des Benutzers befinden.

6.2.3 HoloLens

Die HoloLens wird sowohl zur visuellen Ausgabe der Empfehlungen in Form einer Top-N-Item-Liste mit drei Items genutzt (s. Kapitel 4.2.4) als auch zur Darstellung von Feedback-Funktionen eingesetzt. Zum Start der Anwendung auf der Datenbrille registriert sich diese mit einer Nachricht mit der Aktion *subscribe* an den WoZ-Controller.

In der Datenbrille werden selektierte Items farblich hervorgehoben und verschiedene Systemmeldungen angezeigt. System-Meldungen werden abhängig von dem mitgesendeten Modus entweder als Informations- oder Warnmeldung angezeigt. Während der

Einblendung von Systemmeldungen werden Empfehlungen ausgeblendet. Die Anzeigedauer der jeweiligen Nachricht hängt von deren Inhalt ab und berechnet sich nach der folgenden Formel, die auf Basis von verschiedenen Versuchen entwickelt wurde:

$$t = (\text{Anzahl Buchstaben} - \text{Anzahl Wörter}) * 1,5$$

Formel 8: Anzeigedauer von Systemnachrichten in der Datenbrille

Jede von der Brille empfangene Systemnachricht wird in eine Warteschlange (Queue) angehängt. Ist die Anzeigedauer einer Nachricht abgelaufen, wird diese aus der Queue entfernt. Sind weitere Nachrichten in der Queue enthalten, so werden diese nach dem v Prinzip *First-In-First-Out* abgearbeitet. Die Warteschlange kann explizit über den WoZ-Controller im Nachrichten-Menü geleert werden (XXX).

Queue kann im Systemnachrichten Menü des WoZ-Controllers geleert werden.

Wird die Navigation zu einem selektierten Item gestartet, so wird während der Routenberechnung ein Ladesymbol im unteren rechten Rand der Brille angezeigt. Wurde eine Route von der CAVE gefunden, erscheint eine Informationsmeldung, dass die Navigation nun gestartet wurde. Wurde keine Route gefunden, so wird dies dem Benutzer in Form einer Warnmeldung mitgeteilt. Sobald das Ziel erreicht wurde, erscheint eine Informationsmeldung mit der entsprechenden Nachricht. Empfehlungen bleiben daraufhin ausgeblendet, bis vom Controller neue Empfehlungen gesendet werden.

Feedback wird an Controller gesendet, wenn countdown abgelaufen ist.

7 Durchführung der Evaluation

Bei der Evaluation nahmen X Probanden teil, darunter X männlich und X weiblich.

Der Versuch dauerte im Mittel 1 h.

Die simulierte Aufenthaltsdauer betrug bei jedem Probanden 60 min.

Im Median nutzten die Probanden während dieser Zeit X Items.

Es wurden in jedem Versuch 20 Items randomisiert ausgewählt.

Probleme...

Besondere Vorkommnisse und Auffälligkeiten...

8 Ergebnisse und Limitierung

Genauigkeit der Empfehlungen

Eindrücke der Probanden

Limitierung:

Es wurde nicht berücksichtigt, dass Menschen auch Ruheorte aufsuchen wollen bzw. nicht konsumieren möchten.

9 Diskussion

10 Ausblick

11 Literaturverzeichnis

- Adomavicius, G.; Tuzhilin, A. (2015) : Context-Aware Recommender Systems. In F. Ricci, L. Rokach, & B. Shapira (Eds.), Recommender Systems Handbook (S. 191–226). Boston, MA: Springer US
- Ahern, S., et al., 2007. World explorer: visualizing aggregate data from unstructured text in geo-referenced collections. In: E.M. Rasmussen, R.R. Larson, E.G. Toms and S. Sugimoto, eds., Proceedings of the 7th ACM/IEEE-CS joint conference on Digital libraries, 18–23 June 2007, JCDL '07, Vancouver. New York: ACM, S. 1-10
- Amatriain, X. : Mining Large Streams of User Data for Personalized Recommendations, 2013
- Amatriain, X.; Basilico, J. (2015): Recommender Systems in Industry: A Netflix Case Study. In F. Ricci, L. Rokach, & B. Shapira (Eds.), Recommender Systems Handbook. Boston, MA: Springer US, S. 385-419
- Amatriain, X.; Jaimes, A.; Oliver, N.; Pujol, J. M. (2015) Data mining methods for recommender systems. In: Recommender systems handbook. Springer, Berlin, S. 227-261
- Awad, N. F.; Krishnan, M. S.: The Personalization Privacy Paradox: An Empirical Evaluation of Information Transparency and the Willingness to Be Profiled Online for Personalization. MIS Quarterly 30(1), S. 13-28 (2006)
- Bachem, C.: Profilgestütztes Online Marketing. Personalisierung im E-Commerce, Hamburg, Germany, (1999)
- Barbeau, S. J., Winters, P. L., Georggi, N. L., Labrador, M. A., & Perez, R. (2010): Travel assistance device: utilising global positioning system-enabled mobile phones to aid transit riders with special needs. IET Intelligent Transport Systems, 4(1), 12. <https://doi.org/10.1049/iet-its.2009.0028>
- Berkovsky, S.; Kuflik, T.; Ricci, F.: The impact of data obfuscation on the accuracy of collaborative filtering. Expert Syst. Appl. 39(5), S. 5033-5042, 2012
- Bettman, J. R., Luce, M. F., and Payne, J. W. "Constructive Consumer Choice Processes," Journal of Consumer Research (25:3), 1998, S. 187-217
- Burke, R., Hammond, K., Young, B.: The FindMe approach to assisted browsing. IEEE Expert: Intell. Syst. Their Appl. 12, 32–40 (1997)
- Bodendorf, F.: Daten- und Wissensmanagement. S.1, Aufl. 170. Springer Verlag, Berlin, Heidelberg (2006)
- Boone, G. (1998). Concept Features in RE: Agent, an Intelligent Email Agent. The Second International Conference on Autonomous Agents (Agents '98), 1998

- Brandtzæg, P. B. (2010). Towards a unified Media-User Typology (MUT): A meta-analysis and review of the research literature on media-user typologies. *Computers in Human Behavior*, 26(5), 940-956.
- Breese, J. S.; Heckerman, D.; Kadie, C.: Empirical analysis of predictive algorithms for collaborative filtering. In Proceedings of the Fourteenth conference on Uncertainty in artificial intelligence (S. 43–52), 1998
- Brug J, Steenhuis I, Van Assema P, De Vries H. The impact of a computer-tailored nutrition intervention. *Prev Med* 1996; 25:236 – 242
- Burke, R. (1999). The Wasabi Personal Shopper: A Case-Based Recommender System, 844–849
- Burke, R. (2000): Knowledge-based recommender systems. Encyclopedia of Library and Information Science, (volume 69)
- Burke, R.: Hybrid Recommender Systems: Survey and Experiments. *UMUAI* 12 (4), 331-370. (2002)
- Burke, R. : Hybrid Recommender Systems. In: Bruslikovsky, P.; Kobsa, A.; Neijdl, W. (eds.) *The Adaptive Web*, S. 628-670. Springer Verlag, Berlin, Heidelberg 2007
- Campbell MK, DeVellis BM, Strecher VJ, Ammerman AS, DeVellis RF, Sandler RS. Improving dietary behavior: the effectiveness of tailored messages in primary care settings. *Am J Public Health* 1994;84(5):783-787
- Chellappa, R. K.; Sin, R. G. : Personalization versus Privacy: An Empirical Examination of the Online Consumer's Dilemma. *Information Technology and Management* 6(2), S. 181-202, 2005
- Cooperstein, D., Delhagen, K., Aber, A., and Levin, K.: Making Net Shoppers Loyal. Forrester Research, Cambridge, MA June 1999.
- Culnan, M. J.; Bies, R. J. : Consumer privacy: Balancing economic and justice considerations. *Journal of Social Issues* 59(2), S. 323-342 (2003)
- Cunningham, P.; Bergmann, R.; Schmitt, S.; Traphoner, R.; Breen, S.; Smyth, B: *WebSell: Intelligent Sales Assistants for the World Wide Web*. E-2001, 2001
- Desrosiers, C. & Karypis, G. (2011), A Comprehensive Survey of Neighborhood-based Recommendation Methods., in Francesco Ricci; Lior Rokach; Bracha Shapira & Paul B. Kantor, ed., *Recommender Systems Handbook*, Springer, S. 107-144
- Delgado, J.; Davidson, R. (2002): Knowledge Bases and User Profiling in Travel and Hospitality Recommender Systems
- Deutsches Telemediengesetz: <http://www.gesetze-im-internet.de/tmg/>, 17.05.2017, 26.02.2007
- Directive 95/46/EC of the European Parliament and of the Council of 24 October 1995 on the Protection of Individuals with Regard to the Processing of Personal Data and on the

Free Movement of such Data. Official Journal of the European Communities (1995), p. 31. <http://158.169.50.95:10080/legal/en/dataprot/directiv/directiv.html>

Eli Pariser : The Filter Bubble : What the Internet Is Hiding from You. Penguin Press, New York, 2011

Eremeev, A. P.; Vagin, N. V. (2011): Common Sense Reasoning in Diagnostic Systems, Efficient Decision Support Systems - Practice and Challenges From Current to Future. InTech, S. 100-120

Everitt , B. S. : Cluster analysis . London : Edward Arnold, 1993

Felfering, A., & Burke, R. (2008). Constraint-based Recommender Systems Technologies and Research Issues. Technologies and Research Issues

German Teleservices Data Protection Act., 1997, http://www.datenschutz-berlin.de/recht/de/rv/tk_med/iukdg_en.htm#a2

Goldberg, D.; Nichols, D.; Oki, B. M.; Terry, D. (1992): Using collaborative filtering to weave an information tapestry. Communications of the ACM, 35(12), 61–70

González, G., López, B., & de la Rosa, J. L. L. (2004). Managing emotions in smart user models for recommender systems. n Proceedings of 6th International Conference on Enterprise, S. 187-194

Good, N., Schafer, J., Konstan, J., Borchers, A., Sarwar, B., Herlocker, J. & Riedl, J. (1999). Combining Collaborative Filtering with Personal Agents for Better Recommendations. Proceedings of AAAI, (Vol. 35), 439–446

Google, <https://developers.google.com/glass/design/principles>, 28.05.2015

Gupta, D.; Digiovanni, M.; Narita, H.; & Goldberg, K.: Jester 2.0. (1999). A New Linear-Time Collaborative Filtering Algorithm Applied to Jokes. Workshop on Recommender Systems Algorithms and Evaluation, 22nd International Conference on Research and Development

Gupta, P.; Goel, A.; Lin, J.; Sharma, A.; Wang, D.; Zadeh, R. (2013). WTF the Who to Follow Service at Twitter. In D. Schwabe, V. Almeida, H. Glaser, R. Baeza-Yates, & S. Moon (Eds.), Proceedings of the 22nd international conference on World Wide Web - WWW '13 (pp. 505–514). New York, New York, USA: ACM Press.

Hagen, P. R., Manning, H., and Souza, R.: Smart Personalization. Forrester Research, Cambridge, MA (1999).

Hof, R., Green, H., and Himmelstein, L.: Now it's YOUR WEB. Business Week, October 5, (1998) 68-75

Horton, W. K. (1994). *The icon book: visual symbols for computer systems and documentation*. New York: J. Wiley.

- Iyengar, S. S.; Lepper, M. R.: When Choice Is Demotivating: Can One Desire Too Much of a Good Thing? *Journal of Personality and Social Psychology* (76:6), 2000, S. 995-1006
- Jannach, D.; Zanker, M.; Felfernig, A.; & Friedrich, G. (2011). Recommender systems: An introduction. *Safari Tech Books Online*. Cambridge: Univ. Press. Retrieved from <http://proquest.safaribooksonline.com/9780521493369>
- Kavassalis, P., Spyropoulou, N., Drossos, D., Mitrokostas, E., Gikas, G., and Hatzistamatiou, A. 2003. "Mobile Permission Marketing: Framing the Market Inquiry," *International Journal of Electronic Commerce* (8:1), S. 55-79
- Klahold, A.: Empfehlungssysteme, Recommender Systems - Grundlagen, Konzepte und Lösungen, 2009
- Kobsa, A., Koenemann, J. & Pohl, W. (2001). Personalized Hypermedia Presentation Techniques for Improving Online Customer Relationships. *The Knowledge Engineering review*, (16), S. 111-155
- Kobsa, A. : Tailoring Privacy to Users' Needs. 8th Conference on User Modeling, 2001
- Kobsa, A. : Privacy-enhanced web personalization. In: Bruslikovsky, P.; Kobsa, A.; Neijdl, W. (eds.) *The Adaptive Web*, S. 628-670. Springer Verlag, Berlin, Heidelberg 2007
- Konstan, J. A.; Riedl, J. (2012): Recommender systems: from algorithms to user experience. In: *User Modeling and User-Adapted Interaction*, Volume 22, Issue 1, S. 101-123
- Kreuter M. Towards more effective health communication: comparing effects of tailored, personalized and untailored messages in a randomized trial. Annual Meeting of the American Public Health Association. Indianapolis, IN, 1997.
- Kreuter, M. W., Farrell, D., Olevitch, L. and Brennan, L. (1999) *Tailored Health Messages: Customizing Communication with Computer Technology*. Lawrence Erlbaum, Mahwah, NJ.
- Lamche, B., Pollok, E., Wörndl, W., & Groh, G. (2014). Evaluating the Effectiveness of Stereotype User Models for Recommendations on Mobile Devices. In *UMAP Workshops*.
- Lee, Y. E.; Benbasat, I. 2003. "Interface Design for Mobile Commerce," *Communications of the ACM* (46:12), S. 49-52
- Levin, I. P.; Gaeth, G. J.: How Consumers are Affected by the Framing of Attribute Information Before and After Consuming the Product, *Journal of Consumer Research* (15:3), 1988, S. 374-378
- Li, T.; Unger, T. : Willing to pay for quality personalization? trade-off between quality and privacy. *European Journal of Information Systems* 21(6), S. 621-642 (2012)

- Lim, K. H.; Benbasat, I.: The effect of multimedia on perceived equivocality and perceived usefulness of information systems, MIS Quarterly, v.24 n.3, S.449-471, Sep 2000
- Linden, G., Smith, B., & York, J. (2003). Amazon.com recommendations: Item-to-item collaborative filtering. IEEE Internet Computing, 7(1), 76–80
- Linden, G.; Hanks, S.; Lesh, N.: Interactive assessment of user preference models: the automated travel assistant. In: Proceedings of International Conference on User Modeling (UM'97), S. 67-78 (1997)
- Maes, P., Guttman, R. H., & Moukas, A. G. (1999). Agents that buy and sell. Communications of the ACM, 42(3), S. 81-ff
- Majid, A., Chen, L., Chen, G., Mirza, H. T., Hussain, I., & Woodward, J. (2013). A context-aware personalized travel recommendation system based on geotagged social media data mining. International Journal of Geographical Information Science, 27(4), S. 662–684
- McDonald, D. W.; Ackerman, M. S.: Expertise Recommender: A Flexible Recommendation System and Architecture. In: CSCW '00 Proceedings of the 2000 ACM conference on Computer supported cooperative work, S. 231-240, 2000
- McGinty, L.; Smyth, B. (2003): On the role of diversity in conversational recommender systems. The Fifth International Conference on Case-Based Reasoning, S. 276–290
- McNee, S.M., Riedl, J., Konstan, J.A. (2006). Being accurate is not enough: how accuracy metrics have hurt recommender systems. CHI Extended Abstracts, 1097–1101
- Miyahara, K.; Pazzani, M. J. (2000): Collaborative filtering with the simple Bayesian classifier. In Pacific Rim International conference on artificial intelligence, S. 679–689
- Musto, C. (2010). Enhanced vector space models for content-based recommender systems (S. 361). ACM Press. <https://doi.org/10.1145/1864708.1864791>
- Musto, C., Semeraro, G., Lops, P., & de Gemmis, M. (2013). Contextual eVSM: A Content-Based Context-Aware Recommendation Framework Based on Distributional Semantics. In C. Huemer & P. Lops (Hrsg.), E-Commerce and Web Technologies: 14th International Conference, EC-Web 2013, Prague, Czech Republic, August 27-28, 2013. Proceedings (S. 125–136). Berlin, Heidelberg: Springer Berlin Heidelberg.
- OECD: Recommendation of the Council concerning Guidelines governing the Protection of Privacy and Transborder Flows of Personal Data. Tech. rep. , Organization for economic Cooperation and Development (2013)
- Oppermann, R. : Adaptive User Support - Ergonomic Design of Manually and Automatically Adaptable Software, Lawrence Erlbaum Associates, Hillsdale, New Jersey, 1994

- Parikh, M., Fazlollahi, B., and Verma, S. "The Effectiveness of Decisional Guidance: An Empirical Evaluation," *Decision Sciences* (32:2), 2001, S. 303-331
- Peppers, D. and Rogers, M.: *The One to One Future: Building Relationships One Customer at a Time*. New York, N.Y.: Currency Doubleday, (1993)
- Peppers, D.; Rogers, M: *The One to One Future*, New York: Doubleday, 1997
- Pruitt, J.; Adlin, T. (2010): *The persona lifecycle: keeping people in mind throughout product design*. Morgan Kaufmann.
- Pu, P.; Chen, L.: Trust building with explanation interfaces. In E. Edmonds, D. Riecken, C. L. Paris, & C. L. Sidner (Eds.), *Proceedings of the 11th international conference on Intelligent user interfaces - IUI '06* (p. 93). New York, New York, USA: ACM Press, 2006
- Pu, P.; Chen, L.; Hu, R. (2011): A user-centric evaluation framework for recommender systems. In: *Proceedings of the Fifth ACM Conference on Recommender Systems, RecSys `11*, S. 157-164. ACM, New York, NY, USA (2011)
- Pu, P.; Chen, L. : Critiquing-based recommenders: survey and emerging trends. *User Modeling and User-Adapted Interaction*, Volume 22, Issue 1, S. 125-150, 2012a
- Pu, P.; Chen, L.; Hu, R. (2012b): Evaluating recommender systems from the user's perspective: survey of the state of the art. *User Modeling and User-Adapted Interaction*, 22 (4-5), S. 317-355
- Rashid, A. M., Albert, I., Cosley, D., Lam, S. K., McNee, S. M., Konstan, J. A., & Riedl, J. (2002). Getting to know you Learning New User Preferences in Recommender Systems. In K. Hammond, Y. Gil, & D. Leake (Eds.), *Proceedings of the 7th international conference on Intelligent user interfaces - IUI '02* (p. 127). New York, New York, USA: ACM Press
- REGULATION (EU) 2016/679 OF THE EUROPEAN PARLIAMENT AND OF THE COUNCIL of 27 April 2016 on the protection of natural persons with regard to the processing of personal data and on the free movement of such data, and repealing Directive 95/46/EC (General Data Protection Regulation)
- Resnick, P.; Iacovou, N.; Suchak, M.; Bergstrom, P.; Riedl, J. (1994): GroupLens an open architecture for collaborative filtering of netnews. In J. B. Smith, F. D. Smith, & T. W. Malone (Eds.), *Proceedings of the 1994 ACM conference on Computer supported cooperative work - CSCW '94* (S. 175–186). New York, New York, USA: ACM Press.
- Resnick, P., & Varian, H. R. (1997). Recommender systems. *Communications of the ACM*, 40(3), 56–58
- Rich, E. : Building and Exploiting User Models. In: Proc. of Sixth International Joint Conference on Artificial Intelligence. (1979a) 720-722
- Rich, E. (1979b). User Modeling via Stereotypes*. *Cognitive Science*, 3(4), 329–354. https://doi.org/10.1207/s15516709cog0304_3

- Schafer, J. B., Konstan, J., and Riedl, J.: Recommender Systems in E-Commerce. ACM Conference on Electronic Commerce (EC99), Denver, CO, (1999) 158-166
- Schiaffino, S.; Amandi, A.: User - interface agent interaction: personalization issues, International Journal of Human-Computer Studies, v.60 n.1, S.129-148, January 2004
- Shardanand, U.; Maes, P. : (1995). Social information filtering: Algorithms of automating „word of mouth“. CHI '95: Proc. of the SGCHI Conf. on Human factors in Computing Systems, 210–217
- Sinha, R.; Swearingen, K. (2002). The role of transparency in recommender systems. In L. Terveen & D. Wixon (Eds.), CHI '02 extended abstracts on Human factors in computing systems - CHI '02 (p. 830). New York, New York, USA: ACM Press
- Skinner CS, Strecher VJ, Hopers H. Physicians' recommendations for mammography: do tailored messages make a difference? Am J Public Health 1994;84(1): S. 43–49
- Slovic, P. : The Construction of Preferences, American Psychologist, (50:5), 1995, S. 364-371
- Stewart, D. W., and Pavlou, P. A. 2002. “From Consumer Response to Active Consumer: Measuring the Effectiveness of Interactive Media,” Journal of the Academy of Marketing Science (30:4), S. 376-396.
- Sutanto, J., Palme, E., Tan, C. H., & Phang, C. W. (2013). Addressing the Personalization-Privacy Paradox: An Empirical Assessment from a Field Experiment on Smartphone Users. Mis Quarterly, 37(4), 1141-1164
- Toch, E.; Wang, Y.; Cranor, L. F. : Personalization and privacy: A survey of privacy risks and remedies in personalization-based systems. User-Modeling and User-Adapted Interaction 22(1-2), S. 203-220 (2012)
- Tsang, E. (1993). Foundations of Constraint Satisfaction
- van Krevelen, D.; Poelman, R.: A Survey of Augmented Reality Technologies, Applications and Limitations. In: The International Journal of Virtual Reality 9 (2010), Nr. 2, S. 1–20
- Wang, W.; Benbasat, I.: Trust In and Adoption of Online Recommendation Agents, Journal of the Association for Information Systems (6:3), 2005, Article 4
- Watson, R. T., Pitt, L. L., Berthon, P., and Zinkhan, G. M. 2002. “U-Commerce: Expanding the Universe of Marketing,” Journal of the Academy of Marketing Science (30:4), S. 333-347
- Xu, H. 2007. “The Effects of Self-Construal and Perceived Control on Privacy Concerns,” in Proceedings of 28th International Conference on Information Systems, December 9-12, Montreal, Canada
- Yaniv, I. : Receiving Other People's Advice: Influence and Benefit, Organizational Behavior and Human Decision Processes (93:1), 2004, S. 1-13

Zhang, A.; Bhamidipati, S.; Fawaz, N.; Kveton, B. : Priview: Media consumption and recommendation meet privacy against interference attacks. In: W2SP (2014)

Zhao, Q., Adomavicius, G., Harper, F. M., Willemsen, M., & Konstan, J. A. (2017). Toward Better Interactions in Recommender Systems: Cycling and Serpantining Approaches for Top-N Item Lists.

12 Anhang

12.1 Benutzer-Modell des Gesamtkonzepts

Jeder Benutzer bekommt bei der Benutzerinitialisierung zu Beginn einen Stereotypen zugewiesen. Dieser Stereotyp ist prinzipiell ein im Vorfeld befülltes Benutzer-Modell, das zum Benutzerprofil des initialisierten Benutzers wird.

Das Benutzerprofil wird anhand explizit als auch implizit angegebener Daten befüllt. Explizite Daten werden aus konkreten Angaben des Benutzers bspw. durch konkrete Angaben in Formularen oder durch Bewertungen bezogen. Implizite Daten werden aus dem Benutzerverhalten abgeleitet.

Die Bezugsquellen für diese Daten können Modulintern liegen (bspw. von Sensoren oder eigenen Berechnungen) oder von externen Modulen innerhalb und außerhalb des Assistenzsystems RadAR+.

Kürzel:

IFR: Indoor- und

Fernrouting

Bezeichnung der Daten	implizit (i)/explizi- t (e)	Quelle	Erfassung	Nutzung	Wertebereich	Notiz	Relevanz für Recommende- r System (0 [nicht relevant] - 10 [sehr relevant])

Allgemeine Präferenzen und Interessen*	explizit	intern	Training bei der Zuordnung zu direkte Referenz auf z. B. Vorliebe für 10 Benutzerinitialisierung Stereotypen; besonders Items mit ggf. bspw. Essen und wichtig für die Ranking-Aggregat Trinken können Adaptivität des (z. B. bestehen aus anhand der Benutzer-Modells Häufigkeit der Eigenschaften aus)
	implizit	intern	Mapping von Content-based Filtering Besuche, Dauer der dem Item-Model 10 Bewegungsprofil auf gegebene Items Besuche oder abgeleitet werden explizitem Rating) Weitere Eigenschaften: Musik, Sport, Technik, Kultur & Unterhaltung, Wissenschaft
Alter/Geburtsdatum*	explizit	intern	Angabe bei Berücksichtigung bzgl. [1;100] Registrierung Altersbeschränkungen, Zuordnung zu Stereotypen

Bewegungsprofil	implizit	intern, wenn GPS verfügbar IFR sonst	GPS-Koordinaten ausgewählten Punkten (längere Aufenthalte an einer Position und Richtungswechsel) an einer Position und Ableitung, ob, wann Zeitstempel und wie häufig Items wahrgenommen wurden Ableitung Präferenzen anhand längerer Aufenthalte an Items	Zuteilung des Nutzers auf eine Vertrautheits-Klasse (Ableitung, ob, wann Zeitstempel und wie häufig Items einer Assoziation zum entsprechenden Verkehrsknoten)	Ansammlung von Geokoordinaten mit zugehörigem Klasse Zeitstempel und einer Assoziation zum entsprechenden Verkehrsknoten		10
Geschlecht*	explizit	intern	Angabe bei Registrierung	Zuordnung zu Stereotypen	männlich, weiblich		10

Verautheit Umgebung	mit der Umgebung	implizit	intern	Bewegungsprofil	Zuordnung Vertrautheitsklassen	zu Vertrautheitsklassen:	10
------------------------	------------------------	----------	--------	-----------------	-----------------------------------	-----------------------------	----

Benutzer in größeren
Zeitabständen
bereits häufiger an
einem
Verkehrsknoten
aufgehalten hat.
Seine Aufenthalte
waren jedoch sehr
kurz oder das
Bewegungsprofil für
den entsprechenden
Ort besagt, dass die
Umgebung von ihm
noch kaum erkundet
wurde.

- Klasse III: In
größeren
Zeitabständen
bereits mehrfach
besuchter
Verkehrsknoten und

Kenntnis über die Umgebung
In dieser Klasse wird angenommen, dass sich der Benutzer in größeren Zeitabständen bereits häufiger an einem Verkehrsknoten aufgehalten hat. Das entsprechende Bewegungsprofil lässt darauf schließen, dass die Umgebung bereits erkundet wurde.
Wahrgenommen wurden jedoch noch kaum Items.

- Klasse IV: Häufig

oder regelmäßiger
besuchter
Verkehrsknoten und
gute Kenntnis der
Umgebung
Dieser Klasse
werden diejenigen
Orte zugeordnet, die
der Benutzer in
regelmäßigen
Zeitabständen
besucht. Darunter
fallen auch Orte, die
der Benutzer in
größeren
Zeitabständen
besucht hat und
anhand des
Bewegungsprofils
angenommen
werden kann, dass er

über gute Kenntnis
seiner Umgebung
verfügt.

Historie zuletzt besuchter Orte bei Reisen	implizit	intern	<p>Geht aus Berücksichtigung von Items</p> <p>Bewegungsprofil bereits explizit</p> <p>sowie expliziten gesuchten Items bei Bewertungen hervor bspw.</p> <p>Nach Reiseabschluss Auto vervollständigt werden das n oder Suchen</p> <p>Bewegungsprofile auf die</p> <p>Geokoordinaten heruntergeladener</p> <p>Items gemappt und abgeglichen. Dadurch wird berechnet, welche Items ein Benutzer genutzt hat bzw. nicht benutzt, aber wahrgenommen hat.</p>		10
initiale, explizite Auswahl von Domänen, aus denen Empfehlungen	explizit	intern	<p>Training bei der Eingrenzung von Liste von Domänen,</p> <p>Profil-Initialisierung Empfehlungen und die dem Training Erstellung einer entsprechende</p>		10

gemacht werden sollen				TrainingsSets; Suche nach Items, Empfehlungen befriedigend sind	Gewichtungen beinhalten. Diese Gewichtungen beschreiben die Relevanz für den entsprechenden Benutzer		
Nutzergruppe*	explizit	intern	Angabe bei Registrierung	Student, Rentner,...Potentielle Interessen über Stereotypen erkennen	Student, Rentner	Angabe zu Beginn	10
Präferenzen bezüglich Items	explizit	intern	aus explizitem Feedback (z. B. Bewertungen bezogen)	Kriterium Generieren Empfehlungen	beim Alle möglichen von Items, wie sie im Item-Modell beschrieben werden		10
	implizit	intern	implizit durch bspw. Bewegungsprofile (häufig besuchte Orte)	Kriterium Generieren Empfehlungen	beim Alle möglichen von Items, wie sie im Item-Modell beschrieben werden		10

Suchhistorie	explizit	intern	Speichern der Berücksichtigung von Items Schlagworte und des bereits explizit Settings bei gesuchten Items bei Suchanfragen bspw. Autovervollständigungen oder Suchen Kriterium beim Generieren von Empfehlungen			10
Verhaltensmuster	implizit	intern	Entscheidungen aus Unterstützung bei Regel-System der Historie Entscheidungen und kontinuierlich Verbesserung der kontextabhängig Empfehlungen auswerten			10
geforderte Mindestaufenthaltsdauer an Items	explizit	intern	[min]	Pre-Filtering	[0-60]	Als Standard voreingestellt, aber vom Benutzer individuell abänderbar

aktuelle Gehgeschwindigkeit	implizit	intern, wenn GPS unter verfügbar; IFR sonst	Bewegungsprofil, GPS-Messungen unter verfügbar; Berücksichtigung der Stresssituation?	Vergleich von normaler Gehgeschwindigkeit zur aktuellen; Zeit	km/h		10
Veganer*	explizit	intern	Angabe in Benutzereinstellungen möglich	Filtern für die Domäne Gastronomie			10
Vegetarier*	explizit	intern	Angabe in Benutzereinstellungen möglich	Filtern für die Domäne Gastronomie			10
Freizeitgestaltung	explizit	intern	Teil des Trainings zur Benutzerinitialisierung	Zuordnung Stereotypen	Sport, Film, Lesen,...		9
Pufferzeiten vor Abfahrt eines Verkehrsmittels	explizit	intern	Explizite Angabe in den Einstellungen	Der Benutzer kann Pufferzeiten einstellen, die den zeitlichen Umfang beschrieben, den er vor Abfahrt eines Verkehrsmittels am	[2, 5, 10, 15] min		9

				entsprechenden Ort sein möchte.			
dauerhafte/temporäre Behinderung(en)*	explizit	intern	Abfrage ob der Nutzer Einschränkungen hat. Wenn ja, welche Art der Einschränkung bringt diese mit sich	Einbezug bei der Routenplanung und bei Berechnung der Empfehlungen der Rollstuhlfahrer Rollstuhlfahrer mit Hilfsperson	Einschränkung beim Gehen, Sehen oder Hören		9
Einstellung Zeitpunkten Warnungen	von explizit für implizit	intern	explizite Angaben Bewegungsprofil	Festlegung der [min] Zeitpunkte, wie viele Minuten vor einem Ereignis eine Warnung eingeblendet werden soll	[min]		8
generelle Gehgeschwindigkeit	implizit	intern	Bewegungsprofil, GPS-Messungen unter Berücksichtigung der Zeit. Unterstützend zur aktuellen	Einbezug zur Berechnung des erreichbaren Umkreises	km/h	Gruppierung in minimal, durchschnittlich und maximal zur Berechnung von worst-, average- und	8

			Gehgeschwindigkeit			best-case Fortbewegungszeiten Die Gehgeschwindigkeit soll im Vorfeld eintrainiert werden. Bei der Bewegung während der Reise wird die aktuelle Gehgeschwindigkeit mit den hinterlegten Gehgeschwindigkeiten abgeglichen	
Raucher*	explizit	intern	Wird bei der Besondere Registrierung erfasst	Berücksichtung von Raucherlokalen	ja/nein		8
Gewünschte Informationsmenge bzgl. der Detailansicht von Items	implizit	intern	Abgeleitet aus Bewegungsprofil	Tailoring der Detailinformationen	(unbekannte Strecke/bekannte Strecke), Modus (Touristenmodus / Alltagsmodus)		7

					(Persona Schubert)	Lisa	
Reisegrund	explizit	IFR	Bezug von IFR		dienstlich privat	oder	7
Sprache*	explizit imlizit	intern	voreingestellt ist die Systemsprache Systemsprache; explizites Ändern der Sprache möglich Sprache wird bei registrierung erfragt		Alle zu berücksichtigenden Sprachen		6
Präferenzen gegenüber Warnungen	explizit	intern	Angabe in Explizites Aktivieren Benutzereinstellung und Deaktivieren von n möglich	Explizites Aktivieren Benutzereinstellung und Deaktivieren von einzelnen Warnungen			6
Religion	explizit	intern	Angabe in Berücksichtigung bei bspw. christlich, Benutzereinstellung Empfehlungen von muslimisch n möglich Anbetungsstädten	Berücksichtigung bei bspw. christlich, Empfehlungen von muslimisch Anbetungsstädten			5
Wege, die gemieden werden sollen	explizit	intern IFR	Constraint, die der Benutzer in seinen Einstellungen festgelegt hat.	Orte, an denen der Benutzer nicht umsteigen möchte oder die er sogar gar nicht erst passieren möchte	intern, für Item-5 Bezogene Eigenschaften IFR für Wegbezogene		5

					Eigenschaften (bspw. keine Treppen, keine dunklen Räume,...)		
Orte, die gemieden werden sollen	explizit	intern	Constraint, die der Benutzer in seinen Einstellungen festgelegt hat.	Orte, an denen der Benutzer nicht verweile	Domänen auf flexibler Hierarchieebene	5	
Nutzererfahrung mit dem System	explizit	intern	Nutzungsdauer und Regelmäßigkeit Prozentualer Anteil genutzter Funktionen aus der Gesamtzahl angebotener Funktionen	Anzeigen/Ausblenden von Funktionen und Einstellungen	Anfänger, Profi	5	
Adaptives lernen (nicht) aktiviert	explizit	intern	Angabe in Benutzereinstellungsn möglich	(de-) aktivieren von adaptivem Lernen	ja/nein	Empfehlungssystem aus und nur Schlagwortsuche möglich, da sonst womöglich Reizüberflutung durch zu viele Items	4

Familienstand	explizit	intern	Angabe in Benutzereinstellungen möglich				4
Ethnischer Hintergrund	explizit	intern	Angabe in Berücksichtigung von Benutzereinstellungen möglich	bei bspw. chinesisch Empfehlungen für Gastronomien (z. B. halal, o. a.) und Aktivitäten/Orten (z. B. Moschee, Kirche am Flughafen)	Lässt zuverlässigen Schlüsse auf die Religion zu	keine	4
Wohnort*	explizit	intern	Angabe bei Registrierung	Ort (bei großen Städten wahrscheinlich keine Orientierungshilfen benötigt werden)	Adresse (PLZ, Ort, Stadtteil), and dem Land)		4
Bankinstitut	explizit	intern	Angabe in Benutzereinstellungen möglich	Priorisierung von Banken bzw. Geldautomaten, an denen der Nutzer keine Gebühren zahlen muss	An Verkehrsknoten sind meist EC-Geldautomaten und seltener von einzelnen Bankinstituten	Verkehrsknoten sind meist EC-Geldautomaten und seltener von einzelnen Bankinstituten	3

						Automaten	
Musikgeschmack	explizit	intern	Angabe in Berücksichtigung bei Benutzereinstellung Empfehlungen möglich			Sehr unwahrscheinlich, dass diese Faktoren bei der Generierung von Empfehlungen einfließen, da die meisten POI an Verkehrsknoten keine solch Zielgruppenspezifische Konzepte verfolgen	3
Name*	explizit	intern	Wird bei der Personalisierung Registrierung erfasst („Hallo XY,...“)				3
Preisvorstellungen/Budget	explizit	intern	Explizite Angabe in Berücksichtigung bei > 0 [€] den Einstellungen jeder Erzeugung von Domäne Empfehlungen				3
Sehschwäche	explizit	intern	Explizite Angabe in Entfernung von Dioptrien Schildern als Trigger für Einblendungen passt sich an die			Verstärkt akustische Signale verwenden	3

				Sehfähigkeiten des Benutzers an			
Höreinschränkung	explizit	intern	Explizite Angabe in den Einstellungen	akustisches Feedback ein/aus, Navigationsroute mit der möglichst besten dynamischen Beschilderung (Verspätungszeiten dann ersichtlich)	ja/nein	Verstärkt Signale verwenden	visuelle 3
Technikaffinität	explizit	intern	Explizite Angabe in den Einstellungen anhand Fragebogens zur Technikaffinität	Ein-/Ausblenden von Funktionen des Erklärungen zur Nutzung	z.B. Nutzung von Spracheingabe/ zur Sprachsteuerung ja/nein		1
Ängste	explizit	intern	Explizite Angabe in den Einstellungen	Ausschließen von Items, die dem Benutzer Angst einflößen	Liste von Phobien mit Ranking, das aussagt, inwieweit diese Angst ein Ausschluss-		1

				Kriterium für ein Item ist	
Ad-hoc Einschränkung	explizit		Routenberechnung	Gepäck, Fahrradmitnahme, Baby- oder Kleinkindausstattung/ z.B. Kinderwagen (Personen Martina Grundler)	

Art des Tickets	explizit	IFR	Berücksichtigung von Fernbus Mehrkosten für Nahverkehr zusätzliche Tickets bei Bahnticket der Generierung von Fernverkehr Empfehlungen Bahnticket Bahn- Flugticket	Beinhaltet das Ticket Hin- und Rückreise, so kann über die Aufenthaltsdauer und der wahrscheinliche Umfang des Gepäcks geschätzt werden. Flüge: <i>Bei inner europäischen Flügen kann (sofern Zielflughafen kein klassisches Urlaubsziel ist) voreingestellt werden: online Check-In, ohne Gepäckaufgabe</i>
-----------------	----------	-----	---	--

Falls der Zielflughafen häufig für einen klassischen Städtetrip oder Urlaub angeflogen wird, soll angenommen werden, dass Gepäck aufgegeben werden muss

Bei *außereuropäischen* Flügen kann Gepäckaufgabe angenommen werden

Darüber hinaus kann für Benutzer, die sich sicher im Umgang mit Reise-Apps sind, der Online Check-In

						vorausgewählt werden. Bei Nutzern, die angeben keine Erfahrung im Umgang mit Reise-Apps zu haben, kann davon ausgegangen werden, dass die Gepäckaufgabe vorausgewählt werden.	
Der visuell/akustische Informationsgrad passt sich automatisch dem Erfahrungsgrad des	implizit	intern		Einstellung der Informations-Fülle (Tailoring)	minimal, default	Der Erfahrungsgrad ergibt sich aus Informationen der Nutzer und des	

Nutzers an.					Kontextmodells. (S-N-01)	
Mobilitätsbezogene Präferenzen	explizit	IFR		Bei der Routenplanung favorisiertes zu berücksichtigen Verkehrsmittel, Verspätungstoleranz		
nur Handgepäck		IFR		Gepäckaufgabe notwendig oder nicht	ja/nein	
Via-Wunschhaltestellen	explizit					
Wird Online Check-In genutzt		IFR		Berechnung der benötigten Aufenthaltszeit am Flughafen	ja/nein	
Zustieg an der Station	explizit	IFR			keine Stufe, Max. eine Stufe, keine Treppe, keine Rolltreppe, kein Aufzug, min. 90 cm Durchgangsbreite	
Zustieg zum Fahrzeug	explizit	IFR			keine Stufe, max. eine Stufe, min. 90 cm Durchgangsbreite	

physische Verfassung			anhand von Berücksichtigung bei Gehgeschwindigkeit, der Routenplanung zu Alter und weitere POIs demographischen Daten	Problem: Wie kann ausgemacht werden, welche Auswirkungen eine Änderung der Physischen Verfassung auf die Reise hat? Explizites Abfragen nach Verletzungen wird wahrscheinlich aufwändig zu bedienen. Zusätzlich sind die mit einer Einschränkung verbundenen Implikationen nicht vollständig abzudecken.
Erinnerungsvorgaben start-trip, on-trip	explizit	intern	Festlegung des [m] oder [min] vor zeitlichen Triggers für einer empfohlenen Einblendungen Handlung	

12.2 Item-Modell des Gesamtkonzepts

Daten	implizit (i)/explizit (e)	Quelle	Erfassung	Nutzung	Bezugsquelle	Wertebereich	Notiz	Relevanz für Recommander System (0 [nicht relevant] - 10 [sehr relevant])			
Geoposition/Standort	explizit	Google Maps, OpenStreetMaps, o. a.	explizite Angabe	Berechnung der Entfernung und der Erreichbarkeit für die Prognose von Weg- und Aufenthaltszeiten	externer Dienst, bspw. OpenStreetMaps	(lat, long) und jeweilige Dauern		10			
Erreichbarkeit	implizit	IFR	aktuelle Verkehrs situation und	Berücksichtigung bei der Kalkulation	externer Dienst, bspw. OpenSt	welche Verkehrsmittel, in welcher	evtl. bereits möglich über entsprechen	10			

			mögliche Routen finden und die Wegzeiten berechnen	on der Relevanz	reetMaps	Zeit	de API			
Öffnungszeiten	explizit	Google Maps, OpenStreetMaps, o. a.	explizite Angabe	geöffnet/geschlossen an Tagen zur Uhrzeiten	externer Dienst, bspw. OpenStreetMaps	Uhrzeiten an Wochentagen		10		
	implizit	Abgleich mit verschiedenen Bewegungsprofilen verschiedener Nutzer.	Approximierbar durch Frequenteren anhand von Bewegungsprofilen und Aufenthaltsdauern (s. Yelp!); konkrete Angaben							
Altersbegrenzung	explizit	Google Maps,	explizite Angabe	ja/nein	externer Dienst,	Jahre		10		

			OpenStreetMaps, o. a.			bspw. OpenStreetMaps					
Altersdurchschnitt der Besucher	explizit	Google Maps, OpenStreetMaps, o. a.	explizite Angabe	Berechnung der Relevanz des Items für entsprechende Benutzer-Gruppe	externer Dienst, bspw. OpenStreetMaps	Jahre	Soll anhand der vorstrukturierten Items erfassbar sein Durchschnittliches Alter von Nutzern, die bereits an dem Ort waren unter Berücksichtigung der Aufenthaltsdauer	9			
Produktivitäts-Item	explizit	Google Maps, OpenStreetMaps, o. a.	explizite Angabe	Flag für Items, die immer angezeigt werden sollen. Die Items in dieser Klasse werden	externer Dienst, bspw. OpenStreetMaps	ja/nein		10			

				auch im Modus I (Effizienz-Modus) eingebunden, sofern sie auf direktem Wege zum nächsten Verkehrsmittel liegen.				
Barrierefreiheit	explizit	Google Maps, OpenStreetMaps, o. a.	explizite Angabe	ja/nein	externer Dienst, bspw. OpenStreetMaps	ja/nein		8
Stromanschluss	explizit	Google Maps, OpenStreetMaps, o. a.	explizite Angabe	ja/nein	externer Dienst, bspw. OpenStreetMaps	ja/nein		
WLAN	explizit	Google Maps, OpenStreetMaps,	explizite Angabe	ja/nein	externer Dienst, bspw. OpenSt	ja/nein		

		o. a.			reetMa ps						
Wetterabhängigkeit	expli zit	Google Maps, OpenStre etMaps, o. a.	explizite Angabe	Post- Filtering	externe Dienst, bspw. OpenSt reetMa ps	ja/nein		7			
Draußen/Drinnen	expli zit	Google Maps, OpenStre etMaps, o. a.	explizite Angabe	Post- Filtering	externe Dienst, bspw. OpenSt reetMa ps	ja/nein		7			
Außenbereich	expli zit	Google Maps, OpenStre etMaps, o. a.	explizite Angabe	Post- Filtering	externe Dienst, bspw. OpenSt reetMa ps	ja/nein		7			
Domänen							Die Relevanz der einzelnen Sub- Domänen ist dynamisch und abhängig von der	10			

		Zitrone	
		...	
Fruchtsäfte	Apfelsaft		
	Orangensaft		
	...		
Alkoholische Getränke	Bier	Pils	
		Hefeweizen	
		Dunkles Hefeweizen	
		Helles	
		Rauchbier	
		„“	
	Schamwein	Sekt	
Wein	Rotwein	Cabernet Sauvignon	

							Bordeaux
							...
	Weißwein	Grauburgunder	Riesling				
							...
	Rosé						...
	Schnaps	Korn					
							...
Heiße tränke	Kaffe e	Café Crème					
		Cappuccino					
		Espresso					
		America no					
		Latte Macchiato					
		Filter-Kaffee					
		Mokka Kaffee					
		...					

							Tee	Schwarztee
							Früchtete	
							e	
							...	
						Kaka		
						o		
<i>Cafés</i>	Bewirtungsstätten mit Verkauf von Speisen, insbesondere von Konditoreierzeugnissen und sonstigen kalten Speisen, im allgemeinen zum Verzehr an Ort und Stelle, sowie damit verbundener Verkauf von Getränken, unter	Raucherbereich Raucherrlokal Toiletten Sitzplätze Stehplätze Sitzplätze						
			Essen	Süßspeisen	Kuchen	Apfelküchen		
						Zwetschgenküchen		
						...		
						Waffeln	mit Puderzucker	
							mit	

							Schokoladensauce	
					Kekse	Schokoladenkekse		
						...		
					Trinken	Alkoholfreie Getränke	Wasser	mit Kohlensäure
								ohne Kohlensäure
						Limonade	Orange	
							Rhabarber	
							Zitrone	
							...	
						Fruchtsäfte	Apfelsaft	
							Orangensaft	
							...	
						Akkoholische Getränke	Bier	Pils
							Hefeweizen	

		zen	
Dunkles			
Hefeweizen			
Helles			
Rauchbier			
„“			
Schamwein	Sekt		
		...	
Wein	Rotwein	Cabernet	Sauvignon
			Bordeaux
			...
Weißwein	Grauburgunder		
		Riesling	
		...	
Rosé			
			...
Schnaps	Korn		

				ge Speisen sowie Getränke an bestimmte Einrichtungen (z.B. Fluggesellschaften, "Essen auf Rädern") oder Personengruppen und für bestimmte Anlässe (z.B. Hochzeiten und andere Feiern oder Feierlichkeiten).				
				<i>Discotheken und Tanzlokale</i>	Lokale mit Tanzmusik, verbunden mit Verkauf von Getränken, im allgemeinen zum			

					Verzehr an Ort und Stelle, unter Umständen auch mit begleitenden Unterhaltungsprogramm.			
				<i>Eisdielen</i>	Bewirtungsstätten, von denen insbesondere Speiseeis sowie ein eng begrenztes Sortiment von Getränken zum Verzehr an Ort und Stelle oder zum Mitnehmen abgegeben werden.			
				<i>Imbisshallen</i>	Bewirtungsstätten, die Rauchfrei lokal			

keine oder wenig Sitzgelegenheiten aufweisen und von denen ein eng begrenztes Sortiment von Speisen mit und ohne Ausschank von Getränken zum Verzehr an Ort und Stelle oder zum Mitnehmen abgegeben wird, z.B. Würstchensstände.	Raucherbereich Toiletten Sitzplätze Stehplätze					
	Essen	glutenfrei lactosefrei halal bio vegetarisch vegane Gerichte				
	Fischgerichte	Warme Speisen	Fischfilet Ganze Forelle Fischstäbchen Fischsuppe			

		pe	
Kalte Speisen	Carpaccio		
	Sushi		
	...		
Fleischgerichte	Warme Speisen	Schnitzel	
		Hühnchencurry	
		...	
Kalte Speisen	Carpaccio		
	Vitello Tonato		
	...		
Süßspeisen	Kuchen	Apfelküchen	
		Zwetschgenkuchen	
		...	
Waffeln	mit Puderzucker		
	mit		

			Schokola densauce	
			...	
	Kekse	Schokola denkekse		
		...		
Trinke n	Alkoho lfreie Geträn ke	Wass er	mit Kohlensä ure	
			ohne Kohlensä ure	
Limo nade		Orange		
		Rhabarb er		
		Zitrone		
		...		
Fruch tsäfte		Apfelsaft		
		Orangen saft		
		...		
Akohol ische Geträn ke	Bier	Pils		
		Hefeweい zen		

	Dunkles Hefeweizen	
	Helles	
	Rauchbier	
	„“	
Schamwein	Sekt	
	...	
Wein	Rotwein	Cabernet Sauvignon
		Bordeaux
		...
Weißwein	Grauburgunder	
		Riesling
		...
Rosé		
		...
Schnaps	Korn	
	...	

						Heißge tränke	Kaffe e	Café Crème	
								Cappuci no	
								Espresso	
								America no	
								Latte Macchiat o	
								Filter- Kaffee	
								Mokka Kaffee	
								...	
						Tee		Schwarz tee	
								Früchtete e	
								...	
						Kaka o			
			<i>Kantine</i>	Verpflegun gseinrichtun g mit Verkauf von Speisen und Getränken, gewöhnlich					

				zu ermäßigte n Preisen, an bestimmte Personen gr uppen durch: Sport-, Betriebs- und Bürokantine n; Schulkantin en und - küchen; Menschen; Messen und Kantinen für Armeeange hörige.			
				<i>Restaura nts</i>	Bewirtungs stätten mit Verkauf von Speisen, im allgemeinen zum Verzehr an Ort und Stelle,	Rauche rlokal Preisni veau Rauche rbereic h Terrass e Toilett	

sowie damit verbundene m Verkauf von Getränken, unter Umständen auch mit begleitende m Unterhaltun gsprogram m.	en
	Biergar ten
	regiona le Küche
	FastFo od
	SlowF ood
	Sitzplätz e
	Stehplätz e
	chinesi sch
	deutsch
	französ isch
	griechi sch
	italieni sch
	türkisc h
	japanis ch
	chinesi sch
	spanisc

h			
Essen	glutenfrei		
	lactose frei		
	bio		
	vegetarisch		
	vegan		
	halal		
Fischgerichte	Warme Speisen	Fischfilet	
		Ganze Forelle	
		Fischstäbchen	
		Fischsuppe	
	
Kalte Speisen	Carpaccio		
		Sushi	
		...	
Fleischgerichte	Warme Speis	Schnitzel	

en			
	Hühnche ncurry		
	...		
Kalte Speis en	Carpacci o		
	Vitello Tonato		
	...		
Süßspe isen	Kuch en	Apfelkuc hen	
		Zwetsch genkuch en	
		...	
Waffe ln	mit Puderzuc ker		
	mit Schokola densauce		
	...		
Kekse	Schokola denkekse		
	...		
Trinke n	Alkoho lfreie Geträn	Wass er	mit Kohlensä ure

ke	ohne Kohlensä ure		
	Limo nade	Orange	
		Rhabarb er	
		Zitrone	
		...	
	Fruch tsäfte	Apfelsaft	
		Orangen saft	
		...	
	Akohol ische Geträn ke	Bier	Pils
		Hefeweい zen	
		Dunkles Hefeweい zen	
		Helles	
		Rauchbie r	
		""	
	Schau	Sekt	

mwein			
Wein	Rotwein	Cabernet Sauvignon Bordeaux	
		...	
	Weißwein	Grauburgunder Riesling	
		...	
	Rosé		
		...	
Schnaps	Korn		
		...	
Heiße tränke	Kaffe e	Café Crème Cappuccino Espresso Americano Latte	

									Macchiat o
									Filter- Kaffee
									Mokka Kaffee
									...
							Tee	Schwarztee	
								Früchtete	
								e	
								...	
						Kaka			
						o			
<i>Schankwi rtschaften</i>	Bewirtungs stätten mit Ausschank von Getränken zum Verzehr an Ort und Stelle.	Rauche rlokal							
		Preisni veau							
		Rauche rbereic h							
		Terrass e							
		Toilett en							
		Biergar ten							
		regiona le Küche							

FastFood				
SlowFood				
Sitzplätze				
Stehplätze				
chinesisch				
deutsch				
französisch				
griechisch				
italienisch				
türkisch				
japanisch				
chinesisch				
spanisch				
Essen	glutenfrei			
	lactosefrei			
	bio			

vegetar isch			
vegan			
halal			
Fischg erichte	Warm e Speis en	Fischfilet	
		Ganze Forelle	
		Fischstäb chen	
		Fischsup pe	
	
Kalte Speis en	Carpacci o		
	Sushi		
	...		
Fleisch gericht e	Warm e Speis en	Schnitzel	
		Hühnche ncurry	
	...		
Kalte Speis en	Carpacci o		

			en		
			Vitello Tonato		
			...		
Süßspeisen	Kuchen	Apfelkuchen			
		Zwetschgenkuchen			
		...			
	Waffeln	mit Puderzucker			
		mit Schokoladensauce			
		...			
	Kekse	Schokoladenkekse			
		...			
Trinken	Alkoholfreie Getränke	Wasser	mit Kohlensäure		
			ohne Kohlensäure		
	Limonade	Orange			

		Rhabarb er	
		Zitrone	
		...	
	Fruch tsäfte	Apfelsaft	
		Orangen saft	
		...	
Akohol ische Geträn ke	Bier	Pils	
		Hefeweい zen	
		Dunkles Hefeweい zen	
		Helles	
		Rauchbie r	
		„“	
Schau mwei n	Sekt		
		...	
Wein	Rotwein	Cabern et	
		Sauvig	

							non
							Bordeaux
							...
					Weißwein	Grauburgunder	
						Riesling	
						...	
					Rosé		
						...	
				Schnaps	Korn		
						...	
Heiße tränke		Kaffe e	Café Crème				
			Cappuccino				
			Espresso				
			Americano				
			Latte Macchiato				
			Filter-Kaffee				
			Mokka Kaffee				

									...	
									Tee	Schwarztee Früchtete ...
									Kaka o	
<i>Trinkhallen</i>	Bewirtungsstätten, die keine oder wenig Sitzgelegenheiten aufweisen und von denen ein eng begrenztes Sortiment von Getränken abgegeben wird.	Essen	Kalte Speisen	Belegte Brötchen						
				Süßes Gebäck						
				...						
			Warme Speisen	Bockwurst						
				Börek						
				Lamachun						
				Pita						
				Pizza						
				...						
				Süßigkeiten	Kaugummi					
					Schokoriege	Snickers				

Trinke n	Alkoho lfreie Geträn ke	Wass er	mit Kohlensä ure	
			ohne Kohlensä ure	
Limo nade		Orange		
		Rhabarb er		
		Zitrone		
		...		
Fruch tsäfte		Apfelsaft		
		Orangen saft		
		...		
Akohol ische Geträn ke	Bier	Pils		
		Hefeweizi en		
		Dunkles Hefeweizi en		
		Helles		

		Rauchbie r	
		„	
Schau mwei n	Sekt		
	...		
Wein	Rotwein	Cabern et	
		Sauvig non	
		Bordea ux	
	...		
Weißwei n	Graubu rgunde r		
		Rieslin g	
	...		
Rosé			
	...		
Schna ps	Korn		
	...		
Heiße tränke	Kaffe e	Café	
		Créme	
		Cappuci no	

									Espresso	
									America no	
									Latte Macchiato	
									Filter- Kaffee	
									Mokka Kaffee	
									...	
								Tee	Schwarzt ee	
									Früchtete e	
									...	
								Kaka o		
Arten von Shopping Möglichkeiten klassifiziert nach Google (https://support.google.com/merchants/answer/6324436?hl=de)	explizit	Google Maps, OpenStreetMaps, o. a.	Explizite Angabe	Kategorisierung von Shopping-Möglichkeiten	bezogen auf den Flughafen Frankfurt Fraport	Baby & Kleinkind Bekleidung & Accessoires Bürobedarf Elektronik Fahrzeuge & Teile				

						Für Erwachsene						
						Gesundheit & Schönheit						
						Heim & Garten						
						Heimwerkerbedarf						
						Kameras & Optik						
						Kunst & Unterhaltung						
						Medien						
						Möbel						
						Nahrungsmittel, Getränke & Tabak						
						Religion & Feierlichkeiten						
						Software						
						Spielzeug & Spiele						
						Sportartik						

						el					
						Taschen & Gepäck					
						Tiere & Tierbedarf					
						Wirtschaft & Industrie					
Finanzen nach OpenStreet Maps (https://wiki.openstreetmap.org/wiki/Map_Features#Financial)	explizit	Google Maps, OpenStreetMaps, o. a.	Explizite Angabe	Kategorisierung von Möglichkeiten Geld zu holen	bezogen auf den Flughafen Frankfurt Fraport	Geldautomat					
		Google Maps, OpenStreetMaps, o. a.				Bank					
		Google Maps, OpenStreetMaps, o. a.				Wechseltube					
Auszüge aus „Andere Annehmlichkeiten“ nach OpenStreet Maps (https://wiki.openstreetmap.org/wiki/Map_Features#Others)	explizit	Google Maps, OpenStreetMaps, o. a.	Explizite Angabe	Kategorisierung von anderen Möglichkeiten	bezogen auf den Flughafen	Coworking Space					
						Uhr					
						Gericht					
						Krypta					

			eiten	Frankfu rt Fraport	Botschaft						
					Feuerweh r						
					Friedhof						
					Fitnessstu dio						
					Internet						
					Café						
					Kneipp Becken						
					Marktplat z						
					Photoauto mat						
					Polizei						
					Anbetung sstätte	Moschee					
						(Kirche,					
						Synagoge					
					Briefkast en						
					Gefängni s						
					Dusche						
					Telefon						
					Toiletten						
					Wasserste lle						
Auszüge aus „Unterkünfte“ nach OpenStreet Maps	explizit	Google Maps,	Explizite Angabe	Kategorisierung		Apartmen t					

(https://wiki.openstreetmap.org/wiki/Map_Features#Historic)		OpenStreetMaps, o. a.		von anderen Unterkünften	Hotel						
Auszüge aus „Historische Plätze“ nach OpenStreet Maps (https://wiki.openstreetmap.org/wiki/Map_Features#Leisure)	explizit	Google Maps, OpenStreetMaps, o. a.	Explizite Angabe	Kategorisierung von Historischen Plätzen	Aircraft						
					Aquädukt						
					Archäologischer Schauplatz						
					Burg/Schloss						
					Gebäude (allgemein, bspw. Museum)						
					Stadttor						
					Stadtmauer						
					Denkmal						
					Meilenstein						
					Monument						
					Ruine						
					Runenstein						
					Schiff						
					Wrack						

Auszüge aus „Freizeit“	explizit	Google Maps, OpenStreetMaps, o. a.	Explizite Angabe	Kategorisierung von Orten im Freien	Spielothek						
					Badestrand						
					Bandstand						
					Vogelschlag						
					Tanz						
					Minigolf						
					Hundepark						
					Fitness-Center						
					Garten						
					Hacker-Space						
					Hafen						
					Park						
					Spielplatz						
					Schwimmbad						
Reise	explizit	Google Maps, OpenStreetMaps, o. a.			bezogen auf den Flughafen Frankfurt	Fahrkartenautomat					
						Informationssschalter					

12.3 Kontext-Modell des Gesamtkonzepts

12.4 Übersicht über Feedbackmechanismen des Gesamtkonzepts

Bezeichnung	Beschreibung
Aufruf der Detailansicht	
Aufenthaltsdauer an Items	
Bewertung von Items	Binäre Bewertung von Items
Nutzung von Items	
Schlagwortsuche nach Items	Schlagwörter nach
Critiquing beim Training des Systems	
Critiquing bei der Suche nach Items	

12.5 Benutzer-Modell des Prototyps

12.6 Item-Modell des Prototyps

12.7 Kontext-Modell des Prototyps

12.8 Übersicht über Feedbackmechanismen des Prototyps

12.9 Netzwerknachrichten im Prototyp